

**PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ
ESCOLA DE NEGÓCIOS
PROGRAMA DE PÓS-GRADUAÇÃO EM ADMINISTRAÇÃO
MESTRADO EM ADMINISTRAÇÃO**

DANIEL SCHNEIKER

**INFLAÇÃO: UMA APLICAÇÃO DE REDES NEURAIS LSTM PARA PREVISÃO E
ANÁLISE DE RELAÇÕES FUNCIONAIS COM VARIÁVEIS MACROECONÔMICAS
E EXPECTATIVAS**

CURITIBA

2019

DANIEL SCHNEIKER

**INFLAÇÃO: UMA APLICAÇÃO DE REDES NEURAIS LSTM PARA PREVISÃO E
ANÁLISE DE RELAÇÕES FUNCIONAIS COM VARIÁVEIS MACROECONÔMICAS
E EXPECTATIVAS**

Dissertação apresentada ao Programa de Pós-Graduação em Administração da Pontifícia Universidade Católica do Paraná, como requisito parcial para a obtenção do título de Mestre em Administração, linha de pesquisa em Finanças.

Orientadora: Prof^a. Dr^a. Ângela Cristiane Santos Póvoa.

CURITIBA

2019

Dados da Catalogação na Publicação
Pontifícia Universidade Católica do Paraná
Sistema Integrado de Bibliotecas – SIBI/PUCPR
Biblioteca Central
Edilene de Oliveira dos Santos CRB - 9/1636

S359i
2019

Schneiker, Daniel
Inflação : uma aplicação de redes neurais LSTM para previsão e análise de relações funcionais com variáveis macroeconômicas e expectativas / Daniel Schneiker ; orientadora, Ângela Cristiane Santos Póvoa. -- 2019
158 f. : il. ; 30 cm

Dissertação (mestrado) – Pontifícia Universidade Católica do Paraná, Curitiba, 2019.
Bibliografia: f. 136-146

1. Inflação. 2. Previsão. 3. Comportamento do consumidor. 4. Redes neurais (Computação). 5. Macroeconomia. I. Póvoa, Ângela Cristiane Santos.
II. Pontifícia Universidade Católica do Paraná. Programa de Pós-Graduação em Administração. III. Título.

CDD 20. ed. – 332.41

TERMO DE APROVAÇÃO

INFLAÇÃO: UMA APLICAÇÃO DE REDES NEURAIIS LSTM PARA PREVISÃO E ANÁLISE DE RELAÇÕES FUNCIONAIS COM VARIÁVEIS MACROECONÔMICAS E EXPECTATIVAS


Por

DANIEL SCHNEIKER

Dissertação aprovada como requisito parcial para obtenção do grau de Mestre no Programa de Pós-Graduação em Administração, área de concentração em Administração Estratégica, da Escola de Negócios da Pontifícia Universidade Católica do Paraná.




Prof.ª Dr.ª Angela Cristiane Santos Póvoa
Coordenadora do Programa de Pós-Graduação em Administração



Prof.ª Dr.ª Angela Cristiane Santos Póvoa
Orientadora



Prof. Dr. Pedro Guilherme Ribeiro Piccoli
Examinador



Prof. Dr. José Roberto Frega
Examinador

DEDICATÓRIA

Dedico este trabalho aos amigos da primeira infância, em especial a dois deles (eles saberão quem são). Mesmo depois de décadas de vida e dos mais diversos caminhos trilhados mundo afora, mantivemos e sempre reforçamos nossos laços de amizade, com lealdade e respeito acima de tudo.

AGRADECIMENTOS

Agradeço primeiramente a Deus, que me deu a vida, minha saúde, minha família e todas as condições privilegiadas que me fizeram chegar onde estou hoje.

Agradeço minha esposa Bianca e minha filha Anne pelo amor e companheirismo e que pacientemente me acompanharam neste processo e período de ausências parciais por conta da dedicação a este trabalho, e que sempre estiveram ao meu lado.

Agradeço meus pais pela minha educação, confiança e apoio que me fizeram trilhar o caminho percorrido até aqui.

Agradeço imensamente ao Banco Central do Brasil, esta casa de excelência, da qual tenho muito orgulho em fazer parte, pela confiança depositada no meu projeto. Sem o suporte desta estimada Autarquia eu certamente não teria produzido este trabalho neste momento.

Agradeço aos professores da banca, em especial a minha orientadora professora dra. Ângela, pelos apontamentos e disponibilidade.

Por fim, agradeço a todos os professores, colegas, amigos, à PUC-PR e todas as outras pessoas e empresas que de alguma forma contribuíram para que eu pudesse chegar até aqui.

A todos, meu “muito obrigado!”

ΕΠÍΓΡΑΦΕ

“What makes the bias particularly pernicious is that we all recognize this bias in others but not in ourselves.”

(Thaler, 2016, p. 22)

RESUMO

A inflação está entre as variáveis macroeconômicas mais importantes da economia, impactando diretamente pessoas físicas, jurídicas e governos. A previsão e o acompanhamento da inflação são fundamentais para que as metas de inflação sejam alcançadas. Entretanto, a política monetária, que é o principal meio para isso, tem que lidar com atrasos, no sentido que sua implementação leva determinado tempo para produzir efeitos. Assim, o ideal é que ela seja desenhada de maneira a se olhar para o futuro (Mandalinci, 2017). Esta orientação estratégica pública também interessa às empresas, uma vez que os modelos teóricos de formulação estratégica determinam que fontes de vantagem competitiva sofrem interferências do macroambiente. Empiricamente pode-se verificar que o comportamento de consumo das pessoas pode se alterar com base em suas expectativas e estado de satisfação. A partir disso, cabe investigar se variáveis oriundas do comportamento das pessoas poderiam impactar direta- ou indiretamente a inflação. Pretendeu-se com a presente pesquisa: 1) avaliar a previsibilidade do IPCA de 12 meses; 2) verificar a dinâmica da inflação futura por meio da análise da relação funcional com as variáveis elencadas e; 3) analisar a relevância das expectativas de inflação dos consumidores para o IPCA de 12 meses à frente. Para tanto, um conjunto inicial de 6 de um total de 361 variáveis foi obtido por *machine learning (feature selection)*. Posteriormente foram utilizadas redes neurais LSTM, não só como ferramenta preditiva e exploratória, mas como inovação metodológica, através das quais foram comparados um modelo puramente macroeconômico a modelos híbridos (com a inclusão das expectativas de inflação e renda e a satisfação com a vida). Entre os principais resultados verificou-se que: a inflação futura tem determinantes ligados à demanda, câmbio e *commodities*; a variável mais relevante tem origem nas mercadorias agropecuárias; tanto as expectativas quanto a satisfação com a vida interferiram negativamente no poder preditivo do modelo. Um resultado adicional foi a constatação de que as expectativas de inflação dos consumidores não atendem aos pressupostos da racionalidade, nem da hipótese das expectativas adaptativas, havendo indicações da presença de uma heurística de ancoragem.

Palavras-chave: Inflação. Previsão. Expectativas. Redes neurais. Relação Funcional. Comportamento

ABSTRACT

Inflation is among the most important macroeconomic variables of the economy, directly impacting individuals, corporations and governments. Forecasting and monitoring inflation is critical in order to inflation targeting to succeed. However, monetary policy, which is the main means for this, must deal with delays, in the sense that its implementation takes a certain amount of time to produce effects. Thus, ideally, it should be designed in a way to look forward into the future (Mandalinci, 2017). This public strategic orientation is also of interest to companies, since theoretical models of strategic formulation determine that sources of competitive advantage suffer interferences from the macroenvironment. Empirically it can be verified that people's consumption behavior may change based on their expectations and satisfaction status. Based on this, it is worth investigating whether variables derived from people's behavior could directly or indirectly impact inflation. The aim of this research was: 1) to evaluate the predictability of the 12-month IPCA; 2) to verify the dynamics of future inflation through the analysis of the functional relationship with the variables listed and; 3) to analyze the relevance of consumers' inflation expectations to the 12-month IPCA ahead. To do so, an initial set of 6 of a total of 361 variables was obtained by machine learning (feature selection). Subsequently, LSTM neural networks were used, not only as a predictive and exploratory tool, but as a methodological innovation, through which a purely macroeconomic model was compared to hybrid models (with the inclusion of inflation and income expectations, and life satisfaction). Among the main results, it was verified that: future inflation has determinants related to demand, currency exchange and commodities; the most relevant variable regards to agricultural and farming commodities; both expectations and satisfaction with life negatively interfered with the predictive power of the model. An additional result was the finding that consumer inflation expectations do not meet the assumptions of rationality nor the hypothesis of adaptive expectations, and there are indications of the presence of an anchorage heuristic.

Key words: Inflation. Forecast. Expectations. Neural Networks. Functional relationship. Behavior.

LISTA DE ILUSTRAÇÕES

Figura 1: Perceptron (elaboração própria)	57
Figura 2: Exemplo da arquitetura de uma rede MLP (elaboração própria).....	58
Figura 3: Um esboço de rede neural recorrente (elaboração própria).....	59
Figura 4: Diagrama dos procedimentos metodológicos	65
Figura 5: Séries Macroeconômicas Básicas (1 a 8)	73
Figura 6: Séries Macroeconômicas Básicas (9 a 15)	74
Figura 7: Variáveis macroeconômicas selecionadas normalizadas	79
Figura 8: Mean squared error em cada iteração	82
Figura 9: Previsões realizadas pelos modelos X IPCA 12 Meses Real.....	84
Figura 10: Relações funcionais das séries do modelo macroeconômico	88
Figura 11: Relações funcionais com as variáveis independentes normalizadas	91
Figura 12: Variáveis acrescentadas para formar os modelos híbridos.....	101
Figura 13: Comparação de previsões com os modelos híbridos.....	104
Figura 14: Relações funcionais (var.1.icbr) dos modelos híbridos	108
Figura 15: Relações funcionais (icbra) dos modelos híbridos	109
Figura 16: Relações funcionais (var.12.icbra.12) dos modelos híbridos	110
Figura 17: Relações funcionais (icbre.12) dos modelos híbridos	110
Figura 18: Relações funcionais (var.12.pibd.12) dos modelos híbridos	111
Figura 19: Relações funcionais (var.12.desemp.6) dos modelos híbridos	112
Figura 20: Relação funcional das expectativas de inflação dos consumidores	113
Figura 21: Relação funcional do índice de expectativa de renda pessoal.....	115
Figura 22: Relação funcional do índice de satisfação com a vida	118
Figura 23: Expectativas de inflação dos consumidores versus IPCA Acumulado 12 Meses.....	120
Figura 24: Scatterplot entre expectativas de inflação e variáveis.....	121
Figura 25: Dinâmica entre expectativas de renda pessoal e demais variáveis	129

LISTA DE QUADROS

Quadro 1: Quadro-resumo de modelos e variáveis.....	39
Quadro 2: Definição constitutiva e operacional	63
Quadro 3: Atributos macroeconômicos selecionados	78
Quadro 4: Variáveis utilizadas na seleção de atributos.....	159

LISTA DE TABELAS

Tabela 1: Estatísticas sobre as variáveis básicas	75
Tabela 2: Métricas de comparação	85
Tabela 3: Métricas de comparação com os modelos híbridos.....	106
Tabela 4: Correlação entre expectativas dos consumidores e IPCA acumulado	121
Tabela 5: Teste de causalidade de Granger	122
Tabela 6: Resultado da regressão para expectativas de inflação	125
Tabela 7: Correlação com o índice de expectativa de renda pessoal	128

LISTA DE SIGLAS

AR	<i>Autoregressive model</i>
ARCH	<i>Autoregressive Conditional Heteroskedasticity model</i>
ARIMA	<i>Autoregressive integrated moving average model</i>
ARMA	<i>Autoregressive moving average model</i>
BC	Banco Central
BCB	Banco Central do Brasil
BS	<i>Bootstrap</i>
BVAR	<i>Bayesian VAR</i>
BVS	<i>Bayesian Variable Selection</i>
CNI	Confederação Nacional da Indústria
Copom	Comitê de Política Monetária do BCB
CPI	<i>Consumer Price Index</i>
CSR	<i>Complete Subset Regression</i>
DMA	<i>Dynamic Model Averaging</i>
DMS	<i>Dynamic Model Selection</i>
EGARCH	<i>Exponential Generalized Autoregressive Conditional Heteroscedasticity model</i>
FAVAR	<i>Factor-Augmented VAR</i>
FED	<i>Federal Reserve</i>
FGV	Fundação Getúlio Vargas
GARCH	<i>Generalized Autoregressive Conditional Heteroskedasticity</i>
IBC-BR	Índice de atividade econômica do Banco Central
IBGE	Instituto Brasileiro de Geografia e Estatística
IBRE	Instituto Brasileiro de Economia da FGV
IC-Br	Índice de Preços das Commodities
INEC	Índice Nacional de Expectativa do Consumidor
IPA	Índice de Preços ao Produtor Amplo
IPCA	Índice Nacional de Preços ao Consumidor Amplo (IBGE)
LSTM	<i>Long Short-Term Memory</i>
MLP	<i>Multi Layer Perceptron</i>

PCA	<i>Principal Component Analysis</i>
PIB	Produto Interno Bruto
PME	Pesquisa Mensal de Emprego
PNAD	Pesquisa Nacional por Amostra de Domicílios
PPI	<i>Producer Price Index</i>
PVAR	<i>Panel VAR</i>
RL	Regressão Linear
RMSE	<i>Root mean squared error</i>
RNH	Rede neural híbrida
RNM	Rede neural macroeconômica
RNN	<i>Recurrent neural networks</i> / Redes neurais recorrentes
RS-VAR	<i>Regime-switching VAR</i>
SARIMA	<i>Seasonal autoregressive integrated moving average model</i>
TAR	<i>Threshold autoregressive model</i>
TVP-VAR	<i>Time-Varying Parameter VAR</i>
UCSV	<i>Unobserved Component Stochastic Volatility model</i>
VAR	<i>Vector autoregression</i>

SUMÁRIO

1. INTRODUÇÃO	17
1.1. DELIMITAÇÃO DO TEMA.....	19
1.2. PROBLEMA DE PESQUISA	21
1.3. OBJETIVO GERAL	23
1.4. OBJETIVOS ESPECÍFICOS	23
1.5. JUSTIFICATIVA TEÓRICA	23
1.6. JUSTIFICATIVA PRÁTICA.....	24
1.6.1. Inovação das ferramentas	24
1.6.2. Compreensão do impacto e relação funcional das variáveis como insumo para estratégias públicas e privadas	28
2. FUNDAMENTAÇÃO TEÓRICO-EMPÍRICA.....	29
2.1. A MACROECONOMIA E AS EMPRESAS	29
2.2. MODELOS E VARIÁVEIS PARA PREVISÃO DA INFLAÇÃO	31
2.2.1. Inflação	39
2.2.2. Variação da Taxa de Juros.....	41
2.2.3. Variação Cambial.....	42
2.2.4. Variação da Demanda	42
2.2.5. Variação dos Preços das <i>Commodities</i>.....	42
2.3. ECONOMIA COMPORTAMENTAL.....	43
2.4. EXPECTATIVAS E COMPORTAMENTO	44
2.4.1. Inflação inercial.....	47
2.4.2. Expectativas de inflação	48
2.4.3. Expectativas de renda.....	52
2.4.4. Felicidade e satisfação com a vida	54
2.5. REDES NEURAIS ARTIFICIAIS	56
3. METODOLOGIA.....	61
3.1. ESPECIFICAÇÃO DO PROBLEMA.....	61
3.2. DEFINIÇÃO CONSTITUTIVA E OPERACIONAL DAS VARIÁVEIS	61
3.3. DELINEAMENTO DA PESQUISA.....	63
3.4. PROCEDIMENTOS.....	64
3.4.1. Coleta de Dados.....	65
3.4.2. Pré-processamento e Seleção de Atributos.....	66
3.4.3. População, Amostra e Particionamento dos Dados	66

3.4.4.	Definição da Arquitetura da Rede Neural	67
3.4.5.	Treinamento da Rede	68
3.4.6.	Teste de Previsão	68
3.4.7.	Análise dos Resultados	69
3.4.8.	Treinamento Total e Verificação das Relações Funcionais	69
3.4.9.	Outros Achados Após os Resultados	70
4.	APRESENTAÇÃO E ANÁLISE DOS DADOS	71
4.1.	MODELO MACROECONÔMICO	71
4.1.1.	Dados Básicos	71
4.1.2.	Pré-Processamento e Seleção de Atributos	76
4.1.3.	Rede Neural LSTM Macroeconômica e a Previsão da Inflação	80
4.1.4.	Relações Funcionais	86
4.2.	MODELOS HÍBRIDOS	100
4.2.1.	Dados.....	100
4.2.2.	Pré-Processamento	102
4.2.3.	Redes Neurais LSTM Híbridas e a Previsão da Inflação	102
4.2.4.	Relações Funcionais das Variáveis Macroeconômicas	107
4.2.5.	Relação Funcional das Expectativas de Inflação dos Consumidores 112	
4.2.6.	Relação Funcional do Índice de Expectativa de Renda Pessoal...	114
4.2.7.	Relação Funcional do Índice de Satisfação com a Vida	117
4.2.8.	Outros Achados e Discussões	119
5.	CONSIDERAÇÕES FINAIS	132
6.	REFERÊNCIAS BIBLIOGRÁFICAS	137
	ANEXO A – VARIÁVEIS INDEPENDENTES UTILIZADAS NA SELEÇÃO DE ATRIBUTOS PARA O MODELO MACROECONÔMICO	148

1. INTRODUÇÃO

A inflação está entre as variáveis macroeconômicas mais importantes na economia. De uma forma ou de outra ela impacta a trajetória de vida de pessoas físicas, pessoas jurídicas, instituições, governos e países. Especialmente nos países que adotaram o regime de metas de inflação, o controle da inflação tem tamanha importância que está entre os objetivos essenciais de governos e bancos centrais, e em nosso caso, é um dos pilares da missão institucional do Banco Central do Brasil: “Assegurar a estabilidade do poder de compra da moeda [...]” (Banco Central do Brasil, 2017).

A inflação descontrolada dos anos 80 e início dos anos 90 hoje não faz mais parte do cotidiano dos brasileiros, uma vez que a implantação do plano Real em 1994 trouxe alívio e mais clareza na programação orçamentária de famílias e empresas. O aspecto nocivo de altos níveis de inflação não está apenas ligado à questão monetária do poder de compra, mas também à confiança de empresários na economia, o que na prática reduz o nível de investimentos privados no país.

A manutenção de taxa de inflação baixa, estável e previsível é a melhor contribuição da política monetária para o crescimento econômico sustentável, com desemprego baixo e consequente melhora nas condições de vida da população (Banco Central do Brasil, 2017).

É fácil perceber que a perda de poder de compra da moeda não interessa a cidadãos ou empresas, pois isto não lhes traz qualquer efeito benéfico em suas poupanças e programação de gastos. O que certamente interessa a todos os participantes envolvidos no ambiente econômico, é a manutenção de inflação em níveis saudáveis. Tão importante quanto isto é a compreensão do ambiente inflacionário e a possibilidade de estimar a inflação futura com a maior clareza possível. A necessidade de se lidar com um horizonte menos nebuloso é o motivo pelo qual se faz necessária uma ferramenta de estimativas e compreensão da inflação tanto para a esfera pública quanto a privada.

A previsão da inflação do ponto de vista do governo é fundamental para o desenvolvimento de políticas públicas no país. No nosso caso, com as metas de inflação implantadas em 1999, o acompanhamento e previsão da inflação se fazem necessários para que as metas estabelecidas sejam alcançadas. A compreensão sobre a situação da inflação no país, bem como sua previsão, tem objetivos não

apenas informativos, mas sim de interferência em decisões de política fiscal, cambial e principalmente monetária. Mandalinci (2017) observa que a política monetária tem que lidar com atrasos, no sentido que sua implementação leva determinado tempo para produzir efeitos. Assim, o ideal é que ela seja desenhada de maneira a se olhar para o futuro, o que destacaria a importância de se obter previsões precisas para a inflação. Desta forma, parece claro o interesse público sobre as estimativas de inflação futura.

Do ponto de vista exclusivo das empresas, a previsão de inflação é importante para a confiança do empresariado na economia. Sendo a atividade empreendedora uma atividade inerentemente arriscada, a previsão de variáveis macroeconômicas é de fundamental importância para a redução de algumas das incertezas. Na medida em que se possa entender com mais clareza pelo menos parte do ambiente econômico, os gestores têm mais suporte para tomar decisões de investimento, endividamento e outras questões orçamentárias.

Muitas vezes pode-se acreditar que os efeitos da inflação sobre a criação de valor da empresa podem ser ignorados, principalmente quando se trata de países desenvolvidos com baixíssimas taxas de inflação. Entretanto, o empresário terá sua margem de lucro corroída se não mensurar corretamente seus custos. Mesmo que tenha ciência dos custos impactados pela inflação, a simples intenção de repassar estes custos ao consumidor não impede a inflação de corroer o valor da empresa. Muitos gestores atuam de modo a assegurar que os lucros cresçam à mesma taxa da inflação como medida para se proteger dos efeitos destrutivos dela. No entanto, uma análise mais cautelosa mostra que os lucros na verdade são obrigados a crescer a taxas mais altas que a inflação (Goedhart, Koller, & Wessels, 2010).

Repassar os preços ao consumidor sem perder lucratividade não é algo simples e pode criar desafios significativos para algumas indústrias. Tome-se como exemplo o caso das companhias de refrigerantes nos Estados Unidos, no início da década de 2010. Os custos associados à produção desta indústria (como latas de alumínio, xarope e combustível para caminhões de entrega), cresceram em ritmo mais acelerado do que a média, fazendo com que empresas como a PepsiCo e a Coca-Cola, em meio a uma economia vagarosa, tivessem bastante dificuldade para repassar estes custos aos consumidores (Parnell, 2013). O aumento de preços é certamente um risco para os negócios, ainda mais em um clima econômico nebuloso,

mas deixar de fazê-lo, tendo como causa a inflação, é muito provavelmente uma ameaça à organização e dificilmente a melhor decisão a ser tomada.

No que tange ao processo decisório, há poucas décadas os gestores costumavam subsidiar suas decisões embasadas apenas em suas próprias experiências e instintos. Na era da informação em que vivemos e da abundância de dados disponíveis, os métodos quantitativos têm se mostrado não só como uma ferramenta complementar à experiência da gestão, mas como um instrumento sólido para suportar decisões de negócios. Crescentemente a administração estratégica moderna, pública e privada, tem se valido de técnicas quantitativas no processo decisório. A correta utilização deste instrumental disponível pode reduzir muito a complexidade de problemas e trazê-los a níveis mais prontamente gerenciáveis, tornando o processo decisório mais assertivo e menos subjetivo.

1.1. DELIMITAÇÃO DO TEMA

A previsão da inflação infelizmente não é uma tarefa trivial. Economistas, analistas financeiros e estatísticos estudam como melhorar os modelos do processo inflacionário, avaliando com profundidade e complexidade crescentemente maior as variáveis que poderiam explicar e prever o comportamento futuro das taxas de inflação. A área clássica que trabalha com estes dados é a econometria, uma área da economia que surgiu como disciplina científica na primeira metade do século passado.

Conforme Heij, De Boer, Franses, Kloek & Van Dijk (2004), a tomada de decisão nos negócios e na economia é frequentemente subsidiada pelo uso de informação quantitativa. Os modelos econométricos ajudam a entender a relação entre variáveis econômicas e de negócios e a analisar os possíveis efeitos das decisões. Hoje a econometria se constitui numa ferramenta indispensável para modelar empiricamente a realidade em quase todas as disciplinas da economia e dos negócios.

Os modelos econométricos são bastante utilizados para se estudar diversas variáveis macroeconômicas, entre elas a inflação. No entanto, ao elaborar um modelo de previsão qualquer, dois parâmetros a serem decididos se apresentam como cruciais.

Um deles é se o modelo tentará explicar o comportamento futuro da variável justificado apenas pela própria variável, ou seja, com base em seu comportamento

passado. Neste caso o modelo econométrico seria univariado e, como exemplo, poderia ser um modelo autorregressivo (AR) tradicional. Caso se suponha que a variável estudada seja resultado da interferência de outras variáveis, passa-se então a definir um modelo multivariado, como no caso de um vetor autorregressivo (VAR).

Outro parâmetro é se o modelo contemplará relações lineares ou não-lineares entre a variável dependente e as independentes. Neste contexto, existem modelos econométricos não-lineares, mas uma opção mais moderna é a rede neural artificial.

As redes neurais são uma técnica pertencente à classe dos algoritmos de inteligência artificial. Sua maior vantagem está em aproximar qualquer função, de qualquer ordem, linear ou não, e sua capacidade de generalizar para dados fora da amostra, além de ser um método não paramétrico. Afora as vantagens técnicas, existe ainda uma razão filosófica beneficiada pelo emprego das redes neurais. A inteligência artificial muda o foco do problema. Não sendo um método rígido, matemático e lógico absoluto, ela foca nos aspectos mais naturais da questão e é apta a abordar de forma mais natural os problemas de um mundo incerto, sem o absolutismo matemático. Isso faz dela uma candidata apropriada quando o que se quer analisar é o reflexo do comportamento econômico das pessoas e empresas, ou dados advindos das ciências sociais.

Ainda sobre as redes neurais, considerando os tipos existentes e as características dos dados econométricos, um tipo adequado seriam as redes neurais recorrentes (RNN ou *recurent neural networks*), mais especificamente um subtipo chamado *Long Short-Term Memory* (LSTM), que são adequadas para a pesquisa em séries temporais. Como resultado, a aplicabilidade do modelo é bastante ampla, sendo de utilidade e interesse estratégico de governos, bancos centrais, corporações, pequenas empresas e até mesmo pessoas físicas.

Evidências na literatura, referenciadas mais adiante, mostram que outras variáveis não ligadas diretamente ao processo inflacionário podem ter impactos sobre a economia. Mais especificamente, verificou-se que as expectativas da população e o nível de felicidade ou satisfação com a vida podem mudar os patamares de consumo e poupança das pessoas. As atitudes advindas destes comportamentos, de uma forma ou de outra, acabam interferindo sobre a demanda e oferta dos bens no mercado, o que poderia alterar os preços dos respectivos produtos em uma economia.

A finalidade desta pesquisa é avaliar a previsibilidade da inflação brasileira para 12 meses por dados multivariados tendo as redes neurais como ferramenta preditiva e exploratória, e avaliar se a inclusão de variáveis que expressam expectativas e opiniões da população contribui para explicar a dinâmica da inflação futura.

Inicialmente será elaborado um modelo apenas com as variáveis macroeconômicas, ou tradicionais, por assim dizer, as variáveis mais comuns na literatura econométrica para previsão da inflação (chamado aqui de modelo tradicional ou modelo macroeconômico). Em seguida serão elaborados três modelos híbridos, com a adição de três variáveis externas que não são diretamente macroeconômicas. Entre os objetivos, está o de analisar se estas variáveis trazem informação preditiva para o modelo tradicional e verificar qual é o efeito em termos de poder explicativo para a inflação futura.

Outra finalidade da pesquisa, igualmente importante, é verificar o relacionamento funcional entre as variáveis e a inflação futura. Basicamente busca-se responder nesta etapa que tipo de impacto um aumento ou diminuição em cada variável provoca na inflação à frente, verificando inclusive o comportamento das variáveis incluídas nos modelos híbridos.

No quesito “variáveis a serem usadas”, cabe observar também, que será feito um procedimento prévio de mineração de dados (*data mining*) no intuito de se buscar as melhores configurações de variáveis macroeconômicas (com a adição de defasagens, diferenciações, etc.). Esta etapa de *machine learning*, chamada de seleção de atributos (*feature selection* ou *attribute selection*) para encontrar as melhores variáveis também faz parte dos objetivos do trabalho e foi um resultado encontrado pela pesquisa. São as variáveis resultantes desta etapa que entraram no modelo tradicional, que posteriormente recebeu as variáveis externas para formar o modelo híbrido.

1.2. PROBLEMA DE PESQUISA

Os modelos não lineares, em especial as redes neurais, tem se apresentado como uma das soluções para a compreensão de variáveis macroeconômicas nos últimos anos, embora a literatura sobre o assunto não seja tão abundante quanto à abordagem econométrica. De maneira geral há evidências (conforme referências mais à frente) de que as séries temporais econômico-financeiras têm inter-relacionamentos

não-lineares, motivo pelo qual os modelos lineares com alguma frequência têm desempenho inferior, sendo necessário e importante o entendimento destes inter-relacionamentos.

Outra questão debatida na literatura é se as expectativas inflacionárias têm poder preditivo sobre a inflação futura. Desta forma, é cabível uma investigação sobre a relevância desta variável. A análise dos efeitos das expectativas sobre a inflação futura, possibilita alguma discussão sobre a racionalidade na formação destas expectativas, uma vez que se abrem no mínimo três possibilidades teóricas de análise, ou seja, de que as expectativas são: adaptativas, racionais ou de racionalidade limitada (tal como prega a economia comportamental).

Considerando a pertinência da compreensão e previsão da inflação para o governo, sociedade e todos os agentes envolvidos na economia, e, considerando os avanços que a inteligência artificial tem trazido ao longo dos anos, e ainda o núcleo de variáveis comuns, baseadas em trabalhos anteriores, que até então se julgou como candidatas relevantes para o presente estudo – a saber: a inflação ao consumidor, a inflação ao produtor, a taxa de juros (Selic), a taxa de câmbio, um indicador ligado à demanda, os preços das *commodities*, as expectativas de inflação e renda, e o grau de satisfação com a vida – estabeleceu-se o seguinte problema de pesquisa:

Qual o poder preditivo, o impacto e o tipo de relação funcional das variáveis macroeconômicas na inflação futura e como estes atributos são afetados com a inclusão das expectativas?

O termo “poder preditivo” do problema de pesquisa refere-se à magnitude dos erros gerados pela capacidade das variáveis preverem a inflação, através do modelo proposto. Já o termo “impacto” diz respeito ao grau/magnitude de influência de cada variável independente. Busca-se aqui verificar em que escala determinada variável é impactante ou relevante. Define-se também o termo “relação funcional” como sendo a relação entre a variação em uma variável independente e a produção de variação na variável dependente. Deste modo, é pela observação da relação funcional que se verificará o impacto das variáveis, como descrito anteriormente, mas também visa-se saber se a relação é linear ou não, ou seja, qual o formato da interferência da variável independente, ou ainda, de que maneira a inflação futura é função de determinada variável.

1.3. OBJETIVO GERAL

Verificar o poder preditivo, o impacto e o tipo de relação funcional das variáveis macroeconômicas na inflação futura, e como estes atributos são afetados com a inclusão das expectativas.

1.4. OBJETIVOS ESPECÍFICOS

A fim de se atingir o objetivo geral, encontram-se abaixo alguns objetivos intermediários sumarizados que serão efetuados:

- a) Encontrar o conjunto de variáveis, candidatas ao modelo macroeconômico, através de um procedimento prévio de seleção de atributos (por *machine learning*, segundo o algoritmo de Hall (1999))
- b) Avaliar o poder preditivo do modelo tradicional pela raiz do erro quadrático médio (RMSE).
- c) Verificar o impacto e o tipo de relação funcional das variáveis tradicionais, pelo modelo tradicional.
- d) Avaliar o poder preditivo (RMSE) dos modelos híbridos, pela inclusão das outras variáveis e comparar com o modelo tradicional.
- e) Verificar o impacto e o tipo de relação funcional das variáveis tradicionais e expectativas, segundo os modelos híbridos.
- f) Traçar conclusões a respeito da relevância das variáveis macroeconômicas quanto ao poder preditivo e às relações com a inflação futura
- g) Traçar conclusões a respeito da inclusão das expectativas quanto ao poder preditivo e às relações com a inflação futura.

1.5. JUSTIFICATIVA TEÓRICA

A contribuição teórica mais objetiva desta pesquisa está em se verificar que contribuição e relevância as expectativas e felicidade/satisfação com a vida têm como fator explicativo para a dinâmica dos preços futuros. Evidências empíricas mais à frente mostram a existência destas relações, sejam relações diretas com a inflação ou com outras variáveis econômicas como o consumo e a poupança. Em muitos trabalhos, no entanto, as relações foram modeladas por métodos econométricos e sem considerar simultaneamente as outras variáveis mais usuais da macroeconomia.

Outra contribuição, igualmente importante, é no sentido de explorar o relacionamento funcional das variáveis explicativas com a variável dependente. Apesar de em muitas pesquisas se debater e verificar empiricamente os fatores causadores e explicativos para a inflação futura, mesmo quando se chega a modelos com bom poder preditivo, por muitas vezes não se verificam claramente como estes fatores se relacionam funcionalmente com a inflação. Estas características constituem informações relevantes para uma melhor compreensão sobre os determinantes da inflação futura.

Apesar do grande uso dos modelos econométricos para modelar variáveis macroeconômicas e do crescimento da utilização de redes neurais no assunto, a contribuição desta pesquisa para a literatura também está na metodologia, isto é, no emprego específico da arquitetura LSTM no estudo da inflação haja vista ser frequentemente citada como uma metodologia adequada para séries temporais. Constata-se pouquíssimos trabalhos considerando a previsão da inflação por redes neurais, e mais escasso ainda é o emprego do subtipo LSTM, área para a qual esta pesquisa busca contribuir.

Por fim, também pode se contribuir com a teoria na etapa de seleção de atributos, uma vez que podem ser reveladas variáveis ou situações ainda não verificadas na literatura.

1.6. JUSTIFICATIVA PRÁTICA

A pesquisa contribui com a prática de duas formas: 1) como inovação ou aperfeiçoamento das ferramentas preditivas e de estudo da dinâmica inflacionária e, 2) como compreensão, por parte dos agentes interessados, do impacto e tipo de relacionamento entre as variáveis e a inflação.

1.6.1. Inovação das ferramentas

Embora a utilização de métodos quantitativos no processo decisório não seja algo novo, o que é recente e inovador é a associação da inteligência artificial. As decisões nas organizações públicas e privadas ainda são em grande parte pautadas na experiência dos gestores. Quando o problema envolve a obtenção de informação não-observável diretamente (nem mesmo com grande experiência do gestor) a inteligência artificial, e neste caso específico as redes neurais, aparecem como

possível solução. A pesquisa provê um modelo que pode ser implementado por gestores públicos, instituições, pessoas físicas e empresas – especialmente as organizações participantes do mercado financeiro como bancos, financeiras e corretoras.

A importância de se ter um modelo acurado para previsão da inflação aparece na esfera pública como uma estratégia para políticas públicas e na esfera privada como um ativo estratégico, conforme sumarizado a seguir.

1.6.1.1. A precisão da previsão da inflação como estratégia pública

As previsões de variáveis macroeconômicas são cruciais para a economia e atividade dos negócios, tendo em vista a necessidade de se estabelecer uma percepção geral sobre o futuro e a incerteza que envolve a visão além do presente.

A qualidade, confiabilidade e precisão das previsões são de suma importância, pois as decisões macroeconômicas de um país sensibilizam a população a formar expectativas sobre os cenários vindouros – moldando assim seu comportamento e afetando-a em determinado grau – e prepararão o ambiente para o qual as empresas deverão lidar com previsões microeconômicas.

Partindo do pressuposto de que: 1) decisões de negócios não podem ser tomadas isoladamente sem considerar o ambiente macroeconômico; 2) não é esperado que as empresas (exceto as do mercado financeiro) tenham modelos de previsão de inflação; 3) as organizações não têm controle sobre a variável inflação; torna-se imprescindível e de interesse público que o governo (e outras agências que atuam no mercado) tenha as ferramentas necessárias para a compreensão da inflação. Logo, a qualidade, precisão e confiabilidade das previsões da inflação se tornam primordiais.

No auxílio ao processo decisório, a fonte de informações no nível macroeconômico muito provavelmente será o governo federal. Assim, a previsão de variáveis macroeconômicas, inclusive a inflação, entra no escopo estratégico da sociedade como um todo. Supondo-se que o governo faça um trabalho bem-sucedido no controle e previsão de variáveis macroeconômicas, ele irá interferir positivamente nas estratégias das empresas.

Se há então o interesse corporativo para que o governo atue de forma positiva sobre a economia, a parcela das estratégias empresariais fundamentada nas

estimativas macroeconômicas, entre elas as previsões inflacionárias, terá que ser confiada à estratégia de atuação do governo. No que se refere à inflação, esta atuação ocorrerá por meio de políticas a fim de se cumprir as metas estabelecidas. Considerando a atual vigência do regime de metas de inflação no Brasil, faz-se necessário o uso de ferramentas preditivas para atuação do governo sobre a economia. Não basta apenas olhar a inflação atual, mas sim estimar seu comportamento futuro para que as metas inflacionárias sejam atingidas principalmente via política monetária. Conforme observam Lima, Araujo & Costa e Silva (2011, pp. 360-362):

Nesse tipo de regime, a política monetária volta-se para o comportamento do índice de inflação de forma a atingir o nível desejado de inflação no horizonte de tempo apropriado [...] não se deve tomar decisões de política monetária de acordo com a inflação atual e sim olhar movimentos na inflação esperada, olhar para frente (*forward looking*) e agir de forma premeditada para se antecipar às pressões de preços futuros e, dessa forma, reduzir a volatilidade no emprego e na produção [...] a construção de modelos de previsão e de projeção de variáveis econômicas é fundamental para o êxito do sistema de metas para a inflação.

Assim, a previsão da inflação via modelos é parte importante para o atingimento destas metas e o bom funcionamento da economia, pois a qualidade da previsão fará com que o governo atue sobre ela antecipadamente, via política monetária, obtendo resultados mais assertivos. Logo, pode-se concluir que as decisões de negócios e consequente implementações estratégicas têm seu sucesso em parte justificado indiretamente pela capacidade do governo federal em prever a inflação.

A inflação é parte essencial do planejamento estratégico do Banco Central do Brasil. Cabe citar entre as orientações estratégicas do BC, formuladas para o período 2016 a 2019, a missão: “Assegurar a estabilidade do poder de compra da moeda [...]” (Banco Central do Brasil, 2017) e o primeiro objetivo estratégico: “1. Assegurar o cumprimento das metas de inflação estabelecidas pelo Conselho Monetário Nacional [...]” (Banco Central do Brasil, 2017). Portanto, a previsão e consequente atuação sobre a inflação é estratégia de governo, que por sua vez, é estratégia de interesse público e certamente integrará (mesmo que in- ou conscientemente ignorada) as estratégias das empresas.

Uma vez que cidadãos e empresas comuns não tem controle sobre a inflação, é pouco provável que modelem este processo a fim de conhecer suas causas, e principalmente suas estimativas futuras. Interessa a eles que o governo, através do

Banco Central, tenha as ferramentas necessárias para alcançar estas finalidades. O desenvolvimento e o estudo destas ferramentas irão interferir sobre as estratégias do governo (políticas públicas), que por fim interferirá diretamente nas estratégias das empresas. Em suma, se o governo for bem-sucedido em suas estratégias macroeconômicas, estará muito provavelmente contribuindo positivamente com as estratégias organizacionais no nível microeconômico.

1.6.1.2. A precisão da previsão da inflação como ativo estratégico

As empresas que atuam no mercado financeiro tais como bancos comerciais, bancos de investimentos, financeiras, corretoras, *asset managements* e demais organizações participantes dos mercados de capitais, de crédito, de câmbio e monetário têm especial interesse em modelar com a melhor precisão possível as variáveis que afetam diretamente o ambiente no qual competem. Nestes casos, a importância de estimativas de inflação adequadas não está baseada apenas nas bem-sucedidas atuações governamentais como anteriormente descrito, mas sim no que diz respeito principalmente à interferência direta em suas estratégias, operações e negócios. Estas organizações têm um interesse maior em desenvolver ferramentas próprias (ou adquiri-las de terceiros) de modo a ampliar as ferramentas e as informações geradas por elas (previsões) como parte de seus ativos estratégicos.

A literatura em administração estratégica coloca o papel do conhecimento como uma fonte de recursos das empresas de forma a buscar vantagem competitiva. A abordagem da visão baseada em recursos (Penrose, 1959; Wernerfelt, 1984; Barney, 1991) embora reconheça este papel, não o coloca como o mais importante recurso disponível. Esta importância é dada na visão baseada em conhecimento.

Esta perspectiva presume que os serviços empreendidos por uma empresa dependem de como seus recursos são combinados e aplicados, os quais são resultados do *know-how* (conhecimento) da empresa. Uma característica importante desta visão é que a fonte de vantagem competitiva não está no conhecimento em si, mas sim na aplicação do conhecimento. A aplicação efetiva deste conhecimento levaria a uma elevação do desempenho organizacional (Alavi & Leidner, 2001). Considerando a visão baseada em conhecimento, as organizações do mercado financeiro de posse de informações que aperfeiçoem seus modelos financeiros estariam em vantagem competitiva com viés de melhora em seus desempenhos.

1.6.2. Compreensão do impacto e relação funcional das variáveis como insumo para estratégias públicas e privadas

Assim como o conhecimento sobre o modelo, a compreensão funcional dos determinantes da inflação futura também pode ser vista como ativo estratégico que se insere na visão baseada em conhecimento. O conhecimento das variáveis impactantes da inflação e suas relações contribuem não apenas para gerar vantagem frente aos concorrentes, mas como ferramenta para conhecer melhor o mercado e o próprio negócio. A investigação e conhecimento destas variáveis pode se tornar um ativo estratégico, não adquirido por concorrentes. Um exemplo disso seria o caso hipotético de uma empresa exportadora que descobre, através de um modelo de previsão de inflação com diversas variáveis explicativas, que a partir de um certo patamar, a taxa de câmbio tem pouca influência na inflação futura, *coeteris paribus*. Se ela também opera no mercado interno, essa informação é bastante valiosa, pois indica que uma alta na taxa de câmbio a partir daquele patamar criará receitas para a empresa, e, estando o modelo correto, não impactará a demanda interna, uma vez que não haverá efeitos sobre a inflação. Este conhecimento pode balizar estratégias para este cenário em que se encontra a empresa.

Como interesse público, a constatação da relação funcional entre a inflação e seus determinantes também é um conhecimento relevante. Neste sentido, Summa & Macrini (2014) mostraram o relacionamento dinâmico de algumas variáveis com a inflação, de acordo com o modelo de redes neurais empregado naquele trabalho. Como exemplo da relevância pública de se verificar a relação entre os determinantes e a inflação, pode-se citar a relação funcional que os autores trouxeram entre a inflação importada e a inflação. A demonstração visual de como a inflação importada se relaciona com a inflação permitiu aos autores elaborar a hipótese de que uma queda na inflação importada, não tem se refletido na inflação futura na mesma escala do que na ocorrência de um aumento. Isto poderia indicar que a diminuição nos custos dos produtos, pela queda da inflação importada, acaba se transformando em ganho para as empresas, pois estes custos não estariam sendo repassados para os preços na mesma proporção, gerando então crescimento nas margens de lucro. Este tipo de conhecimento é relevante para o governo pois pode servir de base para tomada de decisões frente a planos de política econômica, fiscal, monetária ou cambial.

2. FUNDAMENTAÇÃO TEÓRICO-EMPÍRICA

Nesta seção discorre-se sobre a relação da macroeconomia e as empresas, os diversos modelos e variáveis utilizados para a previsão de inflação, bem como sobre a economia comportamental e o papel das expectativas. Por fim apresenta-se uma breve conceituação das redes neurais.

2.1. A MACROECONOMIA E AS EMPRESAS

O acompanhamento das variáveis macroeconômicas se tornou um elemento importante para decisões de negócios mais acertadas. A tomada de decisão é um processo complexo e difícil, para a qual a macroeconomia provê subsídios fundamentais para auxiliar os CEOs a comandar os negócios. Para se compreender como a macroeconomia interfere nos negócios, basta analisar que toda decisão e estratégia empresarial será implementada no ambiente macroeconômico, cujas variáveis as empresas não podem controlar e para as quais podem apenas se preparar ou antecipar reações. A atividade geral da economia, os efeitos das políticas econômicas e a inflação afetam os negócios, visto que estes efeitos afetam a demanda futura, além de interferirem também no risco país, no desempenho das ações de empresas listadas em bolsa, na probabilidade de falência das empresas e no nível de suas margens de lucro (Montes & Tiberto, 2012), (Snieska, Laskiene, & Pekarskiene, 2008), (Bhattacharjee, Higson, Holly, & Kattuman, 2009), (Machin & Van Reenen, 1993). A depender das variáveis envolvidas, as empresas menores podem inclusive estar mais vulneráveis ao ambiente macroeconômico (Berger & Udell, 1998).

As políticas macroeconômicas devem ser adequadamente direcionadas a favorecer o ambiente de negócios de modo a incentivar o desenvolvimento e a manutenção das atividades de negócio. Por outro lado, políticas macroeconômicas eventualmente inadequadas podem deteriorar o desempenho de uma indústria (Arestis & Sawyer, 1999).

O principal objetivo das políticas macroeconômicas é reduzir a incerteza e o risco na tomada de decisões econômicas. Políticas macroeconômicas produzem efeitos diretos e interferem nas decisões das empresas, por exemplo, em decisões referentes a produção, contratação, exportação e importação, mas também impactam

decisões das pessoas quanto ao consumo, poupança e empréstimo (Banco Mundial, 2014).

A macroeconomia ajuda a assimilar o ambiente microeconômico, haja vista que esta área é inapta para lidar com problemas monetários, fiscais, cambiais, inflacionários e recessivos, dos quais os negócios precisam ser protegidos. Os fatores microeconômicos dizem respeito específicos às organizações. As decisões estratégicas de negócios são baseadas em fatores deste ambiente e pautadas por impactos futuros nas receitas, lucros, margens, volume de produção, publicidade, etc. (Sun, 2017). Permeando o ambiente microeconômico estão presentes os fatores macroeconômicos, que normalmente são perigosos e muitas vezes difíceis de serem previstos com precisão.

Todos os modelos teóricos de formulação estratégica, tais como as clássicas análises PEST (análise Política, Econômica, Social e Tecnológica) e SWOT (forças, fraquezas, oportunidades e ameaças), bem como as conhecidas cinco forças de Porter, determinam que as fontes de vantagem competitiva sofrem interferências das forças do macroambiente. Alterações nas forças macroambientais podem, por exemplo, impactar diretamente qualquer das cinco forças de Porter e consequentemente impactar a atratividade de um setor. As forças macroeconômicas afetam a saúde geral e bem-estar de uma nação, que por sua vez afetam as competências das empresas em buscar uma taxa de retorno apropriada (Hill & Jones, 2009).

O nível da taxa de inflação e sua oscilação são parâmetros fundamentais para o crescimento das empresas e as decisões de negócios. Um ambiente de inflação elevada ou com perspectiva inflacionária imprevisível gera situações negativas haja vista que: afasta possíveis investimentos e desacelera o crescimento, tornando-o baixo por um período mais longo; leva a distorções e mais incerteza tornando mais difícil as empresas tomarem decisões sobre o futuro, como as que envolvem investimentos¹ (Blanchard & Johnson, 2012); custos e desgastes adicionais podem advir deste ambiente inflacionário, desde a simples remarcação dos preços com mais frequência até as negociações salariais que visam manter o poder de compra dos

¹ Torna-se difícil e nebuloso fazer estimativas quanto aos retornos reais futuros, bem como surge a expectativa de alta nas taxas de juros, tornando mais cara a obtenção de recursos para financiamentos. Considerando nosso caso doméstico, com as metas de inflação, a política monetária via taxa SELIC é o principal instrumento do qual dispõe o Banco Central para controle da inflação.

funcionários; a competitividade internacional se altera, pois os custos do país sobem com a inflação, fazendo com que o preço de bens e serviços fiquem menos competitivos no comércio internacional (Parnell, 2013); e por fim, cria-se um ambiente de desconfiança na qual a própria população investe menos e acaba restringindo o crescimento dos negócios. Considerando estas dimensões, Hill & Jones (2009, p. 65) explicam que:

A inflação de preços pode desestabilizar a economia, produzindo crescimento econômico mais lento, taxas de juros mais altas, e movimentos cambiais voláteis [...] Em um ambiente inflacionário, pode ser impossível prever com qualquer precisão o valor real de retornos que podem ser obtidos de um projeto de cinco anos à frente. Tal incerteza torna as empresas menos dispostas a investir. Esta retenção por sua vez deprime a atividade econômica e por fim empurra a economia para dentro de uma recessão. Portanto, inflação alta é uma ameaça às empresas.

2.2. MODELOS E VARIÁVEIS PARA PREVISÃO DA INFLAÇÃO

A modelagem e previsão da inflação é objeto de estudo da econometria. Conforme será visto na sequência, a especificação dos modelos preditivos pode variar entre modelos puramente estatísticos ou modelos econômicos, assim podendo incluir: modelos autorregressivos (AR), de médias móveis (MA), modelos combinando ambos (ARMA, ARIMA), modelos que incorporam sazonalidade (SARIMA), vetores autorregressivos (VAR) e suas variantes, bem como modelos estruturais que decompõem uma série em outras séries (tendência, ciclo, sazonalidades e ruído). Em relação às variáveis explicativas, quando o modelo é univariado, a própria inflação uma ou mais vezes defasadas é a variável explicativa para o modelo. No caso multivariado, além da inflação defasada, variáveis explicativas comuns nos modelos são: algum indicador característico de demanda (PIB, produção industrial, taxa de desemprego, índices como o IBC-BR do Banco Central, etc.), a taxa de câmbio e a taxa de juros.

Para modelar a previsão de inflação, Bonno (2014) comparou um modelo SARIMA com um modelo estrutural, abordando como variáveis a própria inflação defasada, utilizando o IPCA, além de incorporar no modelo estrutural as séries IBC-BR, índice de preços ao consumidor dos EUA, expectativa da inflação do mercado segundo o relatório Focus, taxa de câmbio, taxa de desemprego e taxa SELIC. Como resultado, verificou-se que o SARIMA, um modelo puramente estatístico, se mostrou superior para previsões fora da amostra em relação ao modelo estrutural que incorpora variáveis econômicas. Uma das explicações aventadas para esta

superioridade é a presença da persistência inflacionária, que foi melhor capturada pelo SARIMA.

Carlo & Marçal (2016) analisaram modelos para previsão do IPCA, utilizando tanto o índice agregado total quanto seus componentes desagregados. Para os modelos desagregados foram especificados modelos SARIMA. Para os modelos agregados, além do SARIMA, foram testados um modelo estrutural e outro do tipo *Markov-switching* (mudança de regime Markoviana). As variáveis utilizadas foram as próprias séries agregada e as desagregadas. A conclusão mais relevante foi de que a previsão do IPCA baseado nas séries mais desagregadas, ou seja, as que faziam parte do maior nível de desagregação, composto por 52 itens, foi a que gerou o menor erro quadrático médio para vários horizontes temporais. Houve também melhora na previsão na combinação entre modelos, principalmente entre os modelos do nível de agregação total.

Caldeira, Moura & Santos (2015), testaram vários modelos do tipo vetor autorregressivo (VAR), tais como TVP-VAR, VAR clássico, VAR bayesiano (BVAR) e FAVAR na previsão das séries macroeconômicas: SELIC, PIB (IBC-BR) e a inflação medida pelo IPCA. Além disso testaram a combinação dinâmica de modelos, bem como a variação de parâmetros ao longo do período testado. As variáveis utilizadas mudavam conforme o modelo testado, mas poderiam contemplar até 20 variáveis macroeconômicas, incluindo o PIB, a produção industrial, utilização da capacidade, dados sobre desemprego, os preços ao consumidor e produtor, nível de salários, taxa de juros, taxa de câmbio, entre outros. Entre os resultados, verificou-se que dentre os modelos testados, o TVP-VAR está frequentemente entre os melhores do estudo para vários horizontes temporais. Especificamente para a inflação, verificou-se que os modelos TVP-VARs, BVARs e FAVAR que utilizaram todas as 20 variáveis, tiveram desempenhos muito bons. Outro achado da pesquisa é que as abordagens utilizadas para combinação de modelos e variação de parâmetros (DMA e DMS) trouxeram benefícios para a previsão das variáveis macroeconômicas do estudo.

Arruda, Ferreira & Castelar (2011) testaram vários modelos de séries temporais e da curva de Phillips na previsão da inflação. Dentre os modelos foram testados um AR(1), um AR com efeito threshold (TAR(1)), modelos VAR e modelos da curva de Phillips. As variáveis escolhidas disponíveis para serem testadas nos modelos foram: o PIB mensal, o IPCA defasado, o repasse cambial (variação cambial mais a inflação

ao produtor americano), a taxa SELIC e o agregado monetário M1. Como resultado, verificou-se que o modelo da curva de Phillips ampliada com efeito threshold, um modelo não-linear, foi o que apresentou o melhor resultado preditivo para o IPCA, corroborando outros estudos sobre a superioridade dos modelos não-lineares.

Mandalinci (2017) comparou e analisou vários modelos para previsão da inflação trimestral de nove países emergentes. Foram diversas variáveis escolhidas. Dentre os modelos multivariados, a depender do modelo, as variáveis utilizadas foram a variação do PIB, a taxa de juros, taxa de câmbio, taxa de desemprego, o crescimento do crédito do setor privado, preço das ações, produção industrial, suprimento monetário, preço do petróleo, preço de commodities agrícolas, entre outros. No tocante aos métodos de previsão, o autor testou modelos univariados como o ARMA e UCSV, bem como os multivariados dos tipos BVAR, TVP-VAR e BVS. No geral, pode-se verificar que o desempenho dos modelos que incorporam mudanças na volatilidade da inflação, em especial o UCSV, foram superiores aos outros. Destacou-se também o TVAR que apresentou desempenho mais estável ao longo do tempo.

Dées & Güntner (2017) utilizaram um modelo PVAR e o compararam com modelos mais tradicionais (AR e VAR) para estimar a inflação de quatro setores da economia – indústria, serviços, construção e agricultura – abrangendo a zona do Euro e suas quatro maiores economias: França, Alemanha, Itália e Espanha. Entre as variáveis foram utilizados o deflator do PIB, o valor agregado real total, os salários, o nível de emprego, a demanda mundial, preços do petróleo, taxa de juros e a taxa de câmbio. O modelo PVAR mostrou bom desempenho comparado a modelos tradicionais univariados, sendo melhor do que modelos VAR quando se considerou a previsão das séries desagregadas pelo PVAR, posteriormente reagregadas.

Garcia, Medeiros & Vasconcelos (2017) trouxeram uma abordagem que se distancia dos métodos econométricos mais populares ao introduzir na análise a aprendizagem de máquina (*machine learning*) por utilizarem *random forest*, que é uma técnica não paramétrica ampliada de árvores de classificação e regressão. Além da *random forest*, os modelos comparados foram o AR, os fatoriais (usando análise de componentes principais), o estimador LASSO (*least absolute shrinkage and selection operator*), o estimador LASSO adaptativo e a regressão completa de subconjuntos (CSR - *complete subset regression*), entre outros. A variável prevista foi o IPCA, havendo 59 variáveis macroeconômicas e 34 variáveis relacionadas às previsões de

especialistas no modelo. Este número grande de variáveis justificou-se devido ao trabalho estar ligado também à questão da redução de dimensionalidade. As variáveis macroeconômicas foram subdivididas em quatro grandes grupos: preços e dinheiro, emprego, taxa de câmbio e finanças e, governo e transações internacionais. Entre os resultados, para horizontes temporais curtos os modelos LASSO e o LASSO adaptativo foram superiores, já para horizontes temporais maiores o modelo dominante foi o CSR. As melhores previsões de inflação, no entanto, vieram da combinação de modelos.

Séries temporais econômicas também são objetos de estudos envolvendo redes neurais. Alguns trabalhos neste sentido abordaram previsão do crescimento econômico e PIB (Feng & Zhang, 2014; Tkacz, 2001), a modelagem da política de taxa de juros (Kukal & Quang, 2011), a previsão da estrutura a termo das taxas de juros (Bose, Sethuraman, & Raipet, 2006), a previsão de taxas de desemprego (Wang & Zheng, 2009), (Sharma & Singh, 2016) e a previsão de taxas de câmbio (Liu, Hou, & Liu, 2017), (Stokes & Abou-Zaid, 2012).

Em linha com esta pesquisa, a literatura abordou a previsão da inflação por redes neurais de variadas formas, e assim como nos modelos anteriores, com variáveis diversas. Encontra-se na literatura também as justificativas para o uso de redes neurais.

Aiken (1999) descreveu que aumentar a precisão de previsão da inflação irá preparar melhor os agentes econômicos para os numerosos componentes interativos e econômicos dependentes da inflação, sendo a técnica da modelagem por redes neurais capaz de aumentar esta precisão. Aiken usou uma rede neural para prever o índice de preços ao consumidor dos EUA (CPI – *Consumer Price Index*) e comparou as previsões do modelo com outros índices usados para previsão da inflação mensal. As variáveis independentes com poder preditivo para o CPI foram as seguintes: o índice de preços ao produtor (PPI – *Producer Price Index*) de materiais brutos, o PPI de materiais intermediários, o PPI de equipamentos de capital, o PPI de bens do consumidor finalizados, o PPI de bens finalizados, o PPI de bens finalizados menos alimentos e energia, a variação nos preços de materiais sensíveis, a variação da base monetária $M1^2$ e a variação da base monetária M2. A conclusão neste estudo foi que

² Para verificar as definições das bases monetárias (M) utilizadas no Estados Unidos, consulte: https://www.federalreserve.gov/faqs/money_12845.htm

a rede previu a inflação com bastante precisão e de forma superior aos outros métodos analisados.

Binner et al. (2004) justificaram a popularidade das redes neurais devido à falha dos modelos lineares em capturar relações não-lineares que permeiam os dados do mundo real. Argumentaram também que a demanda e o interesse por se estimar a inflação é grande, tal como evidenciam os inúmeros artigos existentes e relatórios de bancos centrais. Binner et al. (2004) contrastaram o desempenho de dois modelos não-lineares (um RS-VAR – *Regime Switching VAR* e uma RNN – *Recurrent Neural Network*) contra um modelo linear (VAR) na previsão de inflação mensal do Reino Unido. Os dados eram multivariados e consistiam das seguintes séries temporais independentes: o índice de preços ao consumidor, a base monetária M0 e a produção industrial. Como resultado, os autores mostraram que ambos os modelos não-lineares (RNN e RS-VAR) superaram o modelo linear (VAR) tanto na previsão mensal da inflação quanto para o horizonte de um ano. A RNN e o RS-VAR tiveram desempenhos semelhantes.

Nakamura (2005) descreveu que a investigação de não-linearidades em séries temporais é importante para a teoria macroeconômica como previsão. O autor fez uma comparação entre uma rede neural simples e modelos autorregressivos (AR) para prever a inflação trimestral americana. Os dados independentes eram univariados, advindos da própria inflação, porém defasados. Nakamura exibiu nos resultados que a rede neural errou menos do que os modelos AR nas previsões para um ou dois trimestres.

Choudhary & Haider (2012) descreveram que a razão para a popularidade crescente das redes neurais é por sua habilidade de abarcar não-linearidades e os processos de aprendizagem, ambos os quais podem melhorar o desempenho preditivo de variáveis complexas. Choudhary e Haider (2012) testaram redes neurais univariadas na previsão da inflação mensal de 28 países pertencentes a OCDE (Organização para a Cooperação e Desenvolvimento Econômico). Os resultados das redes neurais foram comparados com o de um modelo autorregressivo de primeira ordem - AR(1). As redes se destacaram consideravelmente contra o modelo AR(1) na previsão da inflação para horizontes de curto prazo (até 3 meses), mas os melhores resultados vieram de uma combinação matemática entre redes.

Terra & Passador (2012) destacaram que as estimativas de inflação têm grande relevância para os gestores, uma vez que decisões de investimento estão vinculadas a elas. O objetivo do estudo foi verificar se modelos de redes neurais são hábeis para prever a inflação em cenários complexos, considerando ainda a realidade de organizações de pequeno porte. Terra & Passador (2012) utilizaram a técnica de redes neurais com dados multivariados para a previsão da inflação brasileira mensal. As variáveis independentes do modelo foram a própria inflação de períodos anteriores, a emissão de moeda, a taxa de juros básica da economia, a taxa de câmbio, os salários médios, o resultado primário do governo e o PIB. Os autores testaram modelos com as variáveis defasadas em um, seis e doze períodos, de maneira a detectar a capacidade de previsão para períodos futuros de até um ano. A conclusão dos autores é que os modelos para previsão com defasagem de 6 a 12 meses não foram capazes de explicar a inflação futura. Dos modelos estudados, o que se julgou mais apropriado, apresentou boa explicação e poderia ser usado com razoável precisão para estimativas de inflação em horizontes temporais de um mês.

Summa & Macrini (2014) utilizaram redes neurais para verificar o impacto de determinadas variáveis na inflação brasileira mensal no período após a implantação do regime de metas de inflação. Vários modelos foram testados utilizando diversas variáveis dependentes e independentes. Como variável dependente testou-se a taxa de inflação e a aceleração da inflação. Entre as variáveis independentes foram utilizadas as seguintes variáveis defasadas: a taxa de inflação, o hiato do produto (como indicador da demanda), a inflação importada (baseada na variação dos índices de preços dos produtos importados e na variação da taxa nominal de câmbio) e a variação da taxa Selic. Uma conclusão importante do artigo foi a verificação de não-linearidade no relacionamento entre as variáveis e a inflação. Também se verificou que a rede neural tem poder explicativo maior do que um modelo linear simples.

Gupta & Kashyap (2015) avaliaram diferentes configurações de dados e redes neurais para previsão de inflação de cada país pertencente ao G-7 (EUA, Reino Unido, França, Alemanha, Itália, Japão e Canadá). Em seus procedimentos estabeleceu-se qual seria o melhor modelo de acordo com o país e que cada modelo poderia ser um *benchmark* para a previsão da inflação para os respectivos executores de política monetária. As séries temporais utilizadas foram os dados mensais de inflação de cada país. Assim sendo, os modelos eram univariados. Segundo os autores, os melhores

modelos escolhidos descreveram bem o comportamento da inflação, além disso, concluíram que a seleção da arquitetura da rede é fator crucial para a precisão na previsão da inflação por redes neurais.

Thakur, Bhattacharyya & Mondal (2016) argumentaram que a previsão da inflação é crucial porque influencia muitas decisões econômicas. Descreveram também que na área de negócios a previsão da inflação é necessária para precificar os bens e planejar a produção adequadamente. Thakur, Bhattacharyya e Mondal (2016) fizeram um estudo para a previsão de inflação mensal da Índia por meio de uma rede neural. A diferença nesta pesquisa é que a previsão de inflação se referia à inflação mensal para o mês do ano seguinte. Os dados utilizados foram multivariados e de periodicidade mensal. Como variáveis explicativas, foram utilizados: o PIB, a taxa de câmbio, as exportações, a base monetária M1, a base monetária M2, as reservas internacionais, as importações, os preços do ouro, os preços do petróleo e a balança comercial. Nos resultados, os autores identificaram que o modelo tem precisão próxima e satisfatória comparada às previsões de agências internacionais conhecidas como da EIU (*Economist Intelligence Unit*), OCDE (Organização para Cooperação e Desenvolvimento Econômico) e FMI (Fundo Monetário Internacional).

O Quadro 1 resume a abordagem de cada autor em seus trabalhos citados anteriormente, referente ao método empregado na previsão da inflação, bem como às variáveis utilizadas:

Autor	Técnica / Modelos Testados	Variáveis Explicativas
Bonno (2014)	SARIMA e Estrutural	IPCA defasado, IBC-BR, IPC dos EUA, expectativas de inflação Focus, taxa de câmbio, taxa de desemprego e taxa SELIC.
Carlo e Marçal (2016)	SARIMA, Estrutural e Markov-switching	O próprio IPCA e suas séries desagregadas.
Caldeira, Moura & Santos (2015)	VAR, TVP-VAR, VAR bayesiano, FAVAR e outros	PIB, produção industrial, utilização da capacidade, (des)emprego, preços ao consumidor e produtor, salários, taxa de juros, taxa de câmbio e outras.
Arruda, Ferreira & Castelar (2011)	AR, TAR, VAR e curva de Phillips	PIB, IPCA defasado, repasse cambial, taxa SELIC e M1

Mandalinci (2017)	ARMA, UCSV, BVAR, TVP-VAR e BVS	Inflação defasada, PIB, produção industrial, taxa de juros, taxa de câmbio, taxa de desemprego, crescimento do crédito do setor privado, preço das ações, suprimento monetário, petróleo, commodities agrícolas, entre outros.
Dées & Güntner (2017)	PVAR, VAR e AR	Deflator do PIB, valor agregado, salários, emprego, demanda mundial, petróleo, taxa de juros e taxa de câmbio.
Garcia, Medeiros & Vasconcelos (2017)	<i>Random forest (machine learning)</i> , LASSO, AR, análise fatorial, <i>subset regression</i>	IPCA, taxa de desemprego, taxa de câmbio, meta SELIC e mais 55 variáveis macroeconômicas, além de 34 variáveis ligadas às previsões dos especialistas.
Aiken (1999)	Rede neural	Índice de preços ao produtor (PPI – Producer Price Index) de materiais brutos, PPI de materiais intermediários, PPI de equipamentos de capital, PPI de bens do consumidor finalizados, PPI de bens finalizados, PPI de bens finalizados menos alimentos e energia, variação nos preços de materiais sensíveis, a variação da base monetária M1 e a variação da base monetária M2.
Binner et al. (2004)	Rede neural, RS-VAR e VAR	IPC do Reino Unido, base monetária M0 e a produção industrial.
Nakamura (2005)	Rede neural e modelos AR	Inflação americana defasada.
Choudhary & Haider (2012)	Redes neurais e AR(1)	Inflação defasada de países da OCDE.
Terra & Passador (2012)	Redes neurais	IGP-DI defasado, a emissão de moeda, a taxa de juros, a taxa de câmbio, os salários médios, o resultado primário do governo e o PIB.
Summa & Macrini (2014)	Redes neurais	IPCA defasado, o hiato do produto (entre produção industrial e produto potencial), inflação importada (índice de preços de produtos importados e taxa de câmbio) e variação da taxa SELIC.

Gupta & Kashyap (2015)	Redes neurais	Inflação defasada de países do G-7.
Thakur, Bhattacharyya & Mondal (2016)	Rede neural	PIB, taxa de câmbio, exportações, base monetária M1, base monetária M2, reservas internacionais, importações, cotação do ouro, cotação do petróleo e a balança comercial.

Quadro 1: Quadro-resumo de modelos e variáveis

Conforme se observou, embora as variáveis empregadas para explicar a inflação futura possam variar na literatura, há um conjunto de variáveis comuns. Para a presente pesquisa, as variáveis explicativas básicas inicialmente escolhidas para a seleção de atributos foram: a inflação defasada, variação da taxa de juros, variação cambial, variação da demanda (ou da atividade econômica) e variação dos preços das *commodities*. A razão para a escolha destas variáveis deveu-se por serem tradicionais e comuns na literatura. A elas acrescentou-se ainda a inflação ao produtor amplo. A premissa de se incluir esta variável na previsão da inflação ao consumidor é que ela poderia representar uma *proxy* da inflação futura medida pelo IPCA, uma vez que esta seria afetada em tempo posterior. Segundo Aiken (1999), a teoria sugere que os preços ao produtor guiam os preços ao consumidor, e, por conta disso, índices de inflação ao produtor deveriam ser incluídos como preditivos da inflação ao consumidor.

Nas subseções abaixo estas variáveis são detalhadas.

2.2.1. Inflação

Martinez e Cerqueira (2013) definem a inflação como sendo um agregado macroeconômico para indicar o efeito médio sobre a economia de um fenômeno complexo que é o aumento de preços dos diversos bens que a compõem. A inflação é a presença na economia do aumento geral de preços de bens e serviços, e não apenas de produtos isolados específicos.

Para se definir o termo “geral” de aumento de preços, precisa-se estabelecer quais produtos são alvos da mensuração de preços para que se calcule a inflação. Estes produtos precisam refletir com a maior precisão possível a cesta de produtos que melhor representa os objetivos atribuídos a determinado índice. Para isto diversos índices de inflação foram concebidos ao longo da história brasileira.

2.2.1.1. IPCA

Para esta pesquisa, o intervalo de interesse inflacionário parte no mínimo do início da adoção ao regime de metas de inflação pelo Brasil, uma vez que, anteriormente, o ambiente econômico estruturalmente era outro e os fatores influenciadores da inflação eram provavelmente diversos dos atuais.

O sistema de metas de inflação foi implementado no Brasil com a edição do Decreto nº 3.088 pelo Presidente da República, em 21 de junho de 1999. As metas de inflação integram um regime monetário no qual o Banco Central do Brasil se compromete a atuar para que a inflação fique dentro dos parâmetros estabelecidos como meta, e divulgados publicamente (Banco Central do Brasil, 2017).

O índice de inflação considerado para as metas de inflação, que é o índice oficial adotado pelo governo federal como o índice da inflação brasileira, é o IPCA (Índice Nacional de Preços ao Consumidor Amplo), calculado e divulgado mensalmente pelo IBGE (Instituto Brasileiro de Geografia e Estatística). O índice tem como unidade de coleta estabelecimentos comerciais e de prestação de serviços, concessionária de serviços públicos e domicílios. O período de coleta do IPCA em geral é do dia 01 a 30 do mês de referência. O alvo da pesquisa para o índice são as famílias com rendimentos mensais compreendidos entre 1 e 40 salários-mínimos, e residentes nas áreas urbanas das regiões. A pesquisa foi iniciada em 1979. (IBGE, 2017).

O IPCA foi o índice escolhido para ser a variável representativa da inflação por duas razões principais: 1) as empresas são sensivelmente afetadas e têm interesse nas divulgações, previsões e estratégias do governo quando se refere ao controle da inflação, uma vez que é com base no IPCA que o governo atuará de modo a perseguir as metas de inflação estabelecidas, interferindo, por exemplo, nas taxas de juros e de câmbio; 2) é o índice de inflação oficial no país, uma vez que traduz o impacto da demanda média geral nos setores de consumos mais importantes para a população.

O IPCA em específico também está ligado às empresas do mercado financeiro uma vez que é um indicador que interfere na análise, concessão e obtenção de empréstimos, sendo ele parte integrante de outros produtos e serviços. Neste quesito, o IPCA é um fator de risco para bancos e financeiras emissoras de títulos, bem como para o Tesouro Nacional, haja vista que a emissão de títulos públicos e privados

atrelados ao IPCA fazem com que o passivo formado perante os investidores dependa das oscilações deste índice.

Ainda com relação à relevância específica do IPCA para as empresas, há evidências sugerindo que este índice é um fator explicativo para: o nível de disponibilidades e caixa das empresas (Costa, Schmitt, Leite Filho, & Silva, 2011), a falência (Mario & Carvalho, 2007), o desempenho econômico-financeiro (Pandini, Stüpp, & Fabre, 2017), o valor de mercado (Carvalho, Roma, Araujo, & Oliveira, 2013), e o nível de endividamento de instituições financeiras (Vieira, Arruda, & Tavares, 2016)

2.2.1.2. IPA

O IPA (IBRE/FGV) inicialmente se chamava Índice de Preços por Atacado e a partir de 2010 passou a se chamar Índice de Preços ao Produtor Amplo. O IPA registra variações de preços de produtos agropecuários e industriais nos estágios de comercialização anteriores ao consumo final (Instituto Brasileiro de Economia, 2017). A inclusão do IPA como variável independente deveu-se por esta questão temporal. Desta forma, é de se esperar que IPA e IPCA tenham algum grau de associação (Habe, 2009). Além disso, Aiken (1999) diz que a previsão da inflação ao consumidor deveria incluir a inflação ao produtor como fator preditivo.

2.2.2. Variação da Taxa de Juros

A taxa de juros básica da economia, conhecida como taxa Selic é a taxa média ajustada dos financiamentos diários apurados no Sistema Especial de Liquidação e de Custódio (Selic) para títulos federais (Banco Central do Brasil, 2017). Considerando o regime de metas de inflação, a determinação da taxa Selic - meta, pelas reuniões do Copom, é a principal ferramenta de política monetária da qual dispõe o Banco Central para controlar a aceleração da inflação (Summa R. , 2011). Desta maneira, o Banco Central toma decisões em relação à taxa de juros (subir, baixar ou manter) com o objetivo de interferir diretamente na inflação futura.

2.2.3. Variação Cambial

O tipo de taxa de câmbio no Brasil é definido como o valor em unidades monetárias em Reais para uma unidade de uma moeda estrangeira (R\$/US\$). Considerando o Dólar como a moeda internacional, a pesquisa utilizará a variação da taxa de câmbio do Dólar Americano como uma das variáveis independentes sujeita à seleção de atributos. A utilização desta variável é importante porque ela afeta o preço de insumos utilizados na produção de produtos nacionais. Além disso, interfere no patamar de importação e exportação do país, o que pode trazer consequências para a inflação. Uma elevação na taxa de câmbio desestimularia a importação e favoreceria as exportações, elevando a demanda agregada e por consequência podendo a vir pressionar os preços internos.

Martinez e Cerqueira (2013) explicam que a variação cambial interfere na inflação através dos custos de produção, dos preços dos bens finais importados e dos preços dos bens comercializáveis.

2.2.4. Variação da Demanda

Por questão de facilidade, para a variável representativa das pressões de demanda, não será utilizado os dados do PIB do IBGE por serem dados trimestrais. Ao invés disso, será utilizada a série PIB-Mensal, também do Banco Central, representando assim a demanda ou variações na demanda, conforme os ciclos econômicos.

2.2.5. Variação dos Preços das *Commodities*

A variação nos preços das *commodities*, precificadas em bolsas, afeta diretamente o preço destas mercadorias transacionadas no país ou de produtos que integrem suas composições. O Índice de Preços das *Commodities* (IC-Br) do Banco Central do Brasil servirá como variável para este fator explicativo. Conforme conceituado pelo Banco Central, o índice exprime a média mensal ponderada dos preços em reais das commodities relevantes para a dinâmica da inflação brasileira. O IC-Br agrega de forma ponderada os indicadores relativos aos segmentos agropecuário, metal e energia (Banco Central do Brasil, 2017). Ainda conforme Martinez e Cerqueira (2013, p. 428), a variação dos preços das *commodities* impacta

a “[...] inflação via mudança nos preços relativos. Esta variável pode ser também um *proxy* para medir o efeito do (des)aquecimento da econômica mundial nos preços domésticos [...]”.

2.3. ECONOMIA COMPORTAMENTAL

A economia comportamental é um ramo da economia que se contrapõe à explicação econômica de que as pessoas são completamente e sempre racionais e maximizadoras de suas utilidades. Até o surgimento da economia comportamental as teorias econômicas estavam baseadas em uma abstração do ser humano para explicar o comportamento econômico chamado de *homo economicus* (homem econômico). As teorias baseadas no *homo economicus* pressupõem que os atores econômicos tenham características como a racionalidade e interesse pessoal atemporal e universal e todas as informações disponíveis para tomar decisões. Mullainathan & Thaler (2000, p. 3) descrevem que “A economia tradicionalmente conceitua um mundo povoado por maximizadores calculistas e não emocionais[...]” e que a economia neoclássica de certa forma acabou por se definir como “anti-comportamental”. Thaler (2016) também resume as premissas do *homo economicus*, observando que os agentes têm preferências bem definidas, expectativas não enviesadas, fazem escolhas ótimas, têm habilidades cognitivas infinitas, força de vontade infinita, e sua motivação maior é o auto-interesse.

No entanto, ao assumir esta simplificação do ser humano, a economia acaba por desconsiderar características humanas que podem ter papel fundamental no entendimento das preferências e tendências do comportamento econômico. O modelo do *homo economicus* considera que o comportamento humano é formado por pelo menos três características que não condizem com a realidade: racionalidade ilimitada, força de vontade ilimitada e egoísmo ilimitado (Mullainathan & Thaler, 2000). Por isso, Camerer & Loewenstein (2003) observam que, ao fornecer fundamentos psicológicos mais realistas, a economia comportamental melhora o poder explicativo do comportamento econômico. As pessoas não seriam racionais totalmente e a todo momento. Assim, junto com a economia comportamental vem a suposição da racionalidade limitada (Simon, 1957). Os agentes econômicos na realidade têm percepções limitadas, erram sistematicamente, não são capazes necessariamente de maximizar sua utilidade e suas expectativas racionais são limitadas (Mikolajek-

Gocejna, 2014). Embora haja inúmeros atributos que descrevem os pressupostos da economia comportamental, não é o escopo deste estudo explorar estes aspectos. Desta forma, passa-se a dar mais foco na última característica elencada: as expectativas.

2.4. EXPECTATIVAS E COMPORTAMENTO

Além das variáveis econômicas usuais em previsões de séries macroeconômicas, procura-se também verificar a relevância das expectativas do consumidor e seu subsequente comportamento e de que forma podem impactar a economia, mas mais especificamente se impactariam a inflação diretamente ou alguma variável que poderia trazer reflexos na inflação.

As expectativas em geral podem ser determinantes sobre a demanda e oferta de bens no mercado. Conforme Frank (2013), as expectativas sobre a renda e os preços futuros dos produtos afetam decisões de compra. As pessoas acabam comprando mais hoje, se existe a expectativa de alta no preço de um produto num futuro próximo. Ainda segundo Frank (2013), a oferta também pode ser determinada parcialmente pelas expectativas, quando por exemplo, fornecedores observam as expectativas de mudanças de preço futuras, mas tomam decisões a respeito da produção hoje, alterando assim a oferta de bens no mercado. As expectativas têm papel peculiar na economia uma vez que dão origem a variáveis não observáveis que podem vir a dar causa a fenômenos econômicos observáveis (Mikolajek-Gocejna, 2014).

Uma das primeiras menções referente às expectativas na macroeconomia surgiu com Irving Fisher (Fisher, 1930), quando formulou a equação que descreve a inflação como a diferença entre a taxa de juros real e nominal. De modo sucinto, o efeito de Fisher diz que a taxa de juros real é determinada pela diferença entre a taxa de juros nominal e a inflação esperada. Assim, por exemplo, ao aplicar recursos sob o rendimento de determinada taxa de juros nominal hoje, o rendimento real da aplicação no futuro somente será positivo se a inflação esperada de hoje até o resgate for inferior à taxa de juros nominal contratada. Por isso, pode ocorrer a chamada substituição intertemporal, que é a resposta através do consumo, dada uma alteração na taxa de juros real. Se a taxa de juros real esperada for baixa, devido a uma inflação futura esperada alta, então haveria um estímulo ao consumo no presente, uma vez

que aplicações financeiras poderiam se tornar menos atrativas. Segundo D'Acunto, Hoang & Weber (2015, p. 9):

Os proponentes das expectativas temporárias de inflação mais alta tipicamente argumentam que expectativas de inflação mais alta levam a taxas de juros mais baixas (efeito da equação de Fisher). Taxas de juros mais baixas estimulam o consumo através da substituição intertemporal [...]

A importância das expectativas também aparece um pouco mais tarde com Keynes (Keynes, 1936), o qual destaca a relevância das expectativas e seus efeitos sobre os investimentos. Conforme Mikolajek-Gocejna (2014), a adição das expectativas às análises macroeconômicas, entretanto, foram falhas na teoria de Keynes, pois não eram coerentes com fundamentos microeconômicos, nível no qual as expectativas são formadas. Logo, ao longo do século passado, desenvolveram-se duas hipóteses principais para teorizar o funcionamento das expectativas na economia: a hipótese das expectativas adaptativas e a hipótese das expectativas racionais.

A hipótese das expectativas adaptativas, defendida por Friedman (1968), pode ser resumida da seguinte forma: os agentes formam suas expectativas após os fatos, são passivos, não são capazes de se antecipar a movimentos da economia e as expectativas de preços futuros dependem das expectativas de preços hoje e dos erros de previsão anteriores (Mikolajek-Gocejna, 2014). Assim, a teoria das expectativas adaptativas dá importância aos eventos passados na formação de expectativas futuras. Uma situação típica que ilustra esta hipótese é em relação à inflação. Segundo esta teoria, se a inflação subiu em determinado ano, as pessoas esperariam que a inflação continuasse a subir no ano seguinte, ou seja, as “Expectativas adaptativas dependem apenas de observações passadas [...]” (Brayton, Mauskopf, Reifschneider, Tinsley, & Williams, 1997, p. 228) . Se a expectativa não se concretiza, as pessoas então adaptam suas expectativas apenas quando os novos dados são conhecidos.

Na década de 70, eventos como a crise do petróleo nos EUA mostraram que a teoria das expectativas adaptativas era falha, pois não teria conseguido prevê-la. A partir disso se desenvolveu a hipótese das expectativas racionais (Muth, 1961), defendida mais acentuadamente por Robert Lucas Jr (Lucas, 1972), que sugere basicamente que os indivíduos não são apenas seres passivos, mas sim racionais e capazes de se antecipar às decisões de um banco central, por exemplo. Conforme descreve Mikolajek-Gocejna (2014) sobre a conceituação desta hipótese, um

indivíduo formaria suas expectativas e previsões sobre o futuro usando todas as informações possíveis e seu conhecimento econômico. Os agentes inclusive agiriam como se soubessem o modelo de previsão das variáveis, de modo que erros nas expectativas seriam aleatórios e não sistemáticos, isto é, as pessoas aprenderiam com seus erros. Assim, os erros das expectativas totais, em média, seria zero e as expectativas como um todo teriam seu valor preditivo correto. As “expectativas racionais são idênticas às previsões produzidas pelo modelo macroeconômico no qual as expectativas são usadas [...]” (Brayton, Mauskopf, Reifschneider, Tinsley, & Williams, 1997, p. 228). Mais recentemente, Thaler (2016, p. 1593) lembrou a premissa das expectativas racionais: “O pressuposto das expectativas racionais torna explícita a ideia [...] de que os agentes atuam como se conhecessem o modelo (e o estado da arte das técnicas econométricas também).”

Considerando o mundo incerto, dinâmico e de informações assimétricas em que vivemos, a hipótese das expectativas racionais sofreu pesadas críticas. Mikolajek-Gocejna (2014) observa que dada nossa situação, com a economia dinâmica e as diferentes situações de informação, a previsibilidade uniforme é algo a se questionar. Uma vez que os agentes têm acesso a diferentes níveis de informação e nenhum deles tem acesso a toda ela, as expectativas seriam formadas com base em critérios diferentes conforme o agente, ou seja, de forma mais particular fazendo com que a distribuição das expectativas seja na verdade heterogênea e enviesada. Portanto, a racionalidade na formação das expectativas teria um aspecto de racionalidade limitada. Este tipo de racionalidade é reforçada quando se considera que: 1) as pessoas não conhecem todas as decisões possíveis, não conhecendo necessariamente a decisão ótima e por consequência não maximizando sua utilidade (Simon, 1957) e; 2) ao tomarem decisões as pessoas cometem erros sistemáticos baseados em algum tipo de heurística (Tversky & Kahneman, 1974), não recorrendo à análise técnica e completa da situação, não avaliando, por exemplo, todas as probabilidades.

Citando pesquisas sobre expectativas de tendência futura dos preços dos imóveis e do comportamento do índice acionário S&P 500, Thaler (2016) observa que há violações nas expectativas racionais. Os testes empíricos sobre expectativas não confirmam a presença da suposta racionalidade advinda da hipótese das expectativas

racionais. O autor avalia que em várias situações as expectativas acabam por se basear muito na extrapolação futura das tendências mais recentes.

Conforme conclui Mikolajek-Gocejna (2014, p. 45),

[...] expectativas não são formadas racionalmente. Lacunas na informação e percepção bem como o uso de simplificações indubitavelmente afetam o processo de formação das expectativas, as quais por natureza não são as mesmas para todos os agentes do mercado devido a diferenças na experiência e conhecimento dos processos econômicos [...]

As expectativas de inflação dos consumidores, as expectativas de renda e o nível de satisfação com a vida são variáveis com consequências comportamentais, no sentido de serem uma expressão do indivíduo (e não um dado econômico como a cotação do Dólar por exemplo), e gerar comportamentos e previsões condizentes com sua expressão (baseado na teoria e dados empíricos). Dentro deste quesito, a expectativa de inflação é a principal variável externa explorada neste trabalho. Porém, a fim de deixar a presente pesquisa também com uma característica exploratória (além da seleção de atributos), pretende-se verificar ainda os efeitos das expectativas de renda e nível de satisfação com a vida, conforme explicitado mais adiante.

2.4.1. Inflação inercial

Segundo a visão keynesiana, a inflação de curto prazo de modo geral se deve a três fatores: 1) ao excesso de demanda sem que a capacidade produtiva possa acompanhar; 2) ao abalo nos custos dos produtos, o que pode impactar na oferta dos mesmos, seja por escassez/desastres naturais ou apenas aumento nos preços dos insumos e; 3) à inércia inflacionária, sendo um componente de realimentação do processo.

A inflação inercial está ligada à antecipação inflacionária na qual a pura expectativa de persistência da inflação interfere nas ações das empresas hoje. De modo a se antecipar à inflação, as empresas podem, por exemplo, reajustar seus preços simplesmente pela expectativa de que os preços continuarão subindo.

Conforme visto anteriormente, a inflação defasada é uma variável bastante comum em trabalhos de previsão de inflação. Considerando que a taxa do IPCA será o índice representativo da inflação e a variável dependente a ser prevista acumuladamente para os 12 meses seguintes, ela também poderá ser uma variável independente, se for identificada como relevante na etapa de seleção de atributos. A

utilização do IPCA como variável independente serve para capturar o impacto da inflação passada na inflação atual (Summa R., 2011; Bresser-Pereira & Nakano, 1984). Assim, o modelo proposto neste trabalho será capaz de capturar a inércia inflacionária, se ela existir.

Summa R. (2011) conclui que as evidências apontam fortemente que a inflação inercial brasileira existe e é parcial e não total, no sentido em que apenas parte da inflação atual é repassada à inflação futura.

Alencar (2006) testou um modelo ARIMA, e como resultado encontrou a presença da inércia parcial, ressaltando que 67% da magnitude da inflação passada mensal aparece na inflação presente. Efeitos semelhantes apareceram no mesmo trabalho nos modelos ARCH, EGARCH e na curva de Phillips testada. Alencar (2006) testou também um modelo VAR de onde concluiu que a inércia inflacionária brasileira existe e persiste por até três meses aproximadamente.

2.4.2. Expectativas de inflação

Para Bernanke (2007), o ex-presidente do FED, o banco central norte-americano, as expectativas de inflação influenciam grandemente a inflação real e consequentemente a habilidade de um banco central para alcançar a estabilidade de preços. No entanto, a aparente relação entre expectativas de inflação e a inflação futura realizada ou o nível de consumo não parece ser claro e unânime quando se analisam as evidências empíricas sobre o tema, conforme as referências a seguir.

Lima & Céspedes (2003) analisaram se as expectativas do mercado, captadas pelo Banco Central (Focus) tem bom poder explicativo para a previsão de inflação e compararam estas expectativas com as previsões geradas por modelos lineares univariados, como o ARIMA. Como resultado, encontraram que as previsões segundo as expectativas do mercado não tiveram grau de precisão razoável e também não superaram os modelos lineares em capacidade preditiva considerando previsões acima de três meses. Posteriormente, Lima & Alves (2011) reanalisaram com dados mais recentes a habilidade preditiva do mercado comparado aos modelos lineares. As conclusões foram similares ao estudo anterior, dando conta que não há evidência significativa de que as expectativas do mercado sejam superiores às previsões dos modelos lineares univariados.

Ang, Bekaert & Wei (2007) investigaram o poder preditivo das expectativas da inflação americana mediante consulta a especialistas e consumidores, em relação a outros métodos puramente econômicos e econométricos. O principal resultado do estudo foi que as pesquisas de expectativa conseguiram prever a inflação melhor do que todos os outros métodos, com o destaque ainda de que uma combinação de previsões (entre pesquisas e métodos) em geral não melhora o poder preditivo para a inflação. Para os autores, algumas explicações possíveis para o melhor desempenho das pesquisas sobre inflação são: 1) as pesquisas mostram opiniões formadas a partir de várias fontes, e por consequência não capturadas pelos modelos matemáticos; 2) os modelos não utilizam a informação sobre as expectativas dos consumidores e especialistas e; 3) a previsão pelas pesquisas reagiu mais rapidamente a mudanças no ambiente macroeconômico no período utilizado no estudo.

Mestre (2007), em um artigo publicado pelo Banco Central Europeu, analisou, entre outros fatos, se as expectativas da inflação europeia, colhidas junto a profissionais e consumidores, trazem alguma informação preditiva para a inflação futura. De maneira geral, a conclusão é que sim, as pesquisas sobre expectativas possuem informações úteis a respeito da previsão inflacionária. Embora as expectativas dos profissionais tenham maior precisão em relação às dos consumidores, estas não podem ser negligenciadas.

Summa R. (2011) fez um apanhado de estudos no qual analisou, entre outros tópicos, as características da inflação inercial e o papel das expectativas nos modelos empíricos. Entre as conclusões o autor ressalta que “[...] as expectativas inflacionárias não se descolam da inflação passada, e portanto, é melhor estimar a curva de Phillips incluindo apenas a inflação passada, sem incluir explicitamente as expectativas [...]”.

Gil-Alana, Moreno & De Gracia (2012) mostraram que as expectativas de inflação baseadas em pesquisas a profissionais do mercado conseguiram prever a inflação trimestral americana melhor do que modelos econométricos tradicionais, além de se mostrarem úteis para prever alterações na inflação futura. Por quê as previsões medidas por estas expectativas foram melhores do que as dos modelos é uma questão crucial, para a qual, os autores descreveram não haver resposta conclusiva na literatura até então. Algumas explicações para o bom desempenho da previsão mediante a pesquisa de expectativas foram aventadas, tais como: o fato de os profissionais agregarem informações diversas e heterogêneas ao conjunto das

expectativas; a rapidez e precisão da reação das expectativas conforme o ambiente macroeconômico e a correta revisão das expectativas depois de mudanças na política monetária.

Burke & Ozdagli (2013) questionaram o papel das expectativas inflacionárias sobre os gastos de consumidores americanos. Mais especificamente os autores verificaram a relação entre as expectativas de inflação e os gastos, levando em conta outras variáveis como expectativas de aumento salarial, as condições do ambiente macroeconômico, e as incertezas a respeito das expectativas inflacionárias. Entre os achados mais relevantes, verificou-se não haver evidências de que um aumento nas expectativas de inflação provoque um aumento no consumo de eletrônicos e eletrodomésticos, havendo um efeito de fato sobre a probabilidade de compra de automóvel quando sobem suas expectativas inflacionárias de curto prazo.

Posteriormente, Bachmann, Berg, & Sims (2015) também verificaram esta mesma questão: se expectativas inflacionárias mais altas teriam efeitos positivos sobre os gastos dos consumidores americanos. Os resultados encontrados seguem no mesmo sentido, de que o impacto de altas expectativas de inflação produz um efeito pequeno e estatisticamente insignificante na propensão ao consumo de bens duráveis.

Considerando a relação entre expectativas de inflação e o nível de consumo ou poupança, o qual pode impactar na dinâmica inflacionária, cabe citar a conclusão de Khumalo (2014), para o caso da África do Sul. Khumalo (2014) destaca que variações nas poupanças das famílias – e consequentemente em seus gastos – devem-se em grande parte a mudanças em suas expectativas de inflação e que esta variável é uma ferramenta mais confiável para se prever o nível de poupança das famílias do que a própria inflação. Isto é, as expectativas inflacionárias teriam algum grau preditivo para o consumo das famílias.

D'Acunto, Hoang & Weber (2015) verificaram com base em dados da população alemã, que nos domicílios nos quais havia uma expectativa de alta da inflação, havia também uma probabilidade 8% maior em intenções de compra de bens duráveis do que nas famílias que esperavam um declínio ou manutenção dos níveis de inflação.

Usando dados da população japonesa, Ichiue & Nishiguchi (2015) exibiram evidências a respeito da relação existente, para os indivíduos pesquisados, entre suas expectativas de alta na inflação e suas propensões a gastar.

Grothe & Meyler (2015), em outro artigo publicado pelo Banco Central Europeu, testaram o desempenho preditivo das expectativas de inflação obtidas junto a especialistas do mercado e as obtidas através de pesquisa junto aos consumidores. O principal achado do estudo é de que tanto as expectativas dos especialistas quanto as dos consumidores possuíam informação preditiva da dinâmica futura da inflação europeia, e além disso superaram o desempenho de métodos estatísticos para a previsão da inflação.

Também neste sentido, Duca, Kenny & Reuter (2016) pesquisaram para a zona do Euro, a relação existente entre as expectativas de inflação do consumidor e seus gastos. Eles descreveram que as expectativas de inflação para um determinado período estão associadas a uma maior probabilidade de consumo nesse período.

Gaglianone, Issler & Matos (2017) fizeram um estudo avaliando a previsão da inflação brasileira com base em expectativas. Dados de expectativas quanto à inflação futura foram obtidos tanto junto aos consumidores quanto ao mercado através de especialistas do mercado financeiro. As expectativas dos consumidores foram obtidas através da pesquisa do Instituto Brasileiro de Economia (IBRE) da FGV, já as opiniões de especialistas vieram através do relatório Focus do Banco Central do Brasil. Neste trabalho, os autores estudaram a combinação de previsões de especialistas e consumidores e verificaram que esta é uma estratégia útil para ajudar a prever a inflação no Brasil.

Por fim, neste trabalho optou-se por testar o efeito da expectativa inflacionária no relacionamento com a inflação, vis-à-vis os pressupostos da racionalidade das expectativas e a lógica teórica nas atitudes do consumidor (efeito de Fisher e substituição intertemporal). Outra razão adicional para a inclusão desta variável é por ter se verificado empiricamente nos trabalhos referenciados resultados conflitantes sobre a relação entre as expectativas de inflação e seu grau preditivo para a inflação futura e, sobre a relação entre as expectativas de inflação e sua interferência no nível de consumo, gastos e poupança – o que poderia vir a impactar os níveis de inflação futuros. Para o cenário brasileiro foi utilizada a pesquisa de expectativas de inflação do consumidor apurada mensalmente pelo IBRE da FGV.

2.4.3. Expectativas de renda

Com um aspecto também exploratório, verificou-se também se poderiam existir efeitos produzidos pelas expectativas de renda na inflação. Apesar da maior dificuldade de encontrar dados relativos a expectativas salariais ou de renda, este componente também pode estar ligado ao nível de consumo das famílias, no entanto as evidências de como isto acontece parecem não estar muito claras ainda, conforme se verá na sequência.

Frank (2013) descreve que pessoas que tenham a expectativa de renda maior, diminuem a necessidade de poupança, gastando mais em relação a pessoas cuja expectativa de renda é menor. Este aspecto teórico possivelmente é válido isoladamente para o caso em que se espera inflação constante, pois considerando a interação entre a expectativa salarial e de inflação, as expectativas de renda teoricamente teriam efeitos diversos sobre o consumo. Conforme observaram Ito & Kaihatsu (2016), altas expectativas de inflação indicam expectativas salariais reais mais baixas, pressupondo a manutenção dos salários nominais. Isso traria reflexos no presente através da redução do consumo por conta do efeito de redução dos salários reais esperados. Ito & Kaihatsu (2016) analisaram dados de consumidores japoneses verificando não apenas as expectativas de inflação, mas também expectativas de salário e o subsequente nível de consumo, e como as expectativas salariais se relacionam com as expectativas inflacionárias. A principal conclusão foi de que a subida das expectativas de inflação estimulou os gastos dos consumidores mesmo tendo havido um período de declínio nas expectativas salariais. Assim, a alta das expectativas de inflação dominou as expectativas salariais, refletindo-se nos gastos conforme conclusão da pesquisa.

Stephens Jr (2004) fez um estudo sobre as expectativas de perda de emprego, os eventos posteriores reais em que ocorre a perda de emprego e o impacto no consumo/poupança das famílias quando as expectativas eram formadas. Stephens Jr (2004) descreve que quanto mais uma família acredita na perda do emprego, menos impactante deveria ser sua alteração no consumo quando este evento vier a se realizar, tendo em vista que com base em sua forte expectativa, seria esperado que o nível de consumo já tivesse se ajustado. Uma das conclusões do trabalho foi a correlação verificada entre as expectativas de desemprego e as perdas de emprego subsequentes, mostrando que as expectativas de desemprego têm um poder preditivo

muito útil para as perdas de emprego futuras. No entanto, surpreendentemente, as famílias parecem não saber usar as expectativas, uma vez que não as levam em conta na hora de consumir ou poupar, pois a outra conclusão do estudo é de que não há relação entre suas expectativas de desemprego e o seu nível de consumo uma vez formadas as expectativas.

De Bruin et. al (2010) destacaram que as expectativas de salário têm impactos sobre as decisões dos consumidores no que se refere a consumo e lazer e, por isso, são informações valiosas para a compreensão e previsão do comportamento econômico. Além disso, descreveram que as dinâmicas salariais são variáveis determinantes para a inflação esperada e a atual, uma vez que a determinação dos preços pelas empresas é também função de seus custos totais com mão-de-obra.

Conforme também observou Potter (2011), as expectativas salariais são dados adicionais para se analisar as dinâmicas inflacionárias, considerando que trabalhadores e empresas negociam alterações salariais pautadas em suas expectativas de inflação.

Arent (2012) analisou as expectativas de renda e seus impactos nos hábitos de poupança das famílias alemãs. Além disso, avaliou também o impacto das expectativas de desemprego sobre a poupança. Arent (2012) parte de uma hipótese muito similar à de Ito & Kaihatsu (2016), descrito anteriormente, porém orientado em outra direção, isto é, a hipótese de que expectativas de salários futuros mais baixos deveriam aumentar as atitudes de poupar das famílias. Entre os resultados encontrados, constatou-se que para a parte ocidental da Alemanha, a expectativa de renda mais baixa – medida pela expectativa de renda individual – aumentou de modo geral a taxa de poupança. Este efeito, no entanto, não pode ser verificado para as expectativas de desemprego. Nesta condição, um aumento nas expectativas de desemprego, o que também deveria estar vinculado a uma expectativa de redução na renda, na realidade reduziu a poupança, tanto na parte ocidental da Alemanha quanto na oriental, o que contraria o modelo teórico da hipótese mencionada.

Assim, considerando as dinâmicas de determinação dos preços e ofertas dos bens produzidos e sua relação com o nível de salários pagos, bem como os resultados empíricos diversos sobre as relações entre decisões de consumo e poupança e as expectativas de renda e desemprego e, a interação teórica entre expectativas de renda e de inflação, optou-se por testar o efeito da inclusão desta variável no modelo

e verificar melhor se há alguma relação das expectativas de renda com a inflação brasileira.

Para o caso brasileiro, porém, há uma dificuldade de se obter dados prontos de longo prazo mensais – a periodicidade escolhida para o presente trabalho. O Índice de Expectativa de Renda Pessoal que integra o Índice Nacional de Expectativa do Consumidor (INEC) da CNI foi escolhido para representar as expectativas de renda. Este índice era trimestral e passou a ser mensal apenas partir de 2010. Desta forma, optou-se por interpolar linearmente estes dados para os meses em que não houvesse dados disponíveis³.

2.4.4. Felicidade e satisfação com a vida

Um questionamento que pode se fazer é se o bem-estar de uma pessoa ou seu estado de humor, traduzido através de seu grau de felicidade e satisfação com a vida poderia fazê-la gastar, consumir produtos ou poupar em níveis diferentes de outros estados de felicidade e satisfação. Ou ainda primeiramente, poderia se questionar se existe alguma relação entre a felicidade ou satisfação com a vida e variáveis macroeconômicas. Esta relação com a inflação especificamente, é outra proposta exploratória para o presente trabalho, ou seja, testar esta variável e verificar se ela produz efeito relevante para a dinâmica da inflação.

A relação de variáveis como a felicidade, satisfação com a vida e bem-estar com agregados macroeconômicos já foi verificada empiricamente. Cabe citar estudos tanto no Brasil quanto no exterior que mostram correlações significativas destas variáveis com a inflação, desemprego, crescimento econômico, taxa de juros, renda e PIB per capita (Welsch, 2007), (Di Tella, MacCulloch, & Oswald, 2001), (2003), (Corbi & Menezes-Filho, 2006), (Ribeiro & Marinho, 2017), (Babula & Mrzyglod, 2013). Há inclusive evidências empíricas em estudos de panorama global sobre a existência da relação entre satisfação com a vida e o PIB per capita dos países (Deaton, 2008), (Babula & Mrzyglod, 2013), (Di Tella, MacCulloch, & Oswald, 2003).

Frey & Stutzer (2002) trouxeram um debate sobre os impactos da felicidade e seu papel para a economia e sua relação com o conceito econômico da utilidade.

³ Tentou-se obter os dados mensais do Índice de Expectativa de Renda Pessoal da CNI ou dados para reconstruí-lo na periodicidade mensal. No entanto, em resposta a este autor, a CNI informou que dados mensais, para o intervalo no qual a pesquisa era realizada trimestralmente, não existem, portanto apenas na forma trimestral.

Embora a ideia de o comportamento econômico estar geralmente mais ligado a uma causa macroeconômica – por exemplo o efeito da inflação, desemprego e renda no comportamento dos consumidores – o efeito inverso foi pouco estudado. Os autores então sugerem que a felicidade pode influenciar muitas decisões econômicas como os hábitos de consumo, uma vez que indivíduos felizes são propensos a poupar mais e distribuir o gasto de forma mais equilibrada, abrangendo bens e intervalos de tempo diferentes, do que pessoas menos felizes.

Graham, Eggers & Sukhtankar (2004) pesquisaram a causalidade reversa, de que a felicidade afeta a renda, utilizando dados em painel da Rússia. Entre os achados mais importantes, verificou-se que a “felicidade residual” (conceituada na pesquisa) está relacionada a níveis de renda mais altos no futuro. As pessoas mais felizes seriam mais propensas a aumentarem suas rendas em períodos futuros.

Güven (2012) abordou a felicidade como fator antecedente ao comportamento econômico. Usando dados de uma pesquisa de domicílios holandeses em conjunto com uma variável climática, a luz solar, Güven correlacionou a incidência do sol com felicidade, mas mais importante do que isso, concluiu que pessoas mais felizes dão mais importância para o futuro, controlando melhor seus gastos ao consumirem menos e poupando mais. Ainda, segundo Güven, pessoas mais felizes também esperam preços mais baixos no futuro, ou seja, têm uma expectativa de inflação diferente das outras pessoas, o que as faz consumirem menos hoje.

Já com um olhar mais voltado para a psicologia, Garg & Lerner (2013) exploraram a relação entre tristeza e consumo. Segundo os pesquisadores, o consumo é influenciado pelo estado de tristeza dos indivíduos, no qual estes acabam pagando mais para adquirir novos bens e também se alimentando de maneira menos saudável. O estudo, entre outros resultados, também revela que de maneira geral, a tristeza aumenta o consumo, com exceção nos casos de pessoas que tenham uma forte característica de autocontrole. Anteriormente, Cryder, Lerner, Gross & Dahl (2008) constataram que o efeito existente da tristeza em gastos é mediado e moderado pela característica de autofoco (*self-focus*) dos indivíduos.


Tanto a felicidade quanto a satisfação com a vida foram considerados para este trabalho pelos resultados empíricos e efeitos que a felicidade/satisfação com a vida pode ter sobre o ambiente macroeconômico, mais especificamente sobre o consumo e – a se verificar – sobre a inflação futura. Devido à pouca quantidade de dados

secundários históricos para a mensuração da felicidade dos brasileiros, não será possível utilizar dados sobre felicidade especificamente, observada diretamente mediante pesquisa à população. Com relação à satisfação com a vida, tem-se o Índice de Satisfação com a Vida da CNI que pode ser usado, porém é de frequência trimestral. Da mesma forma como ocorreu com a série de expectativas de renda pessoal, a CNI informou que não há dados mensais disponíveis para o índice de satisfação com a vida. Neste caso, novamente, procedeu-se a uma interpolação linear dos dados.

2.5. REDES NEURAIS ARTIFICIAIS

A aplicação das redes neurais na área de negócios já é conhecida. Conforme citam Hakimpoor, Arshad, Tat, Khani & Rahmandoust (2011) as redes neurais têm aplicações na área de marketing, finanças, produção, administração estratégica e política de negócios. Smith & Gupta (2000) também destacaram as aplicações das redes neurais na área de negócios, tais como no marketing, varejo, seguros, telecomunicações, gestão de operações, bancos e finanças. Especificamente na área de finanças, Smith & Gupta (2000) descreveram que uma das áreas principais que tem sido afetada pelas redes neurais é a previsão financeira, tendo sido aplicada com sucesso em problemas como precificação de derivativos, previsão de preços de contratos futuros, previsão de taxa de câmbio e previsão de seleção e desempenho de ações. Outras aplicações relacionadas à economia e finanças foram descritas por Salabun & Pietrzykowski (2016), como as análises de aprovação de crédito, valores do mercado imobiliário e previsão de séries temporais do mercado acionário.

A rede neural artificial foi concebida para ser uma semelhança rudimentar com a rede neural cerebral de modo a simular o processo decisório da rede de células nervosas do sistema nervoso central humano (Graupe, 2013). Originalmente a ideia era que ela pudesse resolver problemas tal como o cérebro humano resolve. Rosenblatt (1958) criou um dos primeiros modelos a partir do qual seriam desenvolvidas as redes neurais artificiais. Esse trabalho originou o conceito do neurônio artificial que recebe sinais de entrada e os transforma em um sinal de saída conforme os pesos atribuídos às entradas e uma função de ativação. A este modelo foi dado o nome de Perceptron (Figura 1).



$$Y = f(X1.W1 + X2.W2 + X3.W3 + b)$$

Figura 1: Perceptron (elaboração própria)

Basicamente o neurônio é um nó onde se concentram e são linearmente somados os sinais de entradas ponderados por W e um valor fixo b (como um intercepto de uma regressão linear). Uma função de ativação transforma o valor resultante em um novo valor, produzindo a saída Y . São várias as funções de ativação, sendo as mais populares a linear, a sigmóide e a tangente hiperbólica.

Um salto na evolução das redes neurais foi dado por Rumelhart, Hinton & Williams (1986) quando foi apresentado o algoritmo de retropropagação (conhecido como *backpropagation algorithm*), o que permitiu a implementação de várias camadas de neurônios e a viabilidade de aprendizado (alteração dos pesos) da rede. Este modelo de várias camadas e neurônios foi denominado então de *Multi Layer Perceptron* (MLP).

A arquitetura básica de um Perceptron de múltiplas camadas pode ser resumizada da seguinte forma:

- Uma camada de entrada (*input layer*), onde são recebidos os dados de entrada (variáveis independentes)
- Uma ou mais camadas intermediárias ou escondidas (*hidden layers*), que recebem os dados da camada anterior
- Uma camada de saída (*output layer*) produzindo a previsão ou o que a rede “entende” ser o valor estimado da variável dependente

Cada camada é composta de neurônios que, com exceção da primeira camada, recebem dados dos neurônios da camada anterior e transformam estes dados através

de uma função de ativação. Conforme já descrito, antes de passar os dados pela função de ativação, são atribuídos pesos aos valores de entrada no neurônio. Os valores, agora ponderados, são somados e acrescenta-se ainda um valor fixo de viés.

A título ilustrativo, uma rede neural MLP com entrada de três variáveis (X_n) para “aprender” outra variável e com duas camadas intermediárias, teria uma arquitetura básica representada conforme a Figura 2.




Figura 2: Exemplo da arquitetura de uma rede MLP (elaboração própria)

A rede “aprende” (ou é treinada) a relacionar as variáveis independentes à dependente através de uma sequência de exemplos (conjunto de treinamento), nos quais são apresentadas as variáveis de entrada e a respectiva variável de saída correta correspondente. Assim, a rede neural “aprende” os valores de saída pelos erros gerados na comparação destes valores com os valores corretos. Este erro de aprendizado gerado pela comparação entre o valor correto e o valor entendido pela rede é propagado da saída em direção às entradas através de um algoritmo que vai ajustando marginal- e iterativamente todos os pesos W e os valores b . Este processo é o algoritmo *backpropagation*.

Os perceptrons multicamadas têm uma estrutura de transporte de informação chamada de *feed-forward*, uma vez que a informação corre da entrada até a saída, apenas neste sentido. Ainda nos anos 80 surgiram variantes deste formato, nas quais

a informação era passada de outras formas, por exemplo: entre neurônios da mesma camada ou para o próprio neurônio em tempo posterior (como na Figura 3). Estas variantes tiveram várias denominações, conforme a ideia e implementação de cada autor (como a de Jordan (1986) e Elman (1990)), mas no sentido geral são denominadas como rede neurais recorrentes (RNN – *Recurrent Neural Networks*). A principal diferença para os MLPs é a capacidade de uma “memória interna” da rede de modo que a saída da rede ou de neurônios dependam de e capturem informações do que se calculou até então. As saídas são temporalmente dependentes do estado anterior da rede ou de neurônios, o que indicaria uma aplicação direta quando se trata de estudos sobre séries temporais.




Figura 3: Um esboço de rede neural recorrente (elaboração própria)

No entanto, conforme se desenvolveram estudos sobre as redes neurais recorrentes, ficou evidenciado na literatura problemas com esta abordagem, não emergindo resultados que eram esperados deste tipo de rede. Da maneira geral, como foi idealizada, a rede neural recorrente poderia apresentar problemas de lentidão de aprendizado (ou até mesmo interrupção) e dificuldades no aprendizado com dados de dependência de longo prazo (Bengio, Simard, & Frasconi, 1994), (Hochreiter, 1991), (Hochreiter, Bengio, Frasconi, & Schmidhuber, 2001).

Hochreiter e Schmidhuber (1997) solucionaram os problemas das RNN tradicionais ao introduzirem um subtipo desta arquitetura, denominado de *Long Short-Term Memory* (LSTM), um pouco mais tarde aperfeiçoado por Gers, Schmidhuber e Cummins (2000).

Os modelos que empregam RNN LSTM estão entre os mais modernos atualmente e com aplicações bastante diversas. Empresas como Google, Apple, Microsoft e Amazon são exemplos de organizações que utilizam redes LSTM implementadas dentro de suas estratégias.

Pelas vantagens documentadas tanto na teoria quanto pelo seu uso na prática e pelos resultados preditivos mais acurados sobre métodos econométricos tradicionais, conforme visto anteriormente, mas também em Mitrea, Lee, & Wu, 2009; Semaan, Harb, & Kassem, 2014; Mirmirani & Li, 2004; Binner, Bissoondeeal, Elger, Gazely, & Mullineaux, 2005; optou-se por não utilizar uma metodologia usual econométrica, mas sim utilizar a inteligência artificial, especificamente as redes neurais como ferramenta preditiva. Uma vez justificado o uso de redes neurais, devido às vantagens evidenciadas da arquitetura LSTM para lidar com séries temporais e dados sequenciais (Sundermeyer, Schlüter, & Ney, 2012; Zhao, Chen, Wu, Chen, & Liu, 2017; Zhuge, Xu & Zhang, 2017), este subtipo de rede foi o escolhido para a presente pesquisa.

3. METODOLOGIA

Nesta seção estão especificados detalhes adicionais do problema, das variáveis e principalmente dos procedimentos empregados para se chegar aos resultados da pesquisa.

3.1. ESPECIFICAÇÃO DO PROBLEMA

Por considerar a relevância da previsão e compreensão da inflação brasileira para as ações de política monetária e fiscal do governo federal, o impacto destas ações sobre as pessoas e as empresas, e a relevância da pesquisa sobre o poder preditivo de variáveis macroeconômicas e comportamentais sobre a dinâmica da inflação, é que se estabeleceu o problema de pesquisa conforme a subseção 1.2: **Qual o poder preditivo, o impacto e o tipo de relação funcional das variáveis macroeconômicas na inflação futura e como estes atributos são afetados com a inclusão das expectativas?**

Para a melhor compreensão e alcance dos resultados, estabeleceu-se também as perguntas de pesquisa adicionais elencadas abaixo, que nortearão a pesquisa em busca de se alcançar a resposta para o objetivo geral e os objetivos específicos:

- 1) Qual a melhor configuração de variáveis (atributos) para o modelo macroeconômico?
- 2) Como o poder preditivo se altera pela inclusão das variáveis de expectativas e satisfação com a vida?
- 3) Como é a relação funcional entre as variáveis e a inflação futura no modelo tradicional, em termos de escala e linearidade?
- 4) Como é a relação funcional entre as variáveis e a inflação futura nos modelos híbridos, em termos de escala e linearidade?

3.2. DEFINIÇÃO CONSTITUTIVA E OPERACIONAL DAS VARIÁVEIS

Para um melhor entendimento do que significa cada variável inicial básica no modelo, o quadro abaixo resume os conceitos atribuídos às variáveis, conforme sua definição constitutiva e operacional:

Variável	Definição Constitutiva	Definição Operacional
Inflação ao Consumidor	Aumento generalizado dos preços de bens e serviços para o consumidor final, sem se referir a um produto em específico.	O IPCA, inflação ao consumidor, será obtido pelo site do IBGE, com periodicidade mensal, a partir de novembro/2003 até o presente.
Inflação ao Produtor	Aumento generalizado dos preços de produtos agropecuários e industriais em estágio anterior ao consumidor final.	A inflação ao produtor, estabelecida como uma variável explicativa, será obtida do IPA divulgado pelo IBRE da FGV, nas mesmas periodicidades e intervalo do IPCA.
Taxa de Juros Básica	A taxa de juros básica da economia, divulgada em termos anuais, é a taxa de referência para taxas de juros contratadas em empréstimos, financiamentos, investimentos, aplicações no mercado financeiro, etc.	A taxa de juros medida pelo sistema Selic, sendo a taxa média ajustada dos financiamentos diários para títulos federais, acumulados para o mês de referência, com dados mensais no mesmo intervalo da inflação.
Demanda	Um indicador que representa a atividade da economia, a demanda dos consumidores ou a produção da indústria.	A atividade econômica será medida pela série PIB-Mensal, do Banco Central do Brasil, na periodicidade mensal e intervalos iguais aos da inflação.
Taxa de Câmbio	O quanto vale a moeda de um país em relação a moeda de outro país.	A taxa de câmbio utilizada é a cotação oficial do Dólar Comercial em relação ao Real, divulgada pelo Banco Central. Serão buscadas as últimas cotações de cada mês para o mesmo intervalo da inflação.

Variação dos Preços das Commodities	O preço de uma <i>commodity</i> é o preço cotado em bolsas internacionais de mercadorias e futuros. Logo, a variação do preço de uma commodity é a diferença de seu preço entre um ponto no tempo e outro anterior.	Será utilizado o índice do Banco Central (IC-Br) que reflete o preço de commodities sensíveis à inflação nacional. Dados mensais e intervalo idêntico ao da inflação.
Expectativas de inflação	Percepção da população ou do mercado a respeito da inflação futura.	Será utilizada a pesquisa de expectativas de inflação do consumidor apurada pelo IBRE/FGV. Dados mensais a partir de setembro/2005.
Expectativas de renda	Percepção da população a respeito da tendência futura sobre suas rendas pessoais.	Será utilizado o índice de expectativa de renda pessoal da CNI, cuja periodicidade era trimestral, passando a ser mensal apenas em 2010, com interpolação linear no intervalo em que era trimestral. Intervalo de tempo disponível idêntico ao IPCA.
Satisfação com a vida	Sensação que traduz o bem-estar com a situação geral da vida, considerando vários aspectos: financeiros, saúde, segurança, etc. É um termo que aparece em alguns estudos de forma intercambiável com felicidade ou o nível do bem-estar.	Será utilizado o índice de satisfação com a vida da CNI, cuja periodicidade é trimestral, havendo interpolação linear para produção de dados mensais estimados. Intervalo de tempo disponível idêntico ao IPCA.

Quadro 2: Definição constitutiva e operacional

3.3. DELINEAMENTO DA PESQUISA

A pesquisa está fundamentada em parâmetros técnicos bastante precisos. Quanto aos objetivos esta pesquisa pode ser classificada como descritiva, uma vez que descreve as conexões entre a inflação e variáveis macroeconômicas; mas também com um pequeno viés exploratória ao testar relações da inflação com

variáveis não tão frequentes na literatura – como a satisfação com a vida. O aspecto exploratório também se mostra presente pela própria natureza de como as variáveis finais para os modelos serão estabelecidas (seleção de atributos via *data mining*).

De maneira geral, as razões para a alta ou queda da inflação, apesar de ser um fenômeno complexo, podem ser atribuídas a uma associação de variáveis, cada uma com uma contribuição específica que pode inclusive ter significância apenas em determinado período da história. A escolha das variáveis independentes desta pesquisa foi feita levando-se em conta o que as pesquisas explicativas da área já relatam sobre fatores causadores de inflação e consumo ou poupança. Não obstante o conhecimento das relações explicativas entre as variáveis independentes e dependente, ou mesmo a falta de esclarecimento empírico definitivo sobre algumas relações, o que pode ser aperfeiçoado e melhor descrito é de que maneira se dá este relacionamento. Uma situação é explicar que (ou por que) uma elevação na variável X causa elevação na variável Y. Outra bem diferente, é descrever que a elevação Δs em Y, se dá pela movimentação Δs^2 em X. Exibir este relacionamento dinâmico (ou complexo) faz parte dos resultados desta pesquisa, limitado obviamente pela escolha, extensão e periodicidades das séries, bem como pela escolha e limitação técnica e computacional das redes neurais.

Quanto aos procedimentos, esta pesquisa se caracteriza por ser uma pesquisa documental, uma vez que se valerá de dados documentais e disponíveis em órgãos públicos, alguns deles puros, outros já tendo sofrido algum tipo de tratamento. Assim, as variáveis do modelo, serão dados secundários e são facilmente obtidos dos sites ou sistemas disponibilizados pelas fontes.

3.4. PROCEDIMENTOS

As etapas a serem percorridas de maneira a atingir os objetivos propostos da pesquisa podem ser resumidas conforme o diagrama simplificado da figura seguinte. Cabe observar que as etapas da Figura 4 foram executadas tanto para a rede neural macroeconômica (RNM) quanto para as redes híbridas com a presença das variáveis adicionadas (com exceção da seleção de atributos). Cada etapa é explicada na sequência:




Figura 4: Diagrama dos procedimentos metodológicos

3.4.1. Coleta de Dados

O primeiro passo para iniciar a pesquisa foi a busca pelas séries temporais das variáveis dependente e independentes na periodicidade mensal.

A fonte dos dados varia conforme a série a ser buscada, sendo as seguintes: Banco Central do Brasil (site e Sistema Gerenciador de Séries Temporais do BCB), Instituto Brasileiro de Geografia e Estatística (site do IBGE), Instituto Brasileiro de Economia (site do IBRE da FGV) e Confederação Nacional da Indústria (site da CNI).

3.4.2. Pré-processamento e Seleção de Atributos

A fase de seleção de atributos foi efetuada apenas para a rede neural macroeconômica. De posse dos atributos mais relevantes foram criadas as três redes híbridas, uma para cada adição das outras variáveis externas.

Para a seleção de atributos, inicialmente foram geradas variáveis candidatas para a seleção de atributos a partir de logaritmizações (quando cabível), diferenciações, defasagens e acumulações, gerando uma grande quantidade de variáveis possíveis no intuito de se encontrar o melhor conjunto de variáveis finais.

Em seguida as séries foram normalizadas para permitir que as variáveis, que possuem grandezas muito diferentes, possam ser entendidas pelo modelo da mesma forma. Utilizou-se a normalização max-min, no intervalo -1 a +1, conforme detalhado na seção 4. A etapa de normalização ocorreu também nos modelos híbridos.

Em seguida foi usado um algoritmo de *machine learning*, mais especificamente o de Hall (1999) para a seleção dos melhores atributos (p. ex.: as defasagens ou diferenciações mais relevantes), com o auxílio do software Weka⁴. Cabe observar que não houve intenção de se fazer nenhum procedimento para combinação de variáveis (a exemplo do PCA – *Principal Component Analysis*) a não ser que se verificasse algum problema de dimensionalidade excessiva e isto estivesse causando sobreajuste (*overfitting*) ou superotimização. A razão para isso é que se as dimensões forem combinadas, como no PCA, o significado da verificação das relações funcionais das variáveis individuais ao final, poderia ficar sem sentido ou acabar sendo mais difícil sua interpretação.

3.4.3. População, Amostra e Particionamento dos Dados

A população das séries temporais do estudo poderia ser entendida como todo o histórico que se tem conhecimento até hoje. No entanto, mesmo que isto seja válido, em termos práticos não é possível utilizar todos os registros existentes pois as séries começaram a ser medidas em momentos diferentes. Além disso, as diferentes estruturas nos ambientes econômicos em períodos da história estão intrinsicamente relacionadas às séries temporais, ou seja, as séries refletem as condições específicas de determinado período da economia e não faria sentido usar todo o histórico

⁴ <https://www.cs.waikato.ac.nz/ml/weka/>

disponível pois isto poderia atrapalhar e confundir o treinamento da rede neural. Portanto, definiu-se como marco inicial mínimo o início do regime de metas de inflação (julho/1999). No entanto, o ponto inicial no tempo no qual se tem dados para todas as séries elencadas (incluindo as séries comportamentais) neste trabalho é setembro de 2005. Para a seleção de atributos macroeconômicos as séries foram utilizadas a partir de novembro/2003. Já para rodar os modelos híbridos foi necessário trabalhar com um intervalo menor, a partir de setembro/2005, por conta da pesquisa de expectativas de inflação que começou a ser medida neste mês.

Em suma, o modelo macroeconômico foi rodado com dados a partir de novembro/2003. Posteriormente para que a comparação pudesse ser feita de forma equânime, o modelo macroeconômico novamente e os modelos híbridos foram rodados com dados a partir de setembro/2005.

Independentemente da seleção da amostra, o aprendizado da rede neural precisaria ser confrontado enquanto ocorre. Para isto seria necessário separar a amostra em subconjuntos de treinamento, validação e teste (particionamento), conforme procedimento padrão já conhecido em *machine learning*. A proporção varia na literatura, mas uma proporção comum é 70%, 15% e 15%, ou 80%, 10% e 10%, para dados de treinamento, validação e teste, respectivamente. No entanto, como a quantidade de dados é pequena por conta do intervalo e periodicidade disponíveis, não foi separada a amostra de validação, uma vez que a existência desta seria ideal, mas não imprescindível. Assim, separou-se um intervalo de treinamento com início em novembro/2003 ou setembro/2005, conforme o modelo, até o conjunto de teste que se trata dos últimos 20 meses do período total, finalizando em maio/2017. Logo, o conjunto de teste compreende outubro/2015 a maio/2017. Para melhorar o risco de *overfitting* optou-se por gerar 10 redes neurais a cada ponto de previsão e tomar a média da previsão dos modelos como a previsão oficial do modelo. Mais detalhes sobre este procedimento podem ser verificados na seção seguinte.

3.4.4. Definição da Arquitetura da Rede Neural

Nesta etapa foi escolhida a arquitetura da rede neural utilizada na pesquisa. Partindo do pressuposto de uso das redes neurais recorrentes LSTM, definiu-se a configuração da rede quanto ao número de neurônios, camadas intermediárias, tipos de conexões entre neurônios e camadas, e funções de ativação.

Cada rede foi construída com uma camada intermediária que receberia as entradas e conteria 12 de células LSTM para o modelo macroeconômico e 14 para os modelos híbridos. Todas as funções de ativação das células LSTM foram a tangente hiperbólica, uma vez que ela mapeia o resultado no intervalo -1 a +1, e é preferível sobre a função sigmoide, pois ela promove a atualização dos pesos de forma mais eficaz. Todas as células LSTM enviariam a saída para um neurônio de saída com função de ativação linear, tendo em vista que o que se quer na saída é um valor real sem limites de máximo e mínimo, que é inflação de 12 meses.

3.4.5. Treinamento da Rede

A amostra de treinamento foi usada para o processo de aprendizado da rede. Ao mesmo tempo em que ele ocorreria, a “inteligência” da rede seria colocada à prova na amostra de validação, caso ela existisse. A amostra de validação seria usada para verificar a eficácia do treinamento e ao mesmo tempo evitar o *overfitting*. O *overfitting* ocorre quando um modelo explica de modo muito preciso os dados de treinamento, mas é incapaz de prever novos valores, ou seja, de generalizar o aprendizado em dados fora da amostra.

Como a amostra de validação foi descartada, a verificação de que o treinamento está realmente ocorrendo foi feita com observação nos erros dos modelos sendo treinados com o conjunto de treinamento e enquanto ele acontece. Se observado que os erros do modelo não estivessem convergindo, ou seja, caso as redes não estivessem “aprendendo”, deveria-se avaliar a existência de problemas e possíveis correções / alterações em alguma(s) das etapas anteriores. O treinamento de todas as redes foi feito com 500 passagens (iterações) nos dados.

3.4.6. Teste de Previsão

Após conclusões satisfatórias na amostra de treinamento, ocorreu a previsão da inflação pela rede neural na amostra de teste. O real poder preditivo do modelo foi avaliado nesta amostra. Basicamente, uma vez treinado o modelo, bastou disponibilizar os dados fora da amostra (conjunto de teste) e observar os resultados das previsões. Cabe observar que as previsões no intervalo de teste, ou seja, nos 20 meses finais, foram realizadas de forma dinâmica e não estática. Assim, a cada nova previsão, o modelo “tomou conhecimento” dos dados mais recentes de maneira que

foi novamente treinado para produzir a próxima previsão. A cada nova previsão os modelos tiveram seus pesos reinicializados aleatoriamente.

3.4.7. Análise dos Resultados

Por fim foi realizada a análise dos dados de previsão onde se verificou o poder preditivo dos modelos, seu grau de explicação e erros de previsão. Se após as previsões fosse identificado problemas de *overfitting* (por não conseguir prever no conjunto de teste e evidenciar erros muito grandes), seria necessário avaliar uma alteração na configuração da rede e repetir o treinamento da rede e passos seguintes.

Entre as métricas mais comuns para avaliação de previsões está a raiz do erro quadrático médio (RMSE – *root mean squared error*) que foi a métrica usada para comparar previsões. Não obstante o valor do RMSE, para comparar o poder preditivo dos modelos foi feito um teste de igualdade de RMSE por *bootstrap* com 100.000 simulações, conforme maiores detalhamentos nos resultados. Os resultados também foram comparados às previsões de *benchmarks* tradicionais como o modelo autorregressivo de primeira ordem (AR(1)) e uma regressão linear múltipla alimentada com as mesmas variáveis.

3.4.8. Treinamento Total e Verificação das Relações Funcionais

Por fim, não havendo nenhum problema nas etapas anteriores, as redes foram retreinadas, agora com a totalidade dos dados, e foi analisado como cada variável impacta na inflação futura, oscilando cada variável independente e mantendo todas as outras constantes em suas medianas. Como resultado foram gerados gráficos evidenciando o relacionamento funcional entre as alterações na variável independente e os efeitos produzidos na variável dependente. Aqui foi verificado de que forma a variável dependente é função de cada variável independente. Para cada modelo, foram geradas 100 redes. A relação funcional foi traçada como a média das 100 redes.

A execução do treinamento da rede neural utilizando o conjunto de treinamento, bem como a simulação de previsão nos dados de teste e verificação de impacto das variáveis foram efetuados por meio da linguagem de programação R⁵ com o pacote *keras*⁶.

⁵ <https://www.r-project.org/>

⁶ <https://keras.rstudio.com/>

3.4.9. Outros Achados Após os Resultados

Após a análise dos resultados preditivos e das relações funcionais, procedeu-se a testes a fim de se verificar a racionalidade das expectativas de inflação. Mais especificamente investigou-se premissas da hipótese das expectativas racionais, hipótese das expectativas adaptativas e por fim, verificou-se aspectos da possível presença da heurística de ancoragem e ajustamento (Tversky & Kahneman, 1974) nas expectativas de inflação. Adicionalmente também foram constatados alguns achados no relacionamento entre as variáveis adicionadas (entre si) e demais variáveis macroeconômicas.

4. APRESENTAÇÃO E ANÁLISE DOS DADOS

Nesta seção serão apresentados os dados coletados, algumas estatísticas descritivas, os tratamentos aplicados aos dados, bem como os resultados encontrados no pré-processamento, na seleção de atributos, e nos modelos avaliados, além de complementar com maiores detalhes a metodologia descrita anteriormente.

4.1. MODELO MACROECONÔMICO

O denominado “modelo macroeconômico” aqui, como já mencionado, refere-se a um modelo baseado apenas em variáveis macroeconômicas, ou seja, a partir de dados coletados da economia, sem a opinião das pessoas. Nesta subseção, este modelo, bem como seus resultados e outras informações a respeito são descritos.

4.1.1. Dados Básicos

As séries macroeconômicas foram todas coletadas pela internet nos sites dos seus respectivos fornecedores. Iniciou-se desta forma a pesquisa com as seguintes séries mínimas estabelecidas anteriormente, e por assim dizer em seus estados brutos: taxa do IPCA mensal, taxa do IPA mensal, taxa SELIC mensal, cotação do dólar mensal (média entre cotação de compra e venda no último dia útil do mês), série PIB-Mensal em Reais do BCB e IC-Br. A estas variáveis básicas, foram ainda acrescentadas outras variáveis a título de exploração adicional como insumos para o *data mining*: as três séries originais que compõem o IC-Br (IC-Br Agropecuária, IC-Br Metal e IC-Br Energia), a série PIB-Mensal em Dólar do BCB, a taxa de desemprego mensal⁷ (IBGE), a variação da produção industrial mensal (IBGE), a meta de inflação para 12 meses à frente⁸ e o erro entre a meta e a inflação realizada⁹. A este conjunto

⁷ O IBGE mudou a metodologia para calcular a taxa de desemprego, passando da Pesquisa Mensal de Emprego (PME) para a PNAD Contínua (PNADC). Para a presente pesquisa, as duas séries foram encadeadas da seguinte forma: de março de 2012 até o presente foram utilizados os dados da PNADC. De março de 2012 para trás, foi utilizada a variação nas taxas da PME, porém aplicadas ao primeiro valor da PNADC e reaplicadas recursivamente até o início da série. Assim, tem-se uma série da PNADC fictícia para antes de março de 2012, mas que embute a variação nas taxas de desemprego calculadas pela PME.

⁸ Calculada proporcionalmente quando abrange intervalo entre meses de anos com metas diferentes.

⁹ Calculada como a diferença entre a inflação realizada nos últimos 12 meses e a meta para 12 meses, estabelecida 12 meses atrás (conforme a variável anterior).

de variáveis macroeconômicas em seus estados originais foi dado o nome de variáveis/séries básicas.

Nas Figura 5 e Figura 6 são exibidas as 14 séries básicas, bem como o IPCA a ser previsto, ou seja, o IPCA acumulado para 12 meses futuros que é a variável dependente, no intervalo de novembro/2003 a maio/2017.




Figura 5: Séries Macroeconômicas Básicas (1 a 8)




Figura 6: Séries Macroeconômicas Básicas (9 a 15)

Foram calculadas algumas estatísticas descritivas para se ter conhecimento preliminar dos dados. Estas informações estão expostas na Tabela 1.

Séries	Média	Mínimo	Máximo	Desv. Pad.	Assimet.	Curtose em Exc.	Rejeita a Normal ¹⁰	Rejeita Estac. em Nível ¹¹	Rejeita Estac. em Tendência ¹²
IPCA Acum Próx. 12 Meses	0,058	0,025	0,107	0,019	0,436	0,000	SIM	SIM	SIM
Taxa IPCA	0,005	-0,002	0,013	0,003	0,474	0,602	SIM	NÃO	NÃO
Taxa IPA	0,005	-0,020	0,024	0,008	-0,055	-0,169	SIM	NÃO	NÃO
Selic	0,010	0,005	0,017	0,002	0,451	-0,225	SIM	SIM	SIM
Dólar (R\$ / US\$)	2,342	1,556	4,042	0,613	0,913	0,005	SIM	SIM	SIM
PIB-Mensal (milhões de R\$)	3,4E+05	1,4E+05	5,7E+05	1,3E+05	0,116	-1,410	SIM	SIM	SIM
PIB-Mensal (milhões de US\$)	1,5E+05	4,7E+04	2,3E+05	5,2E+04	-0,324	-1,024	SIM	SIM	SIM
IC-Br	117,151	85,820	185,030	26,203	0,927	-0,210	SIM	SIM	SIM
IC-Br Agropecuária	125,116	87,960	216,680	33,374	0,978	-0,021	SIM	SIM	SIM
IC-Br Metal	130,623	84,190	204,770	29,784	0,584	-0,337	SIM	SIM	SIM
IC-Br Energia	74,098	51,120	118,470	13,403	0,744	0,119	SIM	SIM	SIM
Taxa Desemprego	9,679	6,200	14,800	2,191	0,252	-1,080	SIM	SIM	SIM
Variação da Prod. Industrial (%)	0,000	-0,112	0,034	0,017	-2,171	10,522	SIM	NÃO	NÃO
IPCA Meta	0,045	0,045	0,055	0,002	4,068	15,780	SIM	SIM	SIM
Erro Meta	0,015	-0,015	0,071	0,017	0,769	0,687	SIM	SIM	SIM

Tabela 1: Estatísticas sobre as variáveis básicas

Observa-se que as variáveis são bastante diferentes entre si, a começar pela magnitude dos valores, o que pode ser verificado pela média ou pelos valores máximos e mínimos. Enquanto as taxas de IPCA, IPA e outras situam-se em valores inferiores à unidade, valores de PIB estão na casa acima dos milhões. Outra característica dos dados é que as distribuições das séries são assimétricas e não são mesocúrticas em sua grande maioria, o que leva a acreditar que as variáveis não têm distribuição normal. Isto fica evidenciado pelo teste KS de normalidade, que revela que aparentemente nenhuma das séries é normal (considerando a significância a 5%).

Outro aspecto observável é que a maioria das variáveis não é estacionária, dada a significância a 5%. As rejeições aos testes KPSS indicam que a maior parte das séries não permanecem estacionárias sobre determinado nível ou determinada tendência. Para modelos com séries temporais é necessário muitas vezes utilizá-las na forma estacionária. Para isso é preciso diferenciar a série, removendo a tendência e possivelmente, transformando-a em estacionária.

¹⁰ Rejeita a hipótese nula a 5% do teste Kolmogorov-Smirnov para igualdade entre a distribuição de valores da série e a normal.

¹¹ Rejeita a hipótese nula a 5% do teste KPSS para a estacionariedade da série em determinado nível.

¹² Rejeita a hipótese nula a 5% do teste KPSS para a estacionariedade da série em tendência.

4.1.2. Pré-Processamento e Seleção de Atributos

Pelas razões apontadas, tal como as diferentes dimensões dos valores das séries e a necessidade de diferenciá-las, é preciso torná-las mais parecidas entre si, sem perder suas características. Para isso procedeu-se a um pré-processamento das variáveis.

Às variáveis brutas foram aplicadas logaritmizações (sobre variáveis que estejam relacionadas a acumulações de valores/preços que possam exibir tendências exponenciais no tempo como por exemplo o Dólar), acumulações (por períodos determinados, por exemplo com a série mensal da Selic foi possível gerar uma série mensal da Selic acumulada dos 3 meses precedentes), diferenciações e defasagens de 1, 2, 6 e 12 meses. Por exemplo: com a taxa do IPCA foram geradas as séries de taxa do IPCA defasadas em 1, 2, 6 e 12 meses. Foram geradas taxas de IPCA acumuladas para 2, 3, 6 e 12 meses (bem como a adição de defasagens de 1, 2, 6 e 12 meses para cada acumulação), e assim por diante para cada variável básica. A utilização destes parâmetros que variam de 1 a 12 se deve para capturar tanto alterações/acumulações recentes quanto mais espaçadas no tempo. Assim, a partir destas 14 séries macroeconômicas básicas foram geradas um total de 361 variáveis candidatas a seleção de atributos¹³. As séries básicas também foram mantidas, a fim de que pudessem ser candidatas na seleção de atributos.

Foi aplicada a todas as 361 variáveis a normalização max-min para o intervalo -1 a +1. A variável $V_{k,t}$ representa uma variável k no instante t normalizada, e foi obtida pela seguinte equação:

$$V_{k,t} = 2 \cdot \frac{v_{k,t} - \text{Min}(v_k)}{\text{Max}(v_k) - \text{Min}(v_k)} - 1,$$

na qual $v_{k,t}$ refere-se à variável k no instante t não-normalizada. Assim, todas as variáveis vêm a ter magnitudes semelhantes. Na saída dos modelos, a variável dependente é desnormalizada (pela mesma equação) de maneira que seu valor possa ser compreendido.

Com as 361 séries normalizadas, procedeu-se à seleção de atributos com os algoritmos de *data mining*. Para esta etapa, como já relatado, foi utilizado o software Weka. A fim de se chegar ao conjunto de atributos relevantes para previsão da inflação

¹³ Todas as 361 variáveis candidatas à seleção de atributos podem ser encontradas no Anexo A.

acumulada de 12 meses foi utilizado o algoritmo conforme Hall & Smith (1998) e Hall (1999), presente no software Weka (com o método de busca padrão: *BestFirst*). Este algoritmo avalia a relevância de um conjunto de atributos considerando a habilidade preditiva de cada variável, e ao mesmo tempo busca agregar variáveis não-redundantes, ou seja, com baixa intercorrelação.

É importante estabelecer o intervalo de tempo em que esta seleção será buscada. Como um dos objetivos da pesquisa é fazer a previsão da inflação por meio de modelos, inicialmente se estabeleceu o intervalo em que esta previsão será feita e será objeto de comparação entre os modelos. Conforme já comentado na subseção 3.4.3 da Metodologia, o intervalo de previsão estabelecido foi de outubro/2015 a maio/2017 (20 meses). Isto significa que, tendo todos os dados das séries temporais referentes ao mês de outubro de 2015, os modelos farão a primeira previsão, a qual será a inflação acumulada para 12 meses, ou seja, a inflação acumulada entre novembro/2015 e outubro/2016. A última previsão será realizada em maio/2017 onde os modelos atuarão para prever a inflação acumulada entre junho/2017 a maio/2018. Logo, a seleção de atributos precisa ser rodada antes de ocorrer a primeira previsão. O primeiro gráfico da Figura 5 mostra a taxa do IPCA de 12 meses com uma linha vermelha pontilhada e vertical. O intervalo à direita trata-se do período no qual os modelos atuarão para prever a taxa de inflação acumulada. Observa-se que se trata de um período de desafio considerável a modelos preditivos, pois o IPCA exibe um comportamento bastante diferente de seu passado, sem ciclos precisos e com uma tendência de queda na inflação não verificada anteriormente.

Se a primeira previsão ocorre com os dados de outubro/2015, neste ponto no tempo o último dado de inflação acumulada de 12 meses que se tem é entre novembro/2014 e outubro/2015. Portanto, a seleção de atributos será rodada apenas até outubro/2014, para que não seja possível ao algoritmo “enxergar o futuro”. O primeiro mês a ser usado na seleção de atributos macroeconômicos é novembro/2003 por haver disponibilidade de dados para todas as 361 variáveis. Em suma, a seleção de atributos ocorrerá entre novembro/2003 e outubro/2014.

Como resultado desta etapa, encontra-se no Quadro 3 o conjunto de atributos relevantes encontrado no Weka para o modelo macroeconômico, bem como a nomenclatura de variáveis utilizada por todo o resto do trabalho e com a respectiva descrição:

Nome da Variável	Descrição
var.1.licbr	Variação mensal do <i>log</i> do IC-Br
licbra	Nível do <i>log</i> do IC-Br Agropecuária
var.12.licbra.12	Variação em 12 meses do <i>log</i> do IC-Br Agropecuária e defasado de 12 meses
licbre.12	Nível do <i>log</i> do IC-Br Energia e defasado de 12 meses
var.12.lpidb.12	Variação em 12 meses do <i>log</i> do PIB em Dólar e defasado de 12 meses
var.12.desemp.6	Variação em 12 meses da taxa de desemprego e defasada de 6 meses

Todos os *log* são logaritmos naturais (ln)

Quadro 3: Atributos macroeconômicos selecionados

Com isso, aqui já aparece um dos objetivos da pesquisa. Considerando as 361 variáveis disponíveis para a seleção de atributos e o intervalo analisado, este conjunto de apenas 6 seria a melhor escolha, atendendo ao primeiro objetivo específico do trabalho. O que se pode destacar é que a inflação futura acumulada para 12 meses teria no mínimo dois componentes principais: um componente ligado ao preço das commodities (IC-Br, IC-Br Agropecuária e IC-Br Energia) e outro ligado à demanda (PIB em dólar e desemprego). É interessante notar que não entrou neste subconjunto nenhum atributo relacionado à Selic, ao dólar diretamente, à inflação inercial ou ao índice de inflação ao produtor amplo (IPA), que são variáveis presentes em muitos trabalhos como já se verificou anteriormente. Uma explicação possível para isso é que no “entender” do algoritmo estas variáveis podem não ter poder preditivo para a variável dependente ou serem de alguma forma redundantes em relação às variáveis finais selecionadas.

A Figura 7 mostra as variáveis dependentes e independentes normalizadas, no intervalo da seleção de atributos.




Figura 7: Variáveis macroeconômicas selecionadas normalizadas

4.1.3. Rede Neural LSTM Macroeconômica e a Previsão da Inflação

Uma vez tendo as séries necessárias para a modelagem, procedeu-se à implementação da rede neural LSTM para a previsão de inflação para o período estabelecido. Como já mencionado anteriormente, o intervalo escolhido para previsão do IPCA acumulado é de outubro/2015 a maio/2017, de modo que a inflação prevista é a inflação de 12 meses medida no intervalo de outubro/2016 a maio/2018.

Conforme já comentado, para que a previsão fosse a mais próxima de uma situação real, optou-se por fazer a modelagem e previsão de forma dinâmica, de modo que as informações mais recentes entrassem no modelo e o mesmo fosse reestimado, refletindo o impacto de dados mais recentes. Logo, a cada mês transcorrido, o modelo foi reestimado, tendo como novembro/2003¹⁴ o ponto inicial dos dados até o mês mais recente.

Como já descrito, inicialmente pensou-se em separar uma parte (por exemplo 10%) dos dados de treinamento para amostra de validação, pois isto melhoraria a generalização do modelo e diminuiria o risco de *overfitting* (sobreajustamento). No entanto, verificou-se que como a quantidade de dados é pequena, muita informação seria perdida caso esse procedimento fosse realizado. Porém, ao eliminar a validação permanece o risco de se estimar um modelo sobreajustado aos dados de treinamento e que geraria problema para generalizar a previsão para dados fora da amostra. Há também o risco de se estimar um modelo que acabe se sobreajustando aos dados de teste apenas por acaso. Este último caso seria mais difícil de acontecer pois como o modelo é reestimado a cada mês, esta coincidência teria que acontecer todas as vezes em que o modelo fosse reestimado. Mesmo assim, para contornar estes problemas, a solução foi reestimar 10 modelos a cada mês e considerar como previsão do modelo macroeconômico a média da previsão destas 10 redes neurais macroeconômicas. Assim, tanto modelos bons quanto não tão bons foram considerados. Embora o ideal fosse produzir o máximo de modelos possíveis, a opção pelo estabelecimento do quantitativo de 10 modelos se deve por razões de tempo e poder computacional disponível atualmente. Como as previsões são dinâmicas e para

¹⁴ Além de novembro/2003 ser o ponto mínimo no tempo em que havia dados para todas as variáveis na seleção de atributos, também foi estabelecido este mês como ponto inicial de estimação por se considerar maio/2003 o primeiro ponto seguinte a uma quebra estrutural do IPCA, conforme sugerido por Lima & Alves (2011). Com 7 meses pós quebra estrutural, as variáveis defasadas ou de acumulação puderam, pelo menos parcialmente, capturar o novo cenário.

cada uma foram gerados 10 modelos, e a amostra de teste contém 20 pontos de previsão, na geração de todas as previsões, na realidade, foram implementadas e treinadas 200 redes neurais para cada um dos modelos (o macroeconômico e posteriormente os três híbridos).

A questão sobre número de camadas intermediárias e de neurônios por camada ainda é amplamente debatida, havendo muitas regras de bolso para redes *feed-forward*. Para redes recorrentes esta decisão é ainda mais incerta, sugerindo-se inclusive a tentativa e erro para se chegar na quantidade adequada. Heaton (2008), em referência às redes *feed-forward* destaca que raramente são necessárias duas camadas intermediárias e que para a maior parte dos problemas uma camada intermediária é o suficiente, não havendo razão para mais do que isso. Este entendimento também foi aplicado neste trabalho, motivo pela qual estabeleceu-se uma única camada intermediária. Ainda segundo Heaton (2008), uma das regras de bolso para quantidade de neurônios seria que ficasse abaixo do dobro da quantidade de entradas. Para os métodos de *deep learning*, as regras que estabelecem quantidades de parâmetros podem não fazer sentido, pois o próprio conceito de *overfitting* se mostra desatualizado para estas técnicas e precisa ser melhor compreendido. Conforme Zhang et. al. (2017), redes neurais profundas (*deep artificial neural networks*) frequentemente treinam dados em quantidades significativamente inferiores ao número de parâmetros do modelo, mas surpreendentemente acabam tendo baixos erros de generalização (a diferença entre o erro no conjunto de treinamento e teste). Considerando a falta de uma métrica definitiva sobre as quantidades de camadas e neurônios em redes recorrentes LSTM, foi montada apenas uma camada intermediária com 12 células LSTM (o dobro em relação ao número de entradas) e uma camada de saída, com apenas um neurônio que produz a saída do modelo, ou seja, a previsão para o IPCA acumulado para os próximos 12 meses. Como já esclarecido anteriormente, a função de ativação das células LSTM é a tangente hiperbólica e a do neurônio de saída é uma função linear.

Uma vez que não havia o conjunto de validação para decidir em que momento parar de treinar a rede, a decisão sobre o número de passagens nos dados (iterações) foi tomada com base unicamente no conjunto de treinamento e de maneira empírica. Buscou-se observar um ponto no qual os erros (*mean squared error*) no primeiro conjunto de treinamento normalizado (para fazer a primeira previsão) tivessem uma

convergência em direção ao zero de modo visualmente significativo e não progredissem mais de forma relevante. Assim, rodou-se a rede neural 10 vezes e observou-se os erros produzidos no primeiro conjunto de treinamento. Pela Figura 8 verifica-se que o modelo converge, em média, de forma mais significativa até por volta da 500ª passagem nos dados. A partir daí há ganhos cada vez menores no aprendizado da rede e aumenta-se o risco de *overfitting*. Por este motivo, 500 iterações foi o estabelecido para rodar todas as redes neurais.




Figura 8: Mean squared error em cada iteração

A cada reestimação os modelos tiveram seus pesos inicializados de forma aleatória.

Após a seleção de atributos no Weka, todos os procedimentos de simulação (treinamento, previsão e relações funcionais) foram executados na linguagem de programação R, conforme mencionado previamente.

A fim de comparar o poder preditivo do modelo macroeconômico e dos modelos híbridos (não somente entre si) foram estabelecidos dois outros modelos tradicionais considerados *benchmarks*: um modelo autorregressivo de primeira ordem (AR(1)), que é um modelo univariado e um dos modelos comuns usados como *benchmark* na previsão de séries temporais econômicas, cuja estimação para a inflação de 12 meses se dá de forma recursiva; e um modelo de regressão linear múltipla (RL), que é um modelo multivariado, utiliza as mesmas variáveis independentes das redes neurais e modela a variável dependente diretamente. Os dois *benchmarks* tiveram seus parâmetros de atuação idênticos aos da rede: mesmo intervalo de estimação inicial e reestimação dinâmica mensal. A única diferença é que o modelo AR utiliza a taxa do IPCA mensal como entrada e não-normalizada por ser um modelo univariado.

Alcançando um dos objetivos da pesquisa, os resultados preditivos de todos os modelos em comparação à taxa de inflação acumulada para os próximos 12 meses podem ser vistos na Figura 9. Com a Figura 9 e a Tabela 2 e os comentários relacionados, chega-se ao segundo objetivo específico da pesquisa.





Figura 9: Previsões realizadas pelos modelos X IPCA 12 Meses Real

Observa-se que no início do período a rede neural tem um desempenho inferior ao AR(1) e ao modelo linear. Ao longo dos meses seguintes o desempenho da rede melhora e as previsões ficam mais próximas dos valores reais. O que parece claro neste intervalo de tempo é que a regressão linear tem desempenho bastante inferior ao AR(1), que é um modelo univariado, mas significativamente pior do que a rede

neural, quando se leva em consideração que são modelos que dispõem das mesmas informações.

Na Tabela 2 são exibidas métricas e testes estatísticos para comparar a precisão entre modelos. A linha RMSE refere-se à raiz do erro quadrático médio (*root mean squared error*) entre os valores previstos e as observações reais, uma métrica bastante tradicional para verificar o desempenho preditivo. Para comparar os modelos entre si foi implementado um teste de igualdade de RMSE calculado por *bootstrap*¹⁵. A hipótese nula do teste é de igualdade entre RMSE, já a hipótese alternativa considerada é a de que os modelos da primeira coluna têm RMSE inferior aos modelos da primeira linha. Em suma, a tabela indica qual a significância para a hipótese de que as previsões dos modelos da primeira coluna sejam iguais às previsões dos modelos da primeira linha, sendo a hipótese alternativa de superioridade preditiva dos modelos da primeira coluna.

Modelos		AR(1)	RL	RNM
	RMSE	0,0254	0,0674	0,0188
AR(1)	<i>p-value</i>	-	0,000	1,000
RL	<i>p-value</i>	1,000	-	1,000
RNM	<i>p-value</i>	0,000	0,000	-

Nota:

AR(1): Modelo autorregressivo de primeira ordem

RL: Regressão linear

RNM: Rede Neural Macroeconômica

Tabela 2: Métricas de comparação

Levando estas informações em conta, inicialmente pode-se observar que o melhor modelo é a rede neural, uma vez que tem o menor RMSE, embora, como já notado anteriormente, tenha iniciado o período de previsão com valores mais distantes do que os outros dois modelos. Pelo RMSE também se pode verificar que o pior modelo é a RL. O AR(1) tem RMSE bem mais baixo do que a RL, mas superior à rede neural.

Pelos valores dos *p-values* dos testes, pode-se constatar que tanto o AR(1) quanto a rede neural são superiores à RL, uma vez que os resultados são significantes a 0,1%, o que confirma o observado nos gráficos anteriormente. O teste indica

¹⁵ Teste calculado sobre os erros de previsão, pelo método da máxima entropia (Vinod H., 2006; Vinod & López-de-Lacalle, 2016), multivariado e com preservação da dependência temporal (autocorrelações). Teste feito com 100.000 simulações.

também que a rede neural macroeconômica tem precisão preditiva melhor e bastante significativa.

Estes resultados mostram que o melhor modelo foi a rede neural macroeconômica, o que pode ser uma estratégia útil para previsões de séries temporais econômicas ou financeiras e tomada de decisões.

4.1.4. Relações Funcionais

Ao término da última previsão a rede neural foi reestimada para todo o período pesquisado de modo que pudesse ser obtido um modelo para traçar as relações funcionais entre a inflação acumulada para 12 meses futuros e as variáveis independentes, a fim de cumprir o terceiro objetivo específico do estudo. Uma diferença que foi introduzida é que o período inicial usado na estimação das relações funcionais foi alterado para setembro/2005 (em vez de novembro/2003), uma vez que mais adiante o objetivo é verificar como as relações funcionais se alteram com a inclusão das variáveis que dão origem aos modelos híbridos. Como as expectativas do consumidor iniciaram em setembro/2005, este foi o mês inicial usado para comparar as relações funcionais dos modelos. A perda de informação por se utilizar menos dados na estimação do modelo macroeconômico é certamente indesejável, mas, como pode ser visto mais à frente, o traçado das previsões não se altera de forma tão significativa, de forma que o RMSE também não se alterou de forma tão brusca, passando de 0,0188 para 0,0191.

O objetivo de se traçar relações funcionais é verificar de que forma cada atributo produz resultado na variável dependente. Cabe observar apenas que não se trata de verificar como uma alteração em uma variável se propaga para as outras ao longo do tempo e sim observar como o nível de determinada variável afeta o nível da dependente. Por exemplo, ao oscilar a variável *licbra* (*log* do nível do IC-Br Agropecuária) desde seu valor mínimo até seu máximo e verificar o efeito sobre a inflação, não se está supondo esta oscilação de forma cronológica, ou seja, como se cada alteração progressiva representasse uma variação de um mês para outro. A razão para isso é porque se fosse desta forma, isto produziria efeito em outras variáveis como sobre a variável *var.1.licbr* (variação mensal do *log* do IC-Br), porque o IC-Br Agropecuária faz parte do IC-Br. Assim não seria possível simular a oscilação cronológica em *licbra* sem também produzir variação em *var.1.licbr*. Logo, a intenção

não é verificar o desenvolvimento temporal da oscilação, mas sim como determinado nível de cada atributo está relacionado ao nível da inflação acumulada para 12 meses futuros.

Para esta estimação final, foram usados basicamente os mesmos critérios anteriores. Trata-se da mesma rede em termos de arquitetura e sobre a qual foram realizadas da mesma maneira múltiplas estimações diferentes e com as mesmas 500 iterações de treinamento para cada rede. Neste quesito, a única diferença é que, como o poder computacional necessário é 20 vezes menor, uma vez que não é necessário prever dinamicamente 20 meses como nas simulações anteriores, optou-se por utilizar 100 redes neurais, a fim de se ter um resultado mais robusto. Logo, obteve-se 100 redes neurais LSTM a disposição para a verificação das relações funcionais.

Cada variável independente foi tomada uma-a-uma e seu valor foi variado desde o mínimo até o máximo alcançado no intervalo do estudo. O resultado de cada ponto nesta oscilação foi medido na variável dependente. Enquanto cada uma das variáveis era testada as outras tinham seus valores fixados em suas medianas. Este processo foi repetido de modo que fossem geradas relações funcionais em cada uma das 100 redes treinadas. Com a média em cada ponto, foi traçada a relação funcional.




Figura 10: Relações funcionais das séries do modelo macroeconômico

A Figura 10 mostra as relações funcionais encontradas. Foram testados 100 pontos entre os valores mínimo e máximo das variáveis. Para cada ponto, cada rede neural deu uma resposta para a variável dependente (o IPCA acumulado para 12 meses futuros), permitindo montar os traçados das relações funcionais. Foram traçadas bandas de percentis (2,5 e 97,5) para a resposta no IPCA acumulado, considerando as 100 respostas dos modelos em cada ponto. O objetivo destas bandas

é verificar quão preciso são os 100 modelos em traçar a resposta de uma variável, ou seja, verificar se os modelos divergem muito a respeito da sensibilidade da variável ou se “concordam”. Quanto mais próximas forem as bandas, mais significativa é a resposta dos modelos. Adicionalmente foram traçadas linhas verticais pontilhadas em vermelho que representam os percentis 10, 50 e 90 da variável analisada (eixo horizontal) durante o intervalo de estudo. Esta marcação serve para passar a ideia da faixa de valores pela qual a variável passou no histórico. Assim a análise destas relações funcionais pode ser feita com base no intervalo total ou neste intervalo “normal” de valores para a série em questão. A menção ao intervalo “normal” no decorrer do trabalho quer dizer que se está se referindo ao intervalo entre os percentis 10 e 90.

Optou-se por traçar também a linha horizontal tracejada na cor laranja para indicar o que se chama aqui de “resposta mediana”. Já no primeiro gráfico pode-se verificar que a resposta da rede neural para quando todas as séries independentes estiverem em suas medianas é o ponto onde a variável dependente cruza a mediana da variável analisada. Verificando no primeiro gráfico, seria em torno de 6,15%. Em todos os outros gráficos este dado também pode ser verificado. Portanto, quando todas as variáveis estão em suas medianas, a rede, que foi treinada em todo o histórico, estima que a inflação futura acumulada para 12 meses seja cerca de 6,15%. A indicação deste valor é importante para se analisar se de fato a variável promove um deslocamento significativo na inflação futura, ou se na verdade apenas passeia sobre esta resposta mediana.

Outra característica a se notar nos gráficos gerados é que as séries foram “deslogaritmizadas” (quando cabível). Assim, as variações logarítmicas passaram a ser variações em percentual e os níveis logarítmicos passaram a ser níveis reais das variáveis. Esta transformação permite compreender melhor os valores a serem usados para obter as relações funcionais. Por exemplo, a variação mensal do IC-Br é divulgada pelo Banco Central em termos percentuais e não em termos de *log* da variação. Assim fica mais fácil pensar as relações funcionais por meio de valores mais assimiláveis, pois correspondem mais com o dia-a-dia e a realidade das informações da mídia e do mercado.

É possível observar que nenhuma das relações funcionais é perfeitamente linear, sendo que em alguns casos lembram relações parabólicas. No entanto, se for

considerado apenas o intervalo normal, algumas variáveis tendem a se aproximar de um aspecto mais linear. Neste quesito pode-se citar as séries: icbre.12 e var.12.pibd.12(%).

A Figura 10 permite que se façam comparações em termos do tipo de relação funcional existente e seu impacto. Porém ainda não fica explícito o impacto que cada variável tem na inflação acumulada futura em comparação com as outras. Para verificar o impacto que cada variável gera, precisa-se verificar a magnitude da resposta que a rede neural dá para construir a relação funcional. Assim, deve-se observar a faixa de valores do eixo vertical e comparar as magnitudes entre os vários gráficos. Para tornar este processo mais simples foi gerada a Figura 11. Nesta figura as variáveis estão em seus valores normalizados, tal como entraram no modelo. Desta forma, elas podem ser comparadas diretamente em termos de produção de impacto sobre a variável dependente. Foram traçadas linhas horizontais tracejadas que representam as faixas “normais” de valores da inflação futura acumulada, ou seja, os percentis 10, 50 e 90.

Pode-se notar que o modelo estimado abarca respostas para a inflação em grande parte do intervalo existente indo desde o primeiro decil para além do nono.

Um resultado importante do estudo aparece nesta figura. Numa análise conjunta, a Figura 11 mostra que a variável macroeconômica mais impactante (a que atinge valores absolutos mais altos) e a mais sensível é o IC-Br Agropecuária (icbra). O IC-Br do setor agropecuário (ou IC-Br-A) representa a evolução de preços das mercadorias mais relevantes para a inflação brasileira, mais especificamente: carne de boi, algodão, óleo de soja, trigo, açúcar, milho, café, arroz, carne de porco, suco de laranja e cacau. Logo, a julgar pela “conclusão” do modelo e do intervalo de tempo do estudo, pode-se dizer que, dentre as variáveis analisadas, o nível de preços destas mercadorias foi o mais impactante para a alta de inflação em 12 meses seguintes.

Na sequência pode-se verificar que a variação do desemprego teve papel relevante para a dinâmica inflacionária futura, uma vez que, no contexto do estudo, é a série com maior impacto depois do IC-Br-A. O papel da variação do desemprego tem significado contrário ao do IC-Br-A. Esta variável foi a que mais contribuiu para quedas na inflação de 12 meses futura.

A variável menos impactante parece ser a variação mensal do IC-Br (var.1.icbr). Outras variáveis têm efeitos intermediários consideráveis, conforme comentado a

seguir. Cabe lembrar novamente que a análise da magnitude dos impactos somente tem sentido para os valores do eixo y quando se considera que as outras variáveis estão em seus valores medianos.




Figura 11: Relações funcionais com as variáveis independentes normalizadas

4.1.4.1. Variação do IC-Br (var.1.icbr)

Analisando-se na Figura 10 a variação mensal do IC-Br (var.1.icbr), pode-se verificar que a variável produz efeitos muito semelhantes a uma parábola, embora não esteja centrada na mediana. Percebe-se uma tendência crescente sobre a inflação até a variável atingir algo em torno de 2,5%, quando então esta passa a ter impacto decrescente. Porém, conforme notado anteriormente, a escala destes efeitos é pequena. Isto indica que a variação de preço de apenas um mês nas principais *commodities* para a inflação brasileira produziu um pequeno efeito ao longo dos próximos 12 meses de modo a afetar a inflação. Não está claro neste estudo como esta variação mensal se propagou para produzir impactos na inflação 12 meses à

frente. Como a maior parte do impacto é crescente (uma vez que a parábola é assimétrica em relação à mediana) e pequeno, pode-se supor que uma variação média no IC-Br produziria impacto mais significativo nos meses mais imediatos e que isso iria se atenuando ao longo do tempo, como se fosse a resposta a um choque, a qual foi se amortecendo e convergindo. Como este aprofundamento não é objetivo deste estudo, esta hipótese necessitaria de uma pesquisa econométrica mais extensa. Todavia, esta hipótese e explicação pode ser encontrada em Stockl, Moreria & Giuberti (2017). Entre os achados, os autores concluíram que um choque positivo na variação dos preços das *commodities* que compõem o IC-Br produz uma variação para cima no IPCA já nos primeiros meses seguintes, com pico no segundo mês. A resposta a este choque vai se reduzindo até que a partir do oitavo mês ela é praticamente nula. Os autores também destacam que a resposta do IPCA ao IC-Br, tal como relatado, não teve significância estatística, o que é similar à falta de significância encontrada na relação funcional do IC-Br aqui, conforme explicado mais à frente.

O movimento no IC-Br provoca respostas não lineares e assimétricas. Pode-se notar que se a variação no IC-Br for de -5% o impacto sobre a inflação acumulada futura sofrerá um deslocamento para baixo (em relação à resposta mediana) de aproximadamente 0,15%, ao passo que se o IC-Br registrar uma variação de +5%, a princípio haverá uma contribuição negativa, mas praticamente nula.

Pela posição dos percentis 10 e 90 da variável, pode-se verificar que ela tem uma pequena distribuição assimétrica positiva. Considerando que entre a mediana e o percentil 90 o impacto não varia muito, isto mostra que a variável esteve contribuindo mais para deslocar a inflação para baixo do que para cima, considerando a resposta mediana que é o nível da inflação quando todas as variáveis estão em suas medianas.

Outro fato que chama a atenção são as bandas de percentis. Como a escala do impacto é pequena e a largura destas bandas é bastante grande comparada às das outras variáveis (a do percentil 90 nem mesmo aparece na escala do gráfico), isto indica que o tipo de relação funcional desta variável pode mudar bastante conforme o modelo analisado. O que se pode verificar é que, considerando os 100 modelos que geraram a relação funcional e que as bandas abrangem 95% da amplitude das relações funcionais possíveis, em toda a faixa da variação do IC-Br (eixo x) o valor da resposta mediana, ou seja 6,15%, fica sempre entre as bandas. Isto quer dizer que a

relação funcional encontrada não é significativa baseando-se nos percentis 2,5 e 97,5 das possíveis relações funcionais. Em outras palavras, considerando 95% das relações possíveis encontradas, não parece haver evidências de que a diferença entre o impacto produzido pela variação do IC-Br e a resposta mediana seja significativamente diferente de zero, ou seja, a divergência das redes neurais indicam que na realidade pode não haver impacto algum da variação do IC-Br sobre a variável dependente.

4.1.4.2. IC-Br Agropecuária (icbra)

Voltando o olhar para o nível do IC-Br-A, na Figura 10, a primeira constatação é que a série possui considerável assimetria positiva e é claramente não linear. O nível mínimo em que a variável impacta a inflação é entre a mediana e o primeiro decil. Da mediana para baixo o efeito sobre a inflação é bastante reduzido (ou praticamente nulo). Da mediana para cima o impacto sobre a inflação é crescente e não linear.

Como visto na Figura 11, o impacto do IC-Br-A é o maior entre as variáveis, porém ele difere bastante se a variável apresenta valores abaixo ou acima da mediana. O impacto desta variável na inflação futura é assimétrico, logo, valores menores, abaixo da mediana, têm efeito muito mais limitado e menos sensíveis a mudanças no nível do IC-Br-A. Considerando que o comportamento acima e abaixo da mediana são bastante diferentes, pode-se constatar que em metade do tempo do intervalo estudado este índice esteve no campo acima da mediana, e, portanto, produzindo efeitos significativamente mais fortes do que na outra metade do tempo. A título exemplificativo, se esta e outras variáveis estiverem na mediana, a inflação futura acumulada ficaria estimada em 6,15% como já comentado. Porém se o IC-Br-A passasse de pouco mais de 120 (a mediana) a próximo de 180 (percentil 90), haveria uma contribuição positiva de 2,85% (9% - 6,15%) na estimativa da taxa de inflação futura. Uma diferença considerável dada a escala em que a taxa de IPCA se encontra. Por outro lado, movimentos do IC-Br-A abaixo da mediana praticamente não tiveram efeitos sobre a inflação de 12 meses.

O nível do IC-Br-A, além de ser a série com maior impacto sobre o IPCA futuro, também é a variável mais significativa se for considerada a distância entre as bandas de percentis. Pela largura das bandas, pode-se verificar que na grande maioria dos pontos em que o IC-Br-A está posicionado (principalmente acima da mediana), a

resposta não inclui a resposta mediana do IPCA, ou seja, na medida em que o nível do IC-Br-A sobe acima da mediana, a diferença entre a resposta mediana e o impacto da variável no IPCA tende a ser diferente de zero e positiva.

Outro detalhe que chama a atenção nesta relação funcional, é que o impacto produzido desta variável abaixo de 6,15% é pequeno e limitado. Isto é, ela contribuiu (em média) muito pouco para baixar a inflação para baixo da resposta mediana, nem mesmo quando está em níveis bastante baixos. Assim, a julgar por esta relação funcional, os preços das mercadorias, medidos pelo IC-Br-A não explicam as quedas no IPCA, quando o preço desta cesta de itens cai abaixo de seu valor mediano.

Do ponto de vista administrativo, talvez um dos principais fatos a serem observados nesta relação funcional é justamente este. Se o preço da cesta de mercadorias que compõe o IC-Br-A tiver seu preço reduzido a partir de um certo patamar para baixo, isto aparentemente não se traduziria em deflação dos alimentos e bebidas (cujos insumos estejam baseados nas mercadorias que compõem este índice), e desta forma isto não apareceria no IPCA. Em valores do índice, pode-se verificar que a partir de 130 para baixo, a inflação não se altera de forma significativa, considerando as bandas de percentis. De 110 para baixo, há até mesmo um pequeno aumento na inflação. Uma hipótese possível para explicar a estabilidade dos preços nesta faixa de variação, é que as empresas envolvidas com estas mercadorias mantêm suas margens de lucro em determinado nível. Assim, mesmo com os preços das *commodities* agrícolas e agropecuárias caindo, elas estariam aumentando suas margens de lucro ao não repassar estes preços para seus produtos finais.

Quando se observa o histórico do IC-Br-A (Figura 6), percebe-se que o índice permaneceu na faixa abaixo da mediana na primeira metade do intervalo e após isto é que sobe acima da mediana. Neste intervalo, segundo a relação funcional encontrada, as empresas que têm seus preços de produtos de alguma forma atrelados às mercadorias agropecuárias, talvez não tenham reajustados seus preços conforme havia a oscilação das mesmas dentro de um certo patamar. Possivelmente apenas a para além da mediana é que passaram a reajustar seus preços e produzir reflexos na inflação.

4.1.4.3. Variação do IC-Br Agropecuária (var.12.icbra.12)

A próxima série, a variação em 12 meses do IC-Br-A e defasada de 12 meses (var.12.icbra.12) tem relação funcional não linear. Está entre as variáveis com impacto intermediário e tem distribuição levemente assimétrica. Esta variável produziu efeitos de mais longo prazo, pois trata-se de uma variação de 12 meses nos preços das mercadorias agropecuárias, tomada com 12 meses de defasagem e que produz efeitos 12 meses à frente, na acumulação da inflação. O que se pode ver é que esta variação do IC-Br-A tende a pressionar a inflação mais para cima do que para baixo, pois a distribuição assimétrica é positiva e os impactos alcançados acima da mediana são maiores em módulo, sendo que os impactos abaixo dela são pequenos e muito mais limitados. Uma mudança na variável, da mediana para o percentil 10, provoca uma diminuição de 0,05% na inflação futura acumulada. Quando isto acontece no lado positivo, indo para o percentil 90, a inflação sofre um acréscimo estimado de cerca de 0,22%. No entanto, em boa parte do intervalo estudado, a relação funcional não pode ser considerada significativa a 5%, considerando as bandas de relação funcional possível entre os modelos estimados. As respostas dos modelos deixam de incluir a resposta mediana apenas próximo ao percentil 90 da variável analisada.

Pela seleção de atributos no *data mining*, os preços das mercadorias parecem ter uma grande relevância para a economia brasileira, uma vez que foram selecionados dois atributos ligados às mercadorias. Pode-se justificar isto pela composição do IC-Br Agropecuária. As mercadorias pesquisadas neste índice impactam diretamente e indiretamente o preço dos alimentos e bebidas, itens de consumo essenciais, o que na sequência produz a inflação dos segmentos de alimentos e bebidas, e que, por sua vez, estão presentes nos itens de mensuração do IPCA. Alterações de preço de algumas mercadorias gerarão inflação de alimentos/bebidas já em pouco tempo nos 12 meses seguintes, o que explica a relevância do nível do IC-Br-A do momento, sem defasagens. Em outros casos, em menor escala (var.12.icbra.12) e predominantemente sem significância, os preços das mercadorias produzirão efeitos mais distantes no tempo, devido, talvez, pelo próprio processo industrial, e se propagarão pela economia como um efeito marginal e adicional sobre a inflação futura.

A relevância de mercadorias agropecuárias se reflete na inflação do segmento de alimentos e bebidas. Conforme observam Martinez & Cerqueira (2013), este

segmento contém componentes que exercem pressão sistemática de alta sobre a inflação, estando entre os segmentos que mais pressionam a inflação. Esta conclusão é coerente com os achados obtidos nas relações funcionais de nível do IC-Br-A (icbra) e da variação do IC-Br-A (var.12.icbra.12).

4.1.4.4. IC-Br Energia (icbre.12)

A variável seguinte trata-se do nível do IC-Br Energia (ou IC-Br-E) medido com defasagem de 12 meses. O que se nota de imediato é que há neste caso uma relação quase linear. Além disso, esta variável tem efeitos assimétricos em relação à mediana.

No intervalo pesquisado, o IC-Br-E produziu efeitos proporcionais de forma quase linear, o que quer dizer que, a mudança de nível para cima nos preços do petróleo, carvão e gás natural, que são *commodities* que compõem este índice, produziu efeitos de forma direta sobre o nível da inflação acumulada. Assim, se as *commodities* de energia subiram, a inflação acompanhou. O sentido desta relação era esperado uma vez que o custo da energia afeta diretamente a produção e distribuição de produtos, bem como afeta o consumidor diretamente, como por exemplo o caso da energia elétrica (p. ex.: via termoeletricas), e que está incluída no IPCA. Como a variável é defasada, seus efeitos se propagaram e apareceram 12 meses à frente de quando o índice foi medido. Outra característica observável é que, pela relação funcional, a variável impacta na maior parte do tempo em valores acima dos 6,15%, ou seja, sua interferência está na maior parte do tempo ligada a pressões para alta da inflação, porém, ao contrário do encontrado para as mercadorias, quedas nos preços das *commodities* de energia que integram este índice parecem ter efeitos efetivamente de queda na inflação, haja vista que a relação tem um aspecto mais linear.

A respeito da significância da relação encontrada, pode-se verificar que na maior parte do intervalo estudado é possível afirmar que ela exista, com base nos percentis traçados. Há uma pequena faixa ao redor da mediana que contempla a resposta mediana. Em todo o resto do intervalo, ou seja, na maior parte do histórico percorrido pela variável, o intervalo entre as bandas não inclui a resposta mediana. Assim, a relação é significativa a 5% (pelos 100 modelos avaliados) neste grande intervalo, e com base nisso, pela resposta do modelo macroeconômico, é possível

afirmar que as redes neurais “concordam” que a mudança de nível do IC-Br-E produziu efeitos sobre a inflação acumulada.

Diante dos achados relativos à relevância das *commodities* agropecuárias e de energia, do ponto de vista da gestão, empresas que tenham sua atuação nas áreas diretamente ou indiretamente relacionada às *commodities* (principalmente as agropecuárias) e conheçam bem seu mercado, podem antever mudanças na economia e se preparar melhor para o cenário futuro. Como são empresas que detém *know-how* do setor, podem até mesmo antecipar preços futuros das *commodities* em questão e trazer indícios de como isso possivelmente irá afetar a inflação futura. Bancos e agências de financiamento também podem utilizar estas informações do mercado de *commodities* de modo a ajustar seus planejamentos quanto à disponibilização e taxação de crédito e analisar como isso irá interferir em suas atividades.

4.1.4.5. Variação do PIB em Dólares (var.12.pibd.12)

Em seguida, passa-se à análise da variação em 12 meses do PIB em dólares e defasada de 12 meses (var.12.pibd.12). A relação funcional encontrada não é linear, como pode-se ver claramente. Entretanto, para 90% dos valores (acima do percentil 10) a relação é praticamente linear. Diferentemente das outras séries, esta variação do PIB parece ter uma pequena assimetria negativa. É possível observar também que a variável teve mais impactos para pressionar do que para reprimir a inflação, tendo em vista que a assimetria é negativa e a magnitude do impacto abaixo da resposta mediana é maior.

Esta variável é intrigante, pois indica que, no intervalo estudado, uma alta em 12 meses no PIB em dólares provocou, de forma geral, efeitos um ano depois que levariam a um decréscimo na inflação acumulada mais 12 meses à frente. Na verdade, o que pode ter ocorrido, é que a seleção de atributos, para evitar a redundância de informações “optou” por “escolher” o PIB em Dólares ao invés de escolher ambos o PIB em Reais e a cotação do Dólar. Parece não fazer sentido que um aumento no PIB em Dólares esteja relacionado a uma queda da inflação, mas isto provavelmente está mais relacionado ao dólar do que ao PIB propriamente dito.

A correlação linear calculada entre a variação do PIB em Dólares em 12 meses e a variação do Dólar em 12 meses para todo o intervalo foi de -0,78 (-0,83 a -0,71,

com intervalo de confiança de 95%). Assim, a justificativa para esta relação aparentemente inesperada se deve provavelmente a uma importância maior creditada ao Dólar. As oscilações significativas do PIB em Dólar foram relevantemente geradas pelas oscilações na cotação do Dólar e não somente pelo PIB. Afinal, cabe lembrar que o PIB em Dólares é originado pelo PIB em Reais, mas cotado em Dólares. Como o algoritmo de seleção de atributos busca selecionar não só as melhores variáveis, mas também a melhor combinação entre elas, o algoritmo provavelmente “optou” por selecionar uma variável que pudesse trazer informações a respeito das outras duas variáveis (PIB em Reais e Dólar), uma vez que havia alta intercorrelação, eliminando assim a redundância de informações. Logo, a leitura da relação funcional deveria ser feita mais em função da variação do Dólar no período do que do PIB em si. Assim, no intervalo de estudo analisado, uma variação positiva no PIB em Dólares, está correlacionada a uma variação negativa na cotação do Dólar e isto teria impactos negativos sobre a inflação. Esta relação, de fato, seria coerente, pois a baixa da moeda americana reduziria o custo de insumos presentes na fabricação de produtos vendidos no país, o que impactaria diretamente em seus preços.

Se as outras variáveis estiverem em suas medianas e var.12.pibd.12 estiver em 10%, teoricamente haveria um deslocamento dos 6,15% para algo em torno de 6,50%. Se var.12.pibd.12 for para 0%, a inflação prevista iria então para quase 7,00%, uma diferença de 0,50%. Porém se a variável de 10% passa a medir 20%, o modelo responde com uma inflação futura de 12 meses estimada de praticamente 6,00%, atingindo uma variação negativa de 0,50% em relação ao ponto dos 10%.

Com relação a significância aparente da relação funcional, pode-se verificar que na maior parte do traçado ela existe. Apenas nos pontos mais próximos da mediana é que a resposta mediana aparece entre as bandas dos percentis. Para além desta faixa de valores as respostas dos modelos se afastam dela, indicando que no geral os modelos “concordam” com a relevância dos efeitos desta série sobre a inflação de 12 meses à frente.

4.1.4.6. Variação do Desemprego (var.12.desemp.6)

A última série analisada, a variação em 12 meses da taxa de desemprego e defasada de 6 meses (var.12.desemp.6) mostra uma relação funcional semelhante à série anterior, com magnitudes semelhantes, embora o intervalo de impacto seja

diferente. Enquanto que a variação do PIB em dólar tinha impacto mais forte para pressionar a inflação, mas também tinha efeitos para baixa-la, a variável ligada ao desemprego exibiu muito pouca influência para alta da inflação e consideravelmente mais pressão pela queda da mesma no futuro. A variável tem assimetria positiva e relação funcional não linear. A interferência desta série se deu principalmente para valores acima da mediana, que, como pode-se notar, pressionaram de modo negativo, baixando consideravelmente a inflação do nível dos 6,15%.

Analisando-se o gráfico pode-se ver que se a variação do desemprego em 12 meses e medida com 6 meses de atraso for negativa, ou seja, aumento de emprego, o impacto sobre a inflação futura seria positivo, mas menor em escala comparado com toda o impacto possível produzido pela variável quando ela se torna maior que zero. Se houver valores positivos na variação do desemprego como medido por esta variável, haveria pressões negativas na inflação. Por exemplo, se esta variação de desemprego esteve na mediana e em outro momento no percentil 10, a diferença de impacto sobre inflação é de menos de 1,00%, ao passo que se a variável passou da mediana para o percentil 90, haveria uma diferença negativa de impacto estimada em mais de 2,00%. Esta relação tem sentido quando se considera que o arcabouço teórico que deu origem às metas de inflação tem a premissa de que a inflação é uma inflação de demanda. Neste caso, o aumento do desemprego, diminuiria a demanda, contribuindo para a queda da inflação. Os efeitos seriam inversos caso houvesse diminuição do desemprego.

A relação inversa entre taxa de inflação e taxa de desemprego, a curva de Phillips, já foi calculada para o Brasil em diversos estudos, neste sentido uma revisão de trabalhos pode ser verificada em Summa R. (2011) e Sachsida, Ribeiro, & Dos Santos (2009). Camargo (2018) verificou a relação entre a inflação de serviços e a taxa de desemprego, através de uma regressão linear simples, para o intervalo de 2003 a 2017. A relação analisada utilizou a taxa de desemprego defasada de 6 meses, a mesma defasagem indicada pela seleção de atributos, embora aqui esteja se considerando não a taxa de desemprego, mas a variação desta taxa em 12 meses. Como resultado o autor obteve um R^2 de 0,5041 e uma relação inversa com coeficiente angular de -0,40, ou seja, um aumento de 1% na taxa de desemprego geraria uma queda de 0,4% na inflação de serviços 6 meses à frente.

A julgar pelas relações funcionais das 100 redes neurais, elas aparentemente podem ser consideradas significantes. Em praticamente toda a faixa de valores, há um deslocamento considerável das bandas de percentis se afastando da resposta mediana, sendo plausível considerar que a resposta à variação do desemprego é diferente da resposta mediana e relevante para produzir efeitos sobre a inflação futura.

4.2. MODELOS HÍBRIDOS

Nesta subseção são apresentados os denominados “modelos híbridos” no qual cada um deles é basicamente o modelo macroeconômico com o acréscimo de uma variável externa na entrada, podendo ser: as expectativas de inflação dos consumidores, o índice de expectativas de renda pessoal e o índice de satisfação com a vida.

4.2.1. Dados

Para os modelos híbridos foram adicionados ao modelo macroeconômico as três variáveis externas, que não diretamente financeiras ou econômicas, conforme já detalhado previamente: a expectativa de inflação dos consumidores (IBRE / FGV), o índice de expectativa de renda pessoal (CNI) e o índice de satisfação com a vida (CNI). Cada uma das variáveis deu origem a um modelo híbrido, para se observar se há algum efeito de cada variável ao se integrar ao modelo macroeconômico. Os dados foram coletados diretamente dos seus fornecedores e mediante consulta aos respectivos sites

A expectativa de inflação dos consumidores refere-se à uma pesquisa em que os consumidores respondem quais são suas expectativas (o valor) para a inflação acumulada para os próximos 12 meses. Esta informação trata-se praticamente da variável dependente deste trabalho.

A expectativa de renda pessoal refere-se a um índice construído mediante uma pesquisa às pessoas cujas respostas indicam em uma escala suas expectativas para suas rendas pessoais para um futuro próximo de 6 meses, baseados nos 6 meses anteriores à pesquisa.

O índice de satisfação com a vida diz respeito a um índice construído a partir de respostas das pessoas, que estão baseadas em uma escala quanto à sua satisfação com suas vidas no momento.

A pesquisa de expectativa de inflação dos consumidores tem periodicidade mensal e é feita desde 2005, podendo ser utilizada no modelo normalmente. O mesmo não ocorre com o índice de expectativa da renda pessoal. A pesquisa que dá origem ao índice foi feita trimestralmente até dezembro/2009, passando a ser mensal a partir de março/2010. Desta forma, valores mensais anteriores a março/2010 para os quais não se tinham medições do índice foram interpolados linearmente entre os valores existentes. O índice de satisfação com a vida tem periodicidade trimestral. Neste caso, da mesma forma, foram feitas interpolações lineares para os meses em que não haviam dados disponíveis.




Figura 12: Variáveis acrescentadas para formar os modelos híbridos

A Figura 12 mostra as três variáveis bem como novamente o IPCA acumulado para 12 meses à frente.

4.2.2. Pré-Processamento

As variáveis dos modelos híbridos passaram da mesma forma por uma normalização max-min para o intervalo $[-1, +1]$. Não houve seleção de atributos de variáveis comportamentais porque o objetivo era avaliar o efeito destas variáveis medidas junto à população quanto ao seu poder preditivo, e porque duas destas variáveis (expectativas de inflação e de renda pessoal) dizem respeito ao futuro, tendo conceitualmente aspectos de previsão ou antecipação de eventos, ao contrário das variáveis macroeconômicas que descrevem apenas o que ocorre ou ocorreu.

O intervalo de previsão é o mesmo do modelo macroeconômico. Como já comentado, o primeiro mês em que há dados para as três variáveis é setembro/2005. Desta forma, todas as estimativas dos modelos híbridos foram calculadas com dados a partir deste mês, inclusive para os dados macroeconômicos que agora passam a se relacionar com as novas variáveis externas incluídas.

4.2.3. Redes Neurais LSTM Híbridas e a Previsão da Inflação

Cada rede neural LSTM híbrida foi então desenhada com base em 7 séries de entrada: as 6 séries macroeconômicas e cada uma das 3 séries adicionadas.

Da mesma maneira como ocorreu com o modelo macroeconômico, foram estimados dinamicamente 10 modelos a cada previsão, e a média entre eles foi considerada a previsão do modelo híbrido. A regra da arquitetura também foi mantida, ou seja, o dobro de células LSTM (14) para a quantidade de variáveis de entrada e um neurônio na saída produzindo as estimativas.

Após ser estimado, obteve-se as previsões do modelo híbrido para o intervalo de interesse. Para que a comparação do poder preditivo pudesse ser feita com base nos mesmos parâmetros frente aos modelos anteriores (modelo macroeconômico, AR(1) e RL), foi necessário estimar novamente os modelos anteriores para que tivessem acesso ao mesmo intervalo de informações, ou seja, os modelos foram estimados a partir de setembro/2005. Assim foi possível verificar com mais exatidão como as previsões se alteraram pela inclusão das expectativas e satisfação com a vida. As previsões dos modelos podem ser verificadas na Figura 13. Na comparação

foi incluída também as expectativas de inflação dos consumidores, uma vez que refletem com muita similaridade o que os modelos tentam prever.






Figura 13: Comparação de previsões com os modelos híbridos

Considerando o período de estimação iniciando em setembro/05, pode-se verificar que as previsões do modelo puramente macroeconômico são semelhantes em seu traçado geral às previsões verificadas anteriormente. Há um início ruim e com o decorrer do tempo o modelo vai capturando melhor o cenário inflacionário. A RL e o AR(1) têm previsões muito parecidas às feitas na comparação anterior.

Pode-se observar que as redes neurais híbridas de forma geral não melhoram o poder preditivo do modelo puramente macroeconômico, pelo contrário, na maior parte dos 20 meses testados, os modelos híbridos produziram previsões com erros maiores do que as do modelo macroeconômico. As previsões das redes neurais híbridas começaram bastante distantes dos valores observados e com o tempo foram se aproximando mais das observações reais, de forma semelhante ao modelo macroeconômico. Até a metade do intervalo de testes, os modelos híbridos erraram visivelmente mais, já a partir da metade não é possível observar contribuições significativas ao modelo anterior. Considerando apenas estas características visuais, o resultado preditivo no intervalo estudado indica que a combinação das expectativas de inflação dos consumidores, expectativas de renda pessoal e grau de satisfação com a vida junto às variáveis macroeconômicas não melhoraram a previsão para a inflação acumulada para 12 meses futuros.

Visualmente também pode-se constatar que a série de expectativas de inflação dos consumidores não parece exibir algum poder preditivo. As expectativas ficam distantes dos valores realizados e os erros de previsão são bastante perceptíveis sendo semelhantes aos erros da regressão linear.

A Tabela 3 mostra a comparação por métricas e testes confrontando o modelo híbrido com os modelos anteriores. Por razões de espaço e relevância, foi excluída da comparação a regressão linear.

Os resultados mais importantes da tabela foram destacados. Dentre eles pode-se verificar que a rede neural macroeconômica (RNM) tem poder preditivo superior a todos os modelos híbridos, com significâncias variadas, porém relevantes. O modelo puramente macroeconômico tende a ter mais capacidade preditiva do que com a inclusão das expectativas e satisfação com a vida.

Em relação ao AR(1), observa-se que neste intervalo de estimação iniciado em setembro/2005, percebe-se que a superioridade da rede neural macroeconômica sobre o AR(1), medida pela diferença entre os RMSE, piorou um pouco, uma vez que

os RMSE ficaram mais próximos neste intervalo de estimação menor. Já em relação ao teste não houve alteração neste quesito. Nenhum outro modelo consegue ter melhor poder preditivo sobre o AR(1), do que a RNM. As previsões do modelo AR(1) foram superiores às dos modelos híbridos, conforme os *p-values* dos testes.

Modelos		AR(1)	Exp. Con.	RNM	RNH (exp. con)	RNH (exp. rp)	RNH (isv)
RMSE		0,0248	0,0589	0,0191	0,0303	0,0317	0,0280
AR(1)	<i>p-value</i>	-	0,000	1,000	0,000	0,000	0,001
Exp. Con.	<i>p-value</i>	1,000	-	1,000	1,000	1,000	1,000
RNM	<i>p-value</i>	0,000	0,000	-	0,000	0,000	0,000
RNH (exp. con)	<i>p-value</i>	1,000	0,000	1,000	-	0,095	0,958
RNH (exp. rp)	<i>p-value</i>	1,000	0,000	1,000	0,908	-	0,994
RNH (isv)	<i>p-value</i>	0,999	0,000	1,000	0,045	0,006	-

Tabela 3: Métricas de comparação com os modelos híbridos

Outro resultado bastante claro é o fato de as expectativas de inflação dos consumidores serem superados em poder preditivo por todos os modelos da tabela e com significância bastante clara. Isto mostra que no intervalo estudado, qualquer destes modelos seria melhor para prever a inflação do que as expectativas de inflação medidas perante à população. O único modelo que tem capacidade semelhante às expectativas é a regressão linear, que não aparece na comparação.

Entre os modelos híbridos, pode-se verificar que a precisão do modelo que incorpora as expectativas de inflação dos consumidores (RNH exp.con) é maior (com significância a 10%) do que o que inclui as expectativas de renda (RNH exp.rp). A rede neural que incorpora o índice de satisfação com a vida (RNH isv) tem capacidade preditiva superior aos dois outros modelos híbridos em ambos os testes. Ela é superior a RNH exp.con, significativa a 5%, e tem maior acurácia também em relação à RNH exp.rp, com significância de 1%.

Embora os modelos híbridos tenham conseguido ficar mais próximo das observações reais do que o AR(1) mais na segunda metade do intervalo estudado, os erros de grande magnitude cometidos no início do período impactaram muito o RMSE e contribuíram para que tivessem resultados inferiores nos testes. Observa-se que os RMSE de todos os modelos híbridos foram superiores ao do AR(1).

Desta forma, alcança-se mais um resultado e objetivos específicos da pesquisa, ao se verificar que não há evidências, dentro do contexto do estudo, de que as expectativas ou a satisfação com a vida melhorariam a previsão da inflação de 12 meses do modelo macroeconômico. Pelo contrário, a adição de tais variáveis traria prejuízo à acurácia do modelo.

4.2.4. Relações Funcionais das Variáveis Macroeconômicas

Da mesma forma como foi feito para o modelo macroeconômico, foram traçadas as relações funcionais para cada uma das variáveis dos modelos híbridos, sendo estimadas do mesmo modo 100 redes neurais para cada um. Conforme verifica-se na sequência, houve algumas mudanças nas relações funcionais das séries macroeconômicas que integravam o modelo anterior.

Para comparar as relações funcionais do modelo macroeconômico com as produzidas por cada um dos modelos híbridos, foram antepostas no gráfico as relações funcionais equivalentes do modelo macroeconômico (em azul claro). Outra diferença introduzida na visualização das relações funcionais dos modelos híbridos é que as relações foram centralizadas (eixo y) na “resposta mediana”, que é a resposta do modelo para quando todas as variáveis estão nas medianas. Isto facilita a comparação entre o modelo macroeconômico e a alteração produzida por cada modelo híbrido e permite visualizar melhor o grau do impacto sobre a inflação. A desvantagem desta análise é que se perde o nível em que a resposta mediana se encontra. De qualquer forma cabe informar que a resposta do modelo quando todas as variáveis estão nas medianas se alterou um pouco, indo dos 6,15% do modelo macroeconômico para algo próximo a 5,95%, 6,25% e 6,18%, respectivamente aos modelos híbridos com as expectativas de inflação (RNH exp.con), com as expectativas de renda pessoal (RNH exp.rp) e com a satisfação com a vida (RNH isv).

4.2.4.1. Variação do IC-Br (var.1.icbr)

A Figura 14 mostra a relação funcional da variação do IC-Br nos modelos híbridos. A série var.1.icbr teve sua relação ligeiramente alterada, porém mantendo seu baixo impacto e seu traçado médio muito próximo a do modelo, ou seja, a maneira com que a variação do IC-Br interfere na inflação futura, deslocando-a da resposta mediana, como a pressiona, não mudou muito quando há o acréscimo das variáveis

externas. Outro fato que chama a atenção é a manutenção do erro considerável ao redor da relação funcional, ou seja, a largura das bandas de percentis melhorou um pouco, mas de modo geral sofreu pouca interferência significativa. A dispersão do traçado produzido pelos 100 modelos, ainda mostra que esta relação funcional não pode ser considerada significativa. A resposta mediana (centralizada em 0%) nos modelos híbridos está incluída no intervalo de 95% das bandas em mais de 80% dos valores possíveis assumidos pela variável analisada.




Figura 14: Relações funcionais (*var.1.icbr*) dos modelos híbridos

4.2.4.2. IC-Br Agropecuária (*icbra*)

Para o nível do IC-Br-A (*icbra*), Figura 15, o impacto manteve-se muito similar, tendo pequenas alterações no formato do relacionamento. A dispersão da relação funcional apontada pelos 100 modelos macroeconômicos era ligeiramente mais alta, e a inclusão das variáveis comportamentais fez com que a significância da relação aumentasse muito pouco, ou seja, as bandas de percentis ficaram mais estreitas, embora isto seja mais perceptível a partir do percentil 90. Novamente, é possível constatar que a inclusão das expectativas da inflação, da renda pessoal e satisfação com a vida não foram capazes de influenciar a maneira como o IC-Br Agropecuário se relaciona com a inflação de 12 meses à frente. Esta variável novamente se mostrou relevante para a inflação de 12 meses.

RNH (exp.con) RNH (exp.rp) RNH (isv)




Figura 15: Relações funcionais (icbra) dos modelos híbridos

4.2.4.3. Variação do IC-Br Agropecuária (var.12.icbra.12)

Para a variação do IC-Br-A (var.12.icbra.12) (Figura 16) as alterações foram distintas. De modo geral, da mediana para frente, o impacto continuou positivo, tendo pequenas alterações no formato do relacionamento, mas mantendo aproximadamente a mesma escala. A significância dada pelas bandas aparentemente também não trouxe grandes novidades considerando valores acima da mediana. A mudança mais significativa está da mediana para baixo. Na RNH exp.con e na RNH isv as relações nesta faixa são parecidas com pequenas alterações irrelevantes. A dispersão entre modelos novamente foi bastante grande indicando a irrelevância desta relação funcional nesta faixa. Para a RNH exp.rp, ao contrário do encontrado na rede neural puramente macroeconômica, a influência desta variável agora está positiva, na medida em que variações do IC-Br-A menores levariam a patamares de inflação acumulada maiores. Também cabe analisar que da mediana para baixo a dispersão da relação funcional verificada pelos 100 modelos macroeconômicos era alta, e a inclusão das expectativas de renda não foi capaz de alterar isso, ou seja, embora esta variável tenha alterado o traçado da relação, a dispersão entre modelos manteve-se, não sendo possível afirmar que houve de fato alguma alteração significativa, podendo isto ser apenas fruto do acaso. Ao se analisar a resposta mediana, pode-se verificar que apenas em valores mais distantes é que a variação do IC-Br-A produz impacto significativamente diferente da resposta mediana, uma característica que já estava presente na relação funcional do modelo macroeconômico.

RNH (exp.con)

RNH (exp.rp)

RNH (isv)




Figura 16: Relações funcionais (var.12.icbra.12) dos modelos híbridos

4.2.4.4. IC-Br Energia (icbre.12)

Para o IC-Br-E defasado 12 meses (icbre.12), na Figura 17, houve pequenas alterações, mas nada que pudesse ser observado de forma significativa. A amplitude da escala manteve-se parecida e a relação funcional continuou positivamente crescente, indicando que, mesmo com a adição das séries comportamentais, uma alta nas commodities de energia impacta positivamente em um aumento na inflação acumulada futura. Uma pequena alteração pode ser verificada com relação ao tipo de relação funcional da RNH exp.con, uma vez que antes ela se apresentava de forma praticamente linear, e agora mostra-se suavemente não-linear.




Figura 17: Relações funcionais (icbre.12) dos modelos híbridos

Como a largura das bandas dos modelos praticamente se manteve (com exceção de um estreitamento em valores mais altos na RNH exp.con), a faixa entre as bandas ao redor da mediana que inclui a resposta mediana também se manteve. Assim, aparentemente a inclusão das séries de expectativa e satisfação com a vida não trouxe resultados positivos que modificassem a relevância do nível de preços das commodities de energia para a dinâmica inflacionária futura. Assim, o nível do IC-Br-E manteve-se relevante tal como estava no modelo macroeconômico.

4.2.4.5. Variação do PIB em Dólares (var.12.pibd.12)

No caso da variação do PIB em dólares (var.12.pibd.12) da Figura 18, a relação funcional se manteve com poucas alterações quando se considera valores acima de primeiro decil, tanto em escala quanto no formato, bem como na significância dada pelo intervalo de 95% dos percentis. A mudança mais significativa está antes do primeiro decil, no qual a introdução das expectativas e satisfação com a vida provocou uma pequena redução no impacto da variável para os casos da RNH exp.rp e RNH isv. No entanto, como se trata de valores abaixo do percentil 10 e há ainda uma abertura das bandas, aumentando a incerteza sobre a relevância da variável neste intervalo, é possível afirmar novamente que as séries adicionadas não tiveram efeito relevante sobre o relacionamento entre a variação do PIB em dólares e a variável dependente.




Figura 18: Relações funcionais (var.12.pibd.12) dos modelos híbridos

4.2.4.6. Variação do Desemprego (var.12.desemp.6)

A relação funcional da variação do desemprego (var.12.desemp.6), na Figura 19, permaneceu praticamente inalterada, mantendo-se tanto a escala do impacto quanto a significância baseada nas bandas formadas pelos 100 modelos híbridos. Neste caso, assim como ocorreu na maioria das variáveis anteriores, não parece haver evidências de que a adição das variáveis externas tenha trazido informações relevantes a ponto de modificar a relação desta variável com a inflação.




Figura 19: Relações funcionais (var.12.desemp.6) dos modelos híbridos

A julgar apenas pelas relações funcionais das variáveis macroeconômicas dos modelos híbridos, o que se pode notar é que, dada a introdução das séries de expectativas e satisfação com a vida, houve pouca ou nenhuma melhora na precisão (diminuição da distância entre as bandas) da relação funcional de algumas variáveis e poucas alterações no impacto que cada variável causa na inflação acumulada para 12 meses futuros. Assim, do ponto de vista do *machine learning* estas variáveis adicionadas, de forma geral, não aperfeiçoaram ou modificaram a relação da maioria das variáveis macroeconômicas. Este resultado já poderia ser esperado, uma vez que a introdução das expectativas de inflação, renda e satisfação com a vida piorou o poder preditivo no intervalo analisado anteriormente, conforme as conclusões estatísticas da Tabela 3.

Se este foi o caso, o que pode ter ocorrido é que a inclusão daquelas variáveis em seu estado puro (sem diferenciações, defasagens, etc.) contribuiu mais para “confundir” a rede do que ajudar. É certo que quando se tem informação inútil na entrada do modelo, isto pode atrapalhar o “aprendizado” da rede tornando-o mais demorado ou até impossibilitá-lo de acontecer.

4.2.5. Relação Funcional das Expectativas de Inflação dos Consumidores

Passando a análise das relações funcionais para as séries de expectativas e satisfação com a vida, pode-se observar que a relação funcional das expectativas do consumidor no modelo RNH exp.con mostra uma grande divergência no poder explicativo desta variável dentre os 100 modelos estimados em cada ponto da variável, conforme a Figura 20.




Figura 20: Relação funcional das expectativas de inflação dos consumidores

Observa-se que as linhas dos percentis (2,5 e 97,5) aparecem demonstrando uma dispersão muito grande. Esta dispersão mostra que a relevância das expectativas dos consumidores não é clara, ou na verdade, não existe. Da mediana para baixo, a série não mostra relação funcional significativamente diferente da resposta mediana. Acima da mediana, apenas uma faixa fica diferente da resposta mediana, mas de maneira bastante sutil, ainda mais se for considerada a escala do gráfico.

A julgar pela escala, pode-se dizer que o impacto da expectativa do consumidor como fator explicativo é muito pequeno, ao contrário, por exemplo, do IC-Br-A, que não só tem impacto mais relevante, mas menos dispersão entre os modelos, e pouca diferença entre o modelo macroeconômico e híbrido. Logo, no caso das expectativas de inflação, o tipo da relação funcional não só é incerto como o efeito que a variável causa não é significativo.

A despeito das características encontradas acima, verifica-se outros aspectos na relação funcional. Nota-se que as expectativas dos consumidores têm assimetria positiva e o formato da relação funcional quase linear, com valores abaixo da mediana produzindo menos impacto do que a outra metade dos valores. Há relacionamento inverso com a variável dependente, ou seja, conforme crescem as expectativas a inflação futura realizada tenderia a cair. Considerando as premissas da hipótese das

expectativas racionais, este resultado não lhes é condizente. Relembrando o que já foi descrito, a hipótese sugere que os indivíduos não são apenas seres passivos, mas sim racionais e capazes de se antecipar. Mikolajek-Gocejna (2014), sobre esta hipótese, descreve que um indivíduo formaria suas expectativas e previsões usando todas as informações possíveis e inclusive agiriam como se conhecessem o modelo de previsão das variáveis. Assim, os erros realizados seriam aleatórios (em média seria zero), não sistemáticos (as pessoas aprenderiam com seus erros) e as expectativas como um todo teriam seu valor preditivo correto. Neste mesmo sentido, conforme citado anteriormente as “expectativas racionais são idênticas às previsões produzidas pelo modelo macroeconômico no qual as expectativas são usadas [...]” (Brayton, Mauskopf, Reifschneider, Tinsley, & Williams, 1997, p. 228). Se as premissas das expectativas racionais estivessem presentes, a relação funcional das expectativas de inflação dos consumidores estaria diretamente e proporcionalmente relacionada à inflação realizada. O impacto seria grande e seriam esperadas bandas de percentis pequenas e estáveis ao redor da linha média por todo o intervalo de valores analisado. Apesar disso, nenhum destes aspectos apareceu. Desta forma, como já comentado, estando os níveis de impacto reduzidos (e de forma invertida) e dada a grande variabilidade dessa relação funcional, há grande possibilidade desta relação funcional revelada ter sido obtida apenas ao acaso. Assim, em suma, ao que tudo indica as expectativas de inflação dos consumidores não são relevantes para explicar a taxa de IPCA acumulada realizada nos 12 meses futuros, ou seja, não se pode dizer que tenham algum poder preditivo.

4.2.6. Relação Funcional do Índice de Expectativa de Renda Pessoal

Analisando a relação funcional do índice de expectativa de renda pessoal (RNH exp.rp) na Figura 21, percebe-se inicialmente uma assimetria negativa nos valores. Há relação evidentemente não-linear e inversamente proporcional na maior parte do intervalo, além de significância maior do que a percebida na série das expectativas de inflação, com dispersão que vai se acentuando conforme os valores vão se afastando da mediana em direção ao primeiro decil.

Considerando a resposta mediana, valores acima da mediana são razoavelmente significantes, uma vez que há uma faixa de valores que está contida nas bandas, o que põe em dúvida a relevância da variável neste pequeno intervalo.

Para valores abaixo da mediana, da mesma forma, exceto por um pequeno intervalo, os valores são significantes para se diferenciar da resposta mediana pelo menos até o percentil 10. De forma geral, considerando principalmente intervalos mais comuns de posicionamento da variável, é possível afirmar que existe uma razoável relação inversa entre o índice de expectativa de renda pessoal e a inflação de 12 meses futura.




Figura 21: Relação funcional do índice de expectativa de renda pessoal

Outra característica que se pode notar é a magnitude do impacto. Observa-se que as expectativas de renda pessoal produzem um efeito com alguma relevância, mas não de forma que possa se destacar, ainda mais quando se compara com os impactos das variáveis macroeconômicas.

Como a relação funcional verificada na maior parte do tempo foi inversamente proporcional, quanto maior for o índice de expectativa de renda pessoal, menor será sua contribuição como explicação para a inflação acumulada futura (embora esta relação seja mais significativa aparentemente para valores acima da mediana). Este fato vai de encontro ao que se imaginava. Se as pessoas esperam que suas rendas aumentem nos próximos meses, a princípio seria razoável esperar que aumentassem seu consumo e produzissem efeitos na inflação, ou seja, gerassem alguma inflação de demanda. Pelo menos duas hipóteses podem ser levantadas na tentativa de explicar este resultado.

Primeiramente, é possível supor que isto deve-se simplesmente pelo forte efeito de correlação entre expectativas de renda e expectativas de inflação (ver mais adiante a correlação igual a $-0,848$) combinado à uma dominação dos efeitos das expectativas de inflação sobre as expectativas de renda pessoal. Esta dominação é uma questão que precisa ser verificada empiricamente, tal como a encontrada no trabalho de Ito & Kaihatsu (2016) já citado anteriormente. Assim, no mesmo momento em que há uma expectativa de inflação alta, as expectativas de renda colhidas da população seriam baixas. Junto a isso, a hipótese é que as expectativas de inflação dominem as expectativas de renda, ou seja, o efeito líquido pertenceria às expectativas de inflação. Assim, seguindo a teoria, pela substituição intertemporal, haveria aumento do consumo, de onde um aumento de preços poderia vir de fato a se concretizar. Desta forma, a relação funcional exibida poderia não ser exatamente da expectativa de renda, mas de uma relação de combinação entre a expectativa de inflação correlacionada à – e dominando – expectativa de renda. Assim, o movimento medido pela rede neural na realidade estaria relacionando essa combinação com a inflação futura, ou seja, movimentos à esquerda na relação funcional, diminuindo a expectativa de renda, poderiam ser entendidos como movimentos de alta nas expectativas de inflação. Isto ajudaria a explicar a relação funcional encontrada naquele formato, embora a relação funcional isolada das expectativas de inflação não pareça produzir efeitos relevantes sobre a variável dependente.

Esta interação na verdade não se limita às expectativas de inflação, como poderá ser visto mais à frente, pois as expectativas de renda também estão correlacionadas a variáveis macroeconômicas. Desta forma, as expectativas de renda em si podem não ter efeito preditivo de fato sobre a inflação, mas podem ser na realidade só um produto das variáveis macroeconômicas sobre as pessoas e de suas opiniões sobre a inflação futura.

Outra hipótese para explicar a relação funcional encontrada é o simples fato de que a variável represente meramente “expectativas”. As expectativas de renda podem simplesmente não refletir de fato o que ocorre quanto ao comportamento do consumidor, seja por ele não agir conforme sua expectativa ou porque as pessoas podem estar incrivelmente erradas quanto as suas opiniões futuras sobre suas rendas e, desta forma, agir de forma contrária às suas expectativas formadas anteriormente. Por exemplo: as pessoas podem esperar que suas rendas aumentem, mas na prática:

1) elas não aumentam seu consumo por causa disso ou, 2) simplesmente estão quase sempre erradas e na verdade as rendas não aumentam (ou até diminuem) e elas acabam conseqüentemente não aumentando seu nível de consumo. Assim, nesta segunda hipótese, o aumento da expectativa de renda para à direita na relação funcional poderia levar na verdade a uma estabilidade ou até diminuição do consumo, e isto, ajudaria a esclarecer melhor a relação funcional encontrada.

4.2.7. Relação Funcional do Índice de Satisfação com a Vida

Para o índice satisfação com a vida (RNH isv) na Figura 22, é inegável a semelhança com a relação funcional das expectativas de renda. Esta semelhança de certa forma poderia ser esperada, haja vista a similaridade visual entre as duas séries temporais na Figura 12. De toda forma, cabe analisar que existe uma relação não linear, semelhante a uma parábola com concavidade para baixo e, comparativamente à relação funcional das expectativas de renda, há uma dispersão maior entre os modelos, verificada pela largura entre as bandas que envolvem os valores médios. Considerando a resposta mediana, a relação funcional passa a mostrar impactos significativamente diferentes apenas quando se aproxima do nono decil e após uma pequena faixa abaixo da mediana, de maneira mais dispersa, mas semelhante à relação funcional do índice de expectativa de renda pessoal.




Figura 22: Relação funcional do índice de satisfação com a vida

Há ainda assimetria negativa e impacto pequeno se comparado às relações funcionais das variáveis macroeconômicas. O formato do efeito explicativo desta variável é irregular. A faixa que abrange a maior parte dos valores, mostra uma relação inversa, ou seja, conforme o índice de satisfação com a vida assume valores mais altos, a estimativa para inflação decresce. Da mediana para baixo o efeito é, na verdade, misto, havendo relação inversa sobre o nível de inflação até a metade do intervalo entre mediana e percentil 10. A partir daí a relação se inverte, de forma que níveis cada vez mais baixos de satisfação com a vida levariam a níveis acumulados de inflação menores.

Entretanto, reitera-se que considerando a magnitude dos impactos e a dispersão nos vários modelos, o efeito desta variável é duvidoso conforme os valores vão se afastando da mediana para baixo. De qualquer forma, o resultado encontrado indica que na maior parte do tempo (algo em torno de 70%) uma elevação na satisfação com a vida diminuiria a estimativa para a taxa de inflação dos 12 meses seguintes. Ainda que não haja aparente significância em boa parte da relação funcional, uma parte considerável da satisfação com a vida tem relação inversa com a inflação futura. Estes resultados estão de certa forma de acordo com os achados de Guven (2012). Embora o termo principal utilizado pelo autor tenha sido “felicidade”, a

“satisfação com a vida” também aparece de modo intercambiável neste e em outros trabalhos como sinônimo de “felicidade”. Conforme os achados de Guven (2012), pessoas mais felizes controlam melhor seus gastos, esperam inflação menor, o que as faz consumirem menos. A maior parte da relação funcional aqui encontrada retrata resultados neste mesmo sentido.

4.2.8. Outros Achados e Discussões

Com o desenvolvimento do trabalho até este ponto, novas hipóteses foram levantadas em consequência dos resultados das etapas anteriores, os quais já contemplavam os objetivos principais do estudo. Entretanto, novos achados surgiram, fruto da investigação dos questionamentos levantados com base nas conclusões encontradas nas subseções anteriores e que poderiam esclarecer melhor os resultados encontrados anteriormente. Estes questionamentos e respostas foram discutidos conforme se segue.

4.2.8.1. Formação das Expectativas de Inflação dos Consumidores

Em uma análise mais cautelosa sobre as expectativas de inflação dos consumidores pode-se aventar que os consumidores têm expectativas que talvez possam ser melhor explicadas pela hipótese das expectativas adaptativas. Cabe lembrar que nesta hipótese as expectativas de preços futuros dependem das expectativas de preços hoje e dos erros de previsão anteriores (Mikolajek-Gocejna, 2014). Conforme conceituado por Brayton, Mauskopf, Reifschneider, Tinsley, & Williams (1997, p. 228): “Expectativas adaptativas dependem apenas de observações passadas [...]”.

A partir disso, na Figura 23 pode-se observar as expectativas de inflação dos consumidores desde setembro/2005 até maio/2017. Cabe lembrar que estas expectativas foram tomadas visando um horizonte temporal de 12 meses. Assim, os consumidores expressaram suas opiniões para a inflação acumulada para os 12 meses seguintes. Cada ponto reflete o que os consumidores esperavam em média em determinado mês (eixo x) para a inflação futura. Para contrastar com as expectativas, foi colocado também o gráfico da taxa de inflação (IPCA) de 12 meses até o mês em que cada dado de expectativa foi tomado. Pode-se notar com clareza que os traçados das séries temporais são semelhantes em alguns aspectos,

obviamente com diferenças em termos de magnitude e forma. No entanto, não se pode deixar de observar que os movimentos de uma série são bastante semelhantes aos da outra. É possível sugerir que as expectativas de inflação dos consumidores tendem de alguma forma a “andar” de modo semelhante ao que ocorre com a inflação no passado recente ou ao que ocorre na inflação no momento.

Como o IPCA para determinado mês é divulgado após a pesquisa de expectativas para este mesmo mês, então a relação entre expectativas e inflação acumulada pode ser até mais forte com a inflação defasada de 1 ou 2 meses, uma vez que estas são as informações que estariam disponíveis aos consumidores no momento de externar suas expectativas.

Assim, foi calculada a correlação linear entre expectativas de inflação dos consumidores e as séries do IPCA acumulado sem defasagem e com defasagens de 1, 2 e 6 meses, cujos valores estão apresentados na Tabela 4:




Figura 23: Expectativas de inflação dos consumidores versus IPCA Acumulado 12 Meses

Correlação das expectativas de inflação do consumidor com:	Correlação
IPCA 12 meses	0,883
IPCA 12 meses, defasado 1 mês	0,913
IPCA 12 meses, defasado 2 meses	0,923
IPCA 12 meses, defasado 6 meses	0,844

Tabela 4: Correlação entre expectativas dos consumidores e IPCA acumulado




Figura 24: Scatterplot entre expectativas de inflação e variáveis

A Figura 24 mostra de maneira visual como as variáveis se relacionam.

Pelas correlações apresentadas constata-se que de fato há uma estreita relação entre a inflação acumulada passada e as opiniões emitidas pelos consumidores. Em especial, a correlação com a inflação acumulada defasada de 2

meses não só é alta como é a maior correlação encontrada dentre todas as 361 variáveis disponíveis na seleção de atributos do modelo macroeconômico.

Indo mais além, pode-se verificar através do teste de causalidade de Granger se a inflação acumulada Granger-cause as expectativas dos consumidores (teste de precedência temporal). As séries são possivelmente não-estacionárias, o que pode ser verificado aplicando o teste KPSS. Ao aplicá-lo, como resultado verificou-se que, de fato, rejeita-se a hipótese de estacionariedade (a 1%), motivo pelo qual procedeu-se a uma primeira diferenciação. Já com as séries diferenciadas, novamente efetuou-se o teste KPSS, cujos resultados indicaram que não se pode rejeitar a estacionariedade nem a 10%. Desta forma, foram utilizadas as séries, uma vez diferenciadas, no teste de causalidade de Granger, obtendo-se os resultados da Tabela 5. Para o teste foram consideradas 6 defasagens, por conta das altas correlações encontradas anteriormente até esta defasagem:

Hipótese Nula	Estatística F	p-value
IPCA não Granger-cause EXPECTATIVAS DE INFLAÇÃO DOS CONSUMIDORES	6,1528	0,000
EXPECTATIVAS DE INFLAÇÃO DOS CONSUMIDORES não Granger-cause IPCA	1,1682	0,324

Tabela 5: Teste de causalidade de Granger

O teste rejeita a hipótese de não-causalidade de Granger do IPCA passado sobre as expectativas de inflação dos consumidores no presente e, ao mesmo tempo, não se pode rejeitar a hipótese de não-causalidade de Granger para o caso reverso. Em outras palavras, há um indicativo de que variações no IPCA de 12 meses causam – no sentido de Granger – variações nas expectativas de inflação.

Diante de todo o exposto até este ponto nesta seção, é plausível que muitos consumidores emitam suas opiniões baseadas no histórico recente (de um, dois ou mais meses atrás) da inflação. O resultado encontrado aqui reforça o que disse Summa R. (2011, p. 180), no qual, com base em vários estudos citados, afirmou que: “[...] as expectativas inflacionárias não se descolam da inflação passada [...]”. Este fato também é condizente com Teixeira, De Oliveira & Ferreira (2017, p. 519): “[...] parece claro que consumidores geram suas expectativas para doze meses à frente apenas olhando os níveis de inflação que eles estão vivenciando [...]”

Voltando a análise agora para a questão da racionalidade das expectativas formadas, dentro dos pressupostos das expectativas racionais, a presença de um viés (para cima ou para baixo) viola a hipótese das expectativas racionais. Desta forma, pode-se proceder a um teste para verificar se os erros de previsão das expectativas são significativamente diferentes de zero.

Os dados mostram que a média dos erros¹⁶ das expectativas foi de 1,41%, ou seja, há a presença de um viés positivo. As expectativas de inflação dos consumidores geralmente ficam acima da inflação de 12 meses realmente observada. Corroborando isto pelo teste t, rejeitou-se a hipótese nula de que a média dos erros seja zero, com significância estatística a 1%. Desta forma, viola-se esta premissa da hipótese das expectativas racionais, uma vez que a média dos erros das expectativas não totalizam zero, havendo um viés sistemático ao longo do histórico de previsões.

Conforme explica Guillén (2008, p. 24), embora a presença do viés já inviabilize a hipótese das expectativas racionais, é possível testar também se toda a informação existente na formação das expectativas é utilizada, que é um dos pressupostos da hipótese das expectativas racionais. Desta forma, obviamente como não se pode testar toda a informação disponível, pode-se focar simplesmente nas próprias expectativas como fator explicativo para prever os erros delas mesmas. Se isto ocorrer, há uma nova violação da hipótese das expectativas racionais, uma vez que as expectativas dos consumidores já bastariam para reduzir os erros de previsão delas próprias, não havendo, desta forma, o uso completo de toda a informação. Esta suposta violação pode ser verificada pela seguinte regressão:

$$\text{erros de previsão} = \beta_0 + \beta_1 \cdot \text{expectativas} \quad (1)$$

Procedendo à regressão mencionada, para o caso em estudo, os valores de β_0 e β_1 foram -0,059 e 1,019, respectivamente, e ambos estatisticamente significantes a 0,1%. Isto é, as próprias expectativas dos consumidores ajudam a explicar os erros de previsão, o que poderia ser usado para diminuí-los. Como isto não acontece, pode-se observar então que não é toda a informação que é utilizada, ampliando as violações à hipótese das expectativas racionais e reforçando a ideia de que os erros são sistemáticos.

Diante disso, dentro das limitações deste estudo, não é possível caracterizar as expectativas dos consumidores para a inflação de 12 meses como sendo

¹⁶ erros = expectativas – inflação realizada

expectativas condizentes com os pressupostos da hipótese das expectativas racionais, além do que as expectativas de inflação não se mostraram com poder explicativo para a inflação futura e estão, aparentemente, fortemente vinculadas à inflação recente observada. Assim, as expectativas de inflação dos consumidores poderiam então talvez serem melhor explicadas pela hipótese das expectativas adaptativas.

Embora, aparentemente as expectativas de inflação estejam mais próximas da hipótese das expectativas adaptativas, caberia analisar se isto é procedente de fato. De modo bastante simples, para a inflação estudada nesta pesquisa, pode-se representar o que esta hipótese defende pela seguinte equação:

$$\pi_t^e = b.\pi_t + (1 - b).\pi_{t-12}^e, \quad (2)$$

onde π^e refere-se à expectativa de inflação para os próximos 12 meses tomada no tempo t ou $t - 12$ (meses), π_t refere-se à taxa de inflação de 12 meses de fato realizada no tempo t , e b é o coeficiente das expectativas, ou seja, o coeficiente que revisa as expectativas, geralmente assumido como um valor entre 0 e 1. Assim, por esta equação, a hipótese das expectativas adaptativas diz que a expectativa para a inflação futura é igual a uma fração da inflação realizada mais uma parte da expectativa passada, ou, em outras palavras, é igual a expectativa passada mais um ajuste sobre o erro cometido entre o que se esperava para a inflação no passado e o que de fato foi observado.

Efetuuou-se então a regressão mencionada sobre os dados existentes, obtendo-se a seguinte função, com b estatisticamente significativa a 0,1% e R^2 de 0,63:

$$\pi_t^e = 0,49.\pi_t + 0,51.\pi_{t-12}^e \quad (3)$$

Portanto, aparentemente uma boa parte explicativa da formação das expectativas de inflação dos consumidores poderia estar baseada aproximadamente em uma média entre a inflação realizada e a expectativa que havia para a inflação.

Estendendo um pouco a análise, conforme Guillén (2008, p. 29), para atender aos pressupostos da hipótese das expectativas adaptativas, as expectativas deveriam ser explicadas apenas por valores defasados da variável de interesse (inflação). Desta forma, se forem incluídas, por exemplo, outras variáveis explicativas macroeconômicas e estas forem significantes, a hipótese das expectativas adaptativas estaria violada.

Diante disso, procedeu-se a uma regressão simples para avaliar se este seria o caso. Como “inflação passada” considerou-se as defasagens de 1, 2 e 6 meses (conforme correlações analisadas). Para as variáveis macroeconômicas, optou-se por variáveis que são fáceis de perceber pelo consumidor, seja pela média ou no seu dia-a-dia: a taxa de desemprego defasada de 1 mês e a cotação do dólar defasada de 1 mês. Assim, chegou-se na seguinte função a ser regredida (com valores normalizados):

$$\pi_t^e = A + B.\pi_{t-1} + C.\pi_{t-2} + D.\pi_{t-6} + E.Desemprego_{t-1} + F.ln(Dólar_{t-1}) \quad (4)$$

A Tabela 6 mostra os coeficientes e estatísticas encontrados. A regressão apresentou um R^2 de 0,94.

Pelos resultados, pode-se verificar que existem confirmações em favor da hipótese das expectativas adaptativas, haja vista que os coeficientes B e D (baseados na inflação passada) são significantes. Como as variáveis estão normalizadas, dentre as variáveis selecionadas, a variável mais sensível para provocar alterações nas expectativas é a inflação defasada de 1 mês (coeficiente B), porque é o coeficiente com a maior magnitude. Com as significâncias dos coeficientes B e D (e A do intercepto) e o alto R^2 poderia se caminhar na direção de não se poder negar a hipótese das expectativas adaptativas.

Coeficiente	Valor	t	p-value
A	0,30	9,98	0,000 ***
B	1,06	5,86	0,000 ***
C	-0,18	-0,77	0,440
D	0,17	2,01	0,046 *
E	0,11	4,62	0,000 ***
F	0,23	7,95	0,000 ***

Tabela 6: Resultado da regressão para expectativas de inflação

No entanto, ambos os coeficientes E e F também são significantes. Embora suas magnitudes sejam menores do que o coeficiente B, estão na escala dos demais coeficientes. Isso implica que variáveis macroeconômicas também explicam a formação das expectativas, ou seja, elas não seriam formadas apenas pelo passado da própria inflação de 12 meses. Desta forma, embora haja um grande poder explicativo da inflação passada para a formação das expectativas, principalmente da

inflação conhecida mais recente (dada pela causalidade de Granger e pela magnitude principalmente do coeficiente B), existem dados informacionais que vão além do conhecimento único sobre a inflação. Assim, a suposição de que a formação das expectativas utilizada neste estudo poderia ser explicada pela hipótese das expectativas adaptativas não foi confirmada. Portanto, ambas as hipóteses, racionais e adaptativas, foram rejeitas.

Conforme Leitner & Schmidt (2007, p. 183) em seu trabalho sobre a formação de expectativas no mercado de câmbio: “[...] os participantes do mercado usam heurísticas simples ao invés de calcular soluções exatas e racionais [...] é sensato aos participantes do mercado usar uma simples heurística de tendência”. Como os pressupostos das hipóteses das expectativas racionais e adaptativas foram violados, é possível sugerir que a aplicação de heurísticas na formação das expectativas de inflação também ocorra. Considerando a não confirmação das hipóteses adaptativas e racionais e a relevância da inflação passada na formação das expectativas de inflação, é possível sugerir a presença de uma heurística na formação das expectativas de inflação¹⁷: a ancoragem e o ajustamento (Tversky & Kahneman, 1974).

Para testar o viés da ancoragem, recorreu-se à regressão proposta por Campbell & Sharpe (2009):

$$\text{erros de previsão} = \alpha + \gamma \cdot (\pi_t^e - \bar{A}_h) \quad (5)$$

Nesta equação, os erros de previsão referem-se às diferenças entre as expectativas e os valores reais observados ($\pi_{t+12} - \pi_t^e$). O termo $\bar{A}_h$ diz respeito à âncora, ou seja, o valor a partir do qual os consumidores estão expressando e ajustando suas opiniões a respeito da inflação de 12 meses à frente. Seguindo procedimento semelhante em Campbell & Sharpe (2009), a âncora considerada aqui foi a média das taxas de inflação de 12 meses realizadas nos 6 meses anteriores. Estas defasagens foram escolhidas por terem sido encontradas altas correlações das expectativas de inflação com a inflação passada entre estas defasagens. Um coeficiente γ positivo indicaria a presença de ancoragem em direção a valores defasados da variável inflação observada.

¹⁷ Para uma verificação empírica adequada, sugere-se testar estas heurísticas nos microdados das expectativas, de modo que se tenha resultados no nível dos indivíduos. Como este nível de exploração foge dos objetivos deste trabalho, os testes, resultados e análises aqui ficam apenas no nível agregado das expectativas de inflação dos consumidores.

Diante disso, estimou-se a regressão, a qual apresentou intercepto de -0,024 e γ igual a 0,906, ambos significantes a 1%. Como o coeficiente angular é positivo e estatisticamente significativo, isto indica a presença de evidências compatíveis com o viés comportamental mencionado, ou seja, a presença de uma heurística baseada na ancoragem. Por estes resultados (e os anteriores), as pessoas tenderiam a calcular suas expectativas de inflação ancoradas, pelo menos parcialmente, a partir de valores passados da inflação.

Achados neste mesmo sentido, em que a expectativa de inflação está baseada em uma heurística de ancoragem sobre valores passados podem ser verificados em Assenza, Heemeijer, Hommes, & Massaro (2011) e Campbell & Sharpe (2009).

4.2.8.2. Relações entre Variáveis Macroeconômicas e Expectativas de Renda e Satisfação com a Vida

Ampliando a análise sobre as expectativas de renda pessoal, neste estudo não se pôde verificar o poder preditivo das expectativas de renda pessoal quanto à dinâmica futura da renda pessoal observada, uma vez que não se tem como verificar se tais expectativas se realizaram de fato, ou seja, se, por exemplo, altas expectativas de renda pessoal levaram de fato a um aumento da renda pessoal. Entretanto a relação com a inflação neste trabalho tinha a hipótese de que altas expectativas de renda seriam canalizadas para a demanda e de alguma forma pudessem gerar algum impacto sobre a inflação. Como já verificado, dentre as variáveis adicionadas ao modelo macroeconômico, esta foi a que apresentou o maior e mais significativo impacto sobre a inflação. No entanto, ainda com efeitos muito limitados se comparado às maiores magnitudes das variáveis macroeconômicas.

Ao analisar as maiores correlações existentes entre o índice de expectativa de renda pessoal e todas as outras variáveis, cabem ser mencionados os resultados expostos na Tabela 7. Dentre as correlações encontradas, pode-se perceber que as expectativas de renda pessoal estão relacionadas a um aparente sentimento das pessoas em relação à economia. O índice de expectativa de renda pessoal exibiu alta correlação negativa com a cotação do dólar defasada de 1 mês e com a variação de 12 meses do desemprego. Estão entre as menores correlações entre todas as variáveis macroeconômicas. Este fato aponta que, se o patamar do dólar baixar e/ou

o desemprego em 1 ano cair, pode trazer a percepção às pessoas de que a economia tem melhorado, deste modo que suas expectativas quanto à renda tenderiam a subir.

Correlação do índice de expectativas de renda pessoal com:	Correlação
Expectativas de inflação dos consumidores	-0,848
Cotação do dólar defasada de 1 mês	-0,893
Variação do desemprego em 12 meses	-0,684
Índice de satisfação com a vida	0,945
Variação do PIB em 12 meses, defasada de 1 mês	0,609

Tabela 7: Correlação com o índice de expectativa de renda pessoal

Do mesmo modo, se a percepção da economia piorou, isto faria com que as pessoas esperassem queda em suas rendas. Esta percepção também pode ser verificada com a alta correlação positiva que as expectativas de renda têm com a variação do PIB em 1 ano e defasada de 1 mês, que é a correlação positiva mais alta encontrada considerando as variáveis macroeconômicas. Neste caso, a premissa seria a mesma, uma variação positiva no PIB em 1 ano indicaria uma percepção econômica favorável e as pessoas tenderiam a esperar melhora em suas rendas.

Outro achado são as altas correlações com as expectativas de inflação dos consumidores e com o índice de satisfação com a vida.

Há o risco destas correlações serem espúrias, uma vez que isto não foi investigado neste trabalho e tratam-se de séries temporais. Entretanto, pela Figura 25 é possível verificar como o histórico do índice de expectativa de renda pessoal se assemelha ou se diferencia das outras séries mencionadas. Embora não haja uma investigação mais exaustiva sobre a real relação entre as séries apontadas, pela Figura 25 pode-se supor que há movimentos parecidos (ou proporcionalmente contrários) entre as séries e as expectativas de renda. Os valores estão normalizados para que as séries pudessem ser comparadas na mesma escala.



Figura 25: Dinâmica entre expectativas de renda pessoal e demais variáveis

Conforme já comentado, a relação entre expectativas de renda e expectativas de inflação é uma questão empírica, uma vez que seria necessário proceder a um estudo para verificar qual é de fato a variável dominante. A expectativa inflacionária mais alta teoricamente geraria consumo mais alto e poupança mais baixa (conforme o efeito da equação de Fisher e da substituição intertemporal), gerando pressão para uma inflação de demanda. Entretanto, conforme já citado, Frank (2013) descreve que pessoas que tenham a expectativa de renda maior, diminuem a necessidade de poupança, gastando mais em relação a pessoas cuja expectativa de renda é menor. Porém, a expectativa de alta da inflação, geraria também a expectativa de rendas reais menores (desde que mantidas as rendas nominais). Além disso, teoricamente

quando houvesse expectativa de inflação mais alta e expectativa de renda mais baixa, somente haveria aumento de consumo, e por sua vez, talvez alguma pressão inflacionária, se a expectativa de inflação dominasse os efeitos da expectativa de renda menor, tendo em vista que, em teoria, uma levaria a um aumento e outra a uma diminuição do consumo. Dada a alta correlação negativa, as duas expectativas tendem a andar juntas, mas de forma inversa, e, a julgar apenas pela relação funcional das expectativas de renda (sem um estudo mais aprofundado), parece haver domínio das expectativas de inflação. Não obstante a limitação desta análise, dentro do intervalo de estudo, pode-se afirmar que em geral pessoas que esperavam inflação futura mais baixa também esperavam aumento em suas rendas pessoais e vice-versa.

Há também uma correlação bastante alta e positiva com o índice de satisfação com a vida. Assim, dentro do intervalo estudado, as pessoas em geral que indicaram maiores níveis de satisfação com a vida também eram pessoas que esperavam aumentos em suas rendas pessoais no futuro. E, concatenando com o parágrafo anterior, eram pessoas, da mesma forma, que tinham expectativa de inflação mais baixa. Esta correlação negativa entre satisfação com a vida e expectativa de inflação está em linha com os resultados de Guven (2012), como já comentado na análise da relação funcional do índice de satisfação com a vida.

Como a correlação entre índice de satisfação com a vida e índice de expectativa de renda pessoal é bastante alta, as correlações com as variáveis macroeconômicas da Tabela 7 são muito parecidas. Logo, a percepção econômica por meio da cotação do dólar, da variação do desemprego em 12 meses e da variação do PIB em 12 meses, está da mesma forma correlacionada ao grau de satisfação com a vida medido pelo índice da CNI. Assim, dentro das limitações do estudo, uma queda no dólar, diminuição do desemprego e aumento do PIB estão relacionados a um aumento nos níveis expressos pela pesquisa de satisfação com a vida. Como estas variáveis são defasadas ou abrangeram um grande período de tempo, quase toda a informação produzida por elas pôde subsidiar a opinião dos respondentes das pesquisas de satisfação com a vida e expectativa de renda pessoal, ou seja, as informações macroeconômicas ocorreram quase que inteiramente antes das respostas serem coletadas, sendo razoável hipotetizar que as opiniões podem estar baseadas na sensação do ambiente econômico no qual se encontravam ou tinham conhecimento.

Embora tenha se constatado correlações entre séries de expectativas/satisfação com a vida e as macroeconômicas, o fato isolado de “andarem” correlacionadas não traz garantia de qualquer efeito preditivo sobre a inflação futura. Cabe observar que nenhuma das séries macroeconômicas elencadas nesta seção, com alta correlação com as variáveis adicionadas posteriormente, foi escolhida na seleção de atributos do modelo macroeconômico, e desta forma, não fez parte do aprendizado das redes neurais. Assim, talvez estas variáveis podem ser mais relevantes para contribuir para explicar as expectativas e satisfação com a vida em si, mas não a inflação para 12 meses futuros.

5. CONSIDERAÇÕES FINAIS

Esta pesquisa buscou mostrar a relevância da previsão da inflação como parte importante da administração pública, uma vez que é um dos pilares da orientação estratégica do Banco Central do Brasil. No âmbito privado, ela é um dos fundamentos para o desenvolvimento do ambiente macroeconômico no qual competem as empresas. O estudo questionou a previsibilidade da inflação brasileira e como ela se relaciona com variáveis macroeconômicas, expectativas e a satisfação com a vida. Para isto foram selecionadas as melhores variáveis através da mineração de dados e que posteriormente foram as variáveis utilizadas nas redes neurais macroeconômicas e híbridas.

Respondendo novamente aos objetivos e problema de pesquisa propostos neste trabalho, as conclusões, respaldadas nos resultados, foram sintetizadas abaixo nos seguintes itens:

- 1) As variáveis macroeconômicas originadas da seleção de atributos mostram que a inflação de 12 meses tem componentes relacionados à demanda, câmbio e *commodities*. Não emergiu da seleção, componentes que estivessem ligados diretamente a uma inflação inercial.
- 2) O poder preditivo das variáveis macroeconômicas utilizadas com a metodologia de redes neurais demonstrou ser superior quando comparado aos *benchmarks* (modelo AR e regressão linear).
- 3) As variáveis que causaram os maiores impactos na inflação de 12 meses foram IC-Br Agropecuária, IC-Br Energia, a variação do desemprego e a variação do PIB em Dólares, sendo estas variáveis as que tiveram relações funcionais mais significantes também. Dentre elas, com exceção do IC-Br Agropecuária, as relações funcionais encontradas foram quase lineares na maior parte dos intervalos. No caso das mercadorias agropecuárias a relação achada foi claramente não linear, com a metade inferior do intervalo dos valores praticamente sem efeito sobre a inflação e com efeito muito forte na metade superior.
- 4) Com a introdução dos modelos híbridos, o poder preditivo que havia no modelo macroeconômico diminuiu. Desta forma, um modelo que não incluísse expectativas ou satisfação com a vida seria melhor para o

propósito preditivo. Assim, parece não haver poder preditivo relevante nas expectativas de inflação dos consumidores, nas expectativas de renda ou no índice de satisfação com a vida.

- 5) A introdução das séries nos modelos híbridos não modificou a sensibilidade (impacto e forma das relações funcionais) de modo relevante das variáveis macroeconômicas mais significativas.
- 6) Visualizando as relações funcionais, o impacto que as expectativas e satisfação com a vida tem na inflação futura é pequeno se comparado com o das séries macroeconômicas.
- 7) A formação das expectativas de inflação dos consumidores não condiz com os pressupostos da racionalidade, tampouco pôde ser confirmada pela hipótese das expectativas adaptativas. O que pôde ser notado foi a utilização da heurística da ancoragem. Assim, estas expectativas indicam que podem ser melhor explicadas pela economia comportamental.
- 8) As expectativas e satisfação com a vida também estão altamente correlacionadas a variáveis macroeconômicas defasadas o que pode indicar que também sejam, pelo menos parcialmente, um produto do ambiente econômico.

A seguir estão elencadas as limitações às quais estão submetidos os resultados e conclusões deste trabalho:

- 1) Em primeiro lugar cabe observar que a seleção de atributos efetuada no início não foi repetida dinamicamente de modo a se verificar alterações na composição dos atributos, isto é, a seleção de atributos foi estática e não entrou no período de previsão. Numa situação real, provavelmente este procedimento seria repetido periodicamente (por exemplo: anualmente), até mesmo porque eventualmente a inflação pode apresentar uma quebra estrutural, motivo pelo qual seriam necessárias outras variáveis para explicar a inflação. Ainda neste sentido da quebra estrutural, os resultados encontrados estão baseados em um intervalo usado para a modelagem que possui um início fixo. Simulações baseadas em uma janela móvel, tanto para a seleção de atributos quanto

para a estimação dos modelos possivelmente trariam resultados diferentes.

- 2) Na relação funcional das variáveis, como já comentado, não se aprofundou a análise cronológica das relações, tendo bastado para este trabalho observar a relação entre o nível da variável e seu efeito sobre o nível da variável dependente. Numa análise mais completa seria interessante observar as alterações nas variáveis e o efeito que elas produzem na inflação não apenas devido a choques na própria variável, mas devido também aos choques advindos das outras variáveis que foram impactadas pelo choque da variável sendo testada.
- 3) Na prática, os modelos analisados não serviriam para fazer previsões e estudos em tempo real, haja vista que os dados não são disponibilizados exatamente no último dia de cada mês. Na realidade, a obtenção de todos os dados ocorre com atraso de até algumas semanas. Não obstante, como a previsão é para 12 meses, embora seja uma limitação, este atraso não é tão relevante.
- 4) As interpolações que foram produzidas a fim de se conseguir incluir as séries do índice de expectativa de renda pessoal e satisfação com a vida carregam o risco de terem produzido os resultados encontrados ao acaso. Se fosse possível utilizar séries que fossem originalmente mensais, provavelmente os resultados seriam diferentes, embora, acredita-se, não de forma significativa.
- 5) Na prática, as interpolações efetuadas no índice de satisfação com a vida somente seriam possíveis quando coincidissem com o fim de um trimestre. Como os pontos entre trimestres são interpolados, não seria possível interpolar o mês seguinte ao fim de um trimestre por que não se sabe o valor que corresponde ao trimestre seguinte. Sendo assim, na prática a estimação dinâmica dos modelos seria possível no mínimo com intervalos de três meses ou, obviamente, se fosse possível obter dados mensais para a pesquisa de satisfação com a vida.
- 6) Cabe observar que a pesquisa mediante questionário à população sempre traz o risco de as respostas não refletirem de fato o que pensam as pessoas. Este é um risco inerente às pesquisas em estudos sociais e

que de alguma forma, mesmo que de maneira muito sutil, pode influenciar resultados e conclusões que usem estes dados.

- 7) As expectativas e satisfação com a vida foram utilizadas em seus estados puros, ou seja, sem qualquer outro tratamento do tipo defasagem, diferenciação, etc. Por este motivo, também não foi aplicada a seleção de atributos para estas séries – ou para todas séries, em conjunto com as séries macroeconômicas – uma vez que o objetivo era verificar como estas variáveis interfeririam na previsão da inflação e no relacionamento com as outras variáveis, e também porque em especial as expectativas já trazem informações relacionados ao futuro. No entanto, uma variante deste trabalho poderia incluir uma seleção de atributos para os modelos híbridos, o que poderia gerar outras conclusões.
- 8) As conclusões e resultados da presente pesquisa são reflexos, entre outras coisas, do intervalo utilizado para estimar os modelos. Tanto os resultados dos modelos macroeconômico e híbridos, bem como todos os aspectos de comparação gerados por ambos, estão baseados nos intervalos de tempo nos quais os dados foram coletados. Há que se verificar que, em se tratando de dados mensais, a quantidade de informação disponível não é abundante. Com o decorrer do tempo e, conseqüentemente, maior disponibilidade de dados, é possível que novas pesquisas confirmem ou não os resultados obtidos neste estudo.
- 9) Por fim, a percepção de inflação de cada pessoa entrevistada para expressar sua opinião a respeito da inflação futura não é necessariamente compatível com a cesta de produtos que forma o IPCA, embora a forte correlação com o IPCA acumulado e defasado tenha sido demonstrada.

A principal constatação a respeito das variáveis de expectativas e satisfação com a vida é que elas não melhoraram a acurácia do modelo macroeconômico. Pelo contrário, trouxeram em geral informação desnecessária e prejudicial, tendo em vista que o modelo híbrido contava exatamente com as mesmas variáveis do modelo macroeconômico, mas foi “prejudicado” pela inclusão das novas informações. Mesmo quando as séries adicionadas interferiram nas relações funcionais, não deram

explicação relevantemente melhor para as séries macroeconômicas que já não tinham relação funcional tão relevante. Portanto, as séries macroeconômicas escolhidas e modeladas via redes neurais tiveram explicação melhor para a inflação de 12 meses do que uma combinação delas com cada uma das séries dos modelos híbridos, dentro do contexto do estudo. Cabe apenas observar que as expectativas de renda exibiram a melhor relação funcional entre as variáveis adicionadas. Neste caso, um estudo específico e aprofundado sobre esta série pode ser relevante para uma compreensão melhor do seu impacto em termos de poder preditivo e suas relações mais detalhadas com a macroeconomia.

6. REFERÊNCIAS BIBLIOGRÁFICAS

- Aiken, M. (1999). Using a neural network to forecast inflation. *Industrial Management & Data Systems*, Vol. 99(Issue: 7), pp. 296-301.
- Alavi, M., & Leidner, D. E. (Mar de 2001). Review: Knowledge Management and Knowledge Management Systems: Conceptual Foundations and Research Issues. *MIS Quarterly*, v. 25, no. 1, pp. 107-136.
- Alencar, B. K. (2006). Modelos de Previsão de Inflação: uma análise comparativa no curto prazo. *Dissertação de Mestrado Profissionalizante em Economia (IBMEC)*. Fonte: http://s3.amazonaws.com/public-cdn.ibmec.br/portaibmec-content/public/arquivos/df/dis_2006_2_-_bruno_kuffer_de_alencar.pdf
- Ang, A., Bekaert, G., & Wei, M. (2007). Do macro variables, asset markets, ou surveys forecast inflation better? *Journal of Monetary Economics*, v. 54, pp. 1163-1212.
- Arent, S. (Mar de 2012). Expectations and Saving Behavior: An Empirical Analysis. *Ifo Institute, Working Papers*, No. 128.
- Arestis, P., & Sawyer, M. (1999). The Macroeconomics of Industrial Strategy. *INDUSTRIAL POLICY IN EUROPE: THEORETICAL PERSPECTIVES AND PRACTICAL PROPOSALS* (pp. 352-369). Coventry, England: ROUTLEDGE.
- Arruda, E. F., Ferreira, R. T., & Castelar, I. (Jul-Set de 2011). Modelos Lineares e Não Lineares da Curva de Phillips para Previsão da Taxa de Inflação no Brasil. *Revista Brasileira de Economia*, v. 65, n. 3, pp. 237-252.
- Assenza, T., Heemeijer, P., Hommes, C., & Massaro, D. (Mai de 2011). Individual Expectations and Aggregate Macro Behavior. *DNB Working Paper*, n. 298.
- Babula, E., & Mrzyglod, U. (May de 2013). Economic Determinants of Happiness Among European Nations. *International Journal of Academic Research*, v. 5, n.3, pp. 519-524.
- Bachmann, R., Berg, T. O., & Sims, E. R. (2015). Inflation Expectations and Readiness to Spend: Cross-Sectional Evidence. *American Economic Journal: Economic Policy*, 7(1), pp. 1-35.
- Banco Central do Brasil. (28 de junho de 2017). *Planejamento Estratégico*. Fonte: Banco Central do Brasil: <http://www.bcb.gov.br/Pre/sobre/Pestrategico.asp>
- Banco Central do Brasil. (04 de julho de 2017). *PMF 10 - Regime de Metas para a Inflação no Brasil*. Fonte: Banco Central do Brasil: <http://www.bcb.gov.br/conteudo/home-ptbr/FAQs/FAQ%2010-Regime%20de%20Metas%20para%20a%20Infla%C3%A7%C3%A3o%20no%20Brasil.pdf>

- Banco Central do Brasil. (junho de 2017). *Relatório de Inflação, volume 19, nº 2*.
 Fonte: Banco Central do Brasil:
<http://www.bcb.gov.br/htms/relinf/port/2017/06/ri201706P.pdf>
- Banco Central do Brasil. (04 de julho de 2017). *SGS - Sistema Gerenciador de Séries Temporais*. Fonte: Banco Cenral do Brasil:
<https://www3.bcb.gov.br/sgspub/>
- Banco Central do Brasil. (04 de julho de 2017). *Taxa Selic*. Fonte: Banco Central do Brasil:
http://www.bcb.gov.br/htms/selic/conceito_taxaselic.asp?idpai=SELICTAXA
- Banco Mundial. (Dez de 2014). *Macroeconomic Policy*. Acesso em 22 de Mar de 2018, disponível em The World Bank:
<http://www.worldbank.org/en/topic/macroeconomics/brief/macroeconomic-policy>
- Barney, J. (1991). Firm Resources and Sustained Competitive Advantage. *Journal of Management*, v. 17, n. 1, pp. 99-120.
- Bengio, Y., Simard, P., & Frasconi, P. (Mar de 1994). Learning Long-Term Dependencies with Gradient Descent is Difficult. *IEEE Transactions On Neural Networks*, v. 5, n. 2, pp. 157-166.
- Berger, A. N., & Udell, G. F. (1998). The economics of small business finance: The roles of private equity and debt markets in the financial growth cycle. *Journal of Banking & Finance*, v. 22, pp. 613-673.
- Bernanke, B. S. (10 de Julho de 2007). Inflation Expectations and Inflation Forecasting. *Palestra no "Monetary Economics Workshop" do "National Bureau of Economic Research Summer Institute"*. Cambridge, Massachusetts. Acesso em 19 de Março de 2018, disponível em
<https://www.federalreserve.gov/newsevents/speech/Bernanke20070710a.htm>
- Bhattacharjee, A., Higson, C., Holly, S., & Kattuman, P. (2009). Macroeconomic Instability and Business Exit: Determinants of Failures and Acquisitions of UK Firms. *Economica*, v. 76, pp. 108-131.
- Binner, J. M., Bissoondeeal, R. K., Elger, T., Gazely, A. M., & Mullineaux, A. W. (2005). A comparison of linear forecasting models and neural networks: an application to Euro inflation and Euro Divisia. *Applied Economics*, v. 37(6), pp. 665-680.
- Binner, J. M., Elger, T., Nilsson, B., & Tepper, J. A. (2004). Tools For Non-linear Time Series Forecasting in Economics - An Empirical Comparison of Regime Switching Vector Autoregressive Models and Recurrent Neural Networks. *Applications of Artificial Intelligence In Finance and Economics*, pp. 71-91.
- Blanchard, O., & Johnson, D. R. (2012). *Macroeconomics*. Pearson.
- Bonno, S. J. (2014). Previsão da Inflação Utilizando Modelos de Séries Temporais. *Dissertação de Mestrado*. Rio de Janeiro: FGV.

- Bose, S. K., Sethuraman, J., & Raipet, S. (2006). Forecasting the Term Structure of Interest Rates Using Neural Networks. Em J. Kamruzzaman, R. K. Begg, & R. A. Sarker, *Artificial Neural Networks in Finance and Manufacturing* (pp. 124-138). IGI Global.
- Brayton, F., Mauskopf, E., Reifschneider, D., Tinsley, P., & Williams, J. (Apr de 1997). The Role of Expectations in the FRB/US Macroeconomic Model. *Federal Reserve Bulletin*. Acesso em 26 de Feb de 2018, disponível em chrome-extension://oemmnndcblbdoiebfnladdacbdmfmadadm/https://www.federalreserve.gov/pubs/bulletin/1997/199704lead.pdf
- Bresser-Pereira, L. C., & Nakano, Y. (Jan/Mar de 1984). Fatores aceleradores, mantenedores e sancionadores da inflação. *Revista de Economia Política*, v. 4, n.1, pp. 5-21.
- Burke, M. A., & Ozdagli, A. (2013). Household Inflation Expectations and Consumer Spending: Evidence from Panel Data. *Federal Reserve Bank of Boston, Working Paper no. 13-25*.
- Caldeira, J. F., Moura, G. V., & Santos, A. A. (Out-Dez de 2015). Previsões Macroeconômicas Baseadas em Modelos TVP-VAR: Evidências Para o Brasil. *Revista Brasileira de Economia*, v. 69 n.4, pp. 407-428.
- Camargo, J. M. (12 de março de 2018). *Inflação e Desemprego - a Curva de Phillips*. Acesso em 18 de setembro de 2018, disponível em Blog do IBRE: <https://blogdoibre.fgv.br/posts/inflacao-e-desemprego-curva-de-phillips>
- Camerer, C. F., & Loewenstein, G. (2003). Behavioral Economics: Past, Present, Future. Em C. F. Camerer, G. Loewenstein, & M. Rabin, *Advances in Behavioral Economics* (pp. 3-51). Princeton: Princeton University Press.
- Campbell, S. D., & Sharpe, S. A. (Abr de 2009). Anchoring Bias in Consensus Forecasts and Its Effect on Market Prices. *Journal of Financial and Quantitative Analysis*, v. 44, n. 2, pp. 369-390.
- Carlo, T. C., & Marçal, E. F. (2016). Forecasting Brazilian inflation by its aggregate and disaggregated data: a test of predictive power by forecast horizon. *Applied Economics*, v. 40, ed.50, pp. 4846-4860.
- Carvalho, K. d., Roma, C. M., Araujo, J. M., & Oliveira, M. R. (2013). A Influência das Variáveis Macroeconômicas Sobre o Valor de Empresas: uma Abordagem a partir do Modelo de Ohlson. *Anais do XXXVII EnANPAD*. Rio de Janeiro, RJ, Brasil. Fonte: http://www.anpad.org.br/admin/pdf/2013_EnANPAD_FIN1848.pdf
- Choudhary, M. A., & Haider, A. (2012). Neural network models for inflation forecasting: an appraisal. *Applied Economics*, pp. 44: 20, 2631-2635.
- Corbi, R. B., & Menezes-Filho, N. A. (out-dez de 2006). Os determinantes empíricos da felicidade no Brasil. *Revista de Economia Política*, v. 26, n. 4, pp. 518-536.

- Costa, G. P., Schmitt, F. O., Leite Filho, P. A., & Silva, C. A. (2011). O Reflexo das Variáveis Macroeconômicas no Nível de Caixa Evidenciado pelas Empresas Brasileiras Listadas na BOVESPA. *Anais Congresso ANPCONT*. Vitória, ES, Brasil.
- Cryder, C. E., Lerner, J. S., Gross, J. J., & Dahl, R. E. (Jun de 2008). Misery is not Miserly: Sad and Self-Focused Individuals Spend More. *Psychological Science*, 19(6), pp. 525-530.
- D'Acunto, F., Hoang, D., & Weber, M. (2015). Inflation Expectations and Consumption Expenditure. *2015 Meeting Papers*. Society for Economic Dynamics.
- De Bruin, W. B., Potter, S., Rich, R., Topa, G., & Van Der Klaauw, W. (Aug/Sep de 2010). Improving Survey Measures of Household Inflation Expectations. *Current Issues in Economics and Finance*, V. 16, N. 7.
- Deaton, A. (2008). Income, Health, and Well-Being around the World: Evidence from the Gallup World Poll. *Journal of Economic Perspectives*, v. 22, n.2, pp. 53-72.
- Dées, S., & Güntner, J. (2017). Forecasting Inflation Across Euro Area Countries and Sectors: A Panel VAR Approach. *Journal of Forecasting*, 36, pp. 431-453.
- Di Tella, R., MacCulloch, R. J., & Oswald, A. J. (Mar de 2001). Preferences over Inflation and Unemployment: Evidence from Surveys of Happiness. *American Economic Association*, v. 91, n.1, pp. 335-341.
- Di Tella, R., MacCulloch, R. J., & Oswald, A. J. (2003). The Macroeconomics of Happiness. *The Review of Economics and Statistics*, v. 85, n. 4, pp. 809-827.
- Duca, I. A., Kenny, G., & Reuter, A. (Aug de 2016). *How do inflation expectations impact consumer behaviour? Paper*. Acesso em 18 de fev de 2018, disponível em European Commission: https://ec.europa.eu/info/files/how-do-inflation-expectations-impact-consumer-behaviour-paper_en
- Elman, J. L. (1990). Finding Structure in Time. *Cognitive Science*, v. 14, pp. 179-211.
- Feng, L., & Zhang, J. (2014). Application of artificial neural networks in tendency forecasting of economic growth. *Economic Modelling*, pp. 76-80.
- Fisher, I. (1930). *The Theory of Interest*. New York: The Macmillan Co.
- Frank, R. H. (2013). *Microeconomia e Comportamento* (8ª Edição ed.). Porto Alegre: AMGH.
- Frey, B., & Stutzer, A. (Jun de 2002). What Can Economists Learn from Happiness Research? *Journal of Economic Literature*, v. 40, n. 2, pp. 402-435.
- Friedman, M. (Mar de 1968). The Role of Monetary Policy. *American Economic Review*, 58, pp. 1-17.

- Gaglianone, W. P., Issler, J. V., & Matos, S. M. (Ago de 2017). Applying a microfounded-forecasting approach to predict Brazilian inflation. *Empirical Economics*, v. 53, ed. 1, pp. 137-163.
- Garcia, M. G., Medeiros, M. C., & Vasconcelos, G. F. (Jul-Sep de 2017). Real-time inflation forecasting with high-dimensional models: The case of Brazil. *International Journal of Forecasting*, v. 33, ed. 3, pp. 679-693.
- Garg, N., & Lerner, J. S. (2013). Sadness and consumption. *Journal of Consumer Psychology*, v. 23, pp. 106-113.
- Gers, F. A., Schmidhuber, J., & Cummins, F. (2000). Learning to Forget: Continual Prediction with LSTM. *Neural Computation*, 12, pp. 2451-2471.
- Gil-Alana, L., Moreno, A., & De Gracia, F. P. (Sep de 2012). Exploring Survey-Based Inflation Forecasts. *Journal of Forecasting*, v. 31, ed. 6, pp. 524-539.
- Goedhart, M., Koller, T. M., & Wessels, D. (2010). *How inflation can destroy shareholder value*. Acesso em 23 de agosto de 2017, disponível em McKinsey & Company: <http://www.mckinsey.com/business-functions/strategy-and-corporate-finance/our-insights/how-inflation-can-destroy-shareholder-value>
- Graham, C., Eggers, A., & Sukhtankar, S. (2004). Does happiness pay? An exploration based on panel data from Russia. *Journal of Economic Behavior & Organization*, v. 55, pp. 319-342.
- Graupe, D. (2013). *Principles of Artificial Neural Networks (Advanced Series in Circuits & Systems)* (3 ed., Vol. 7). World Scientific Publishing Company.
- Grothe, M., & Meyler, A. (Nov de 2015). Inflation forecasts: Are market-based and survey-based measures informative? *European Central Bank, Working Paper Series*, No. 1865.
- Guillén, D. A. (março de 2008). Ensaio sobre a formação de expectativas de inflação. *Dissertação de Mestrado (PUC-Rio)*. Rio de Janeiro, RJ.
- Gupta, S., & Kashyap, S. (2015). Forecasting inflation in G-7 countries: an application of artificial neural network. *Foresight*, Vol. 17, pp. 66-73.
- Güven, C. (2012). Reversing the question: Does happiness affect consumption and savings behavior? *Journal of Economic Psychology*, v. 33, pp. 701-717.
- Habe, J. H. (2009). Câmbio e preços no Brasil: uma análise do período 1995-2006. *Dissertação de Mestrado em Economia - Pontifícia Universidade Católica de São Paulo*. São Paulo, SP, Brasil. Fonte: <https://sapientia.pucsp.br/bitstream/handle/9369/1/James%20Hiroshi%20Habe.pdf>
- Hakimpoor, H., Arshad, K. A., Tat, H. H., Khani, N., & Rahmandoust, M. (2011). Artificial Neural Networks' Applications in Management. *World Applied Sciences Journal*, pp. 1008-1019.

- Hall, M. A. (Abr de 1999). Correlation-based Feature Subset Selection for Machine Learning. *Department of Computer Science*. Hamilton, New Zealand. Acesso em 01 de ago de 2018, disponível em <https://www.cs.waikato.ac.nz/~mhall/thesis.pdf>
- Hall, M., & Smith, L. (1998). Practical feature subset selection for machine learning. *C. McDonald (Ed.), Computer Science '98 Proceedings of the 21st Australasian Computer Science Conference ACSC'98* (pp. 181-191). Perth, Australia: Berlin: Springer.
- Heaton, J. (2008). *Introduction to Neural Networks for Java*. Heaton Research, Inc.
- Heij, C., De Boer, P., Franses, P. H., Kloek, T., & van Dijk, H. K. (2004). *Econometric Methods with Applications in Business and Economics*. New York: Oxford University Press Inc.
- Hill, C. W., & Jones, G. R. (2009). *Strategic Management* (9 ed.). South-Western College Pub.
- Hochreiter, S. (1991). Untersuchungen zu dynamischen neuronalen Netzen. Institut für Informatik, Lehrstuhl Prof. Brauer, Technische Universität München.
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, pp. 9, 1735-1780.
- Hochreiter, S., Bengio, Y., Frasconi, P., & Schmidhuber, J. (2001). Gradient Flow in Recurrent Nets: the Difficulty of Learning Long-Term Dependencies. Em J. F. Kolen, & S. C. Kremer, *A Field Guide to Dynamical Recurrent Networks*. IEEE Press.
- IBGE. (04 de julho de 2017). *Índice Nacional de Preços ao Consumidor Amplo - IPCA e Índice Nacional de Preços ao Consumidor - INPC*. Fonte: IBGE: http://www.ibge.gov.br/home/estatistica/indicadores/precos/inpc_ipca/defaultinpc.shtm
- Ichiue, H., & Nishiguchi, S. (April de 2015). Inflation Expectations and Consumer Spending as the Zero Bound: Micro Evidence. *Economic Inquiry*, v. 53, n. 2, pp. 1086-1107.
- Instituto Brasileiro de Economia. (04 de julho de 2017). *IBRE :: IPA*. Fonte: Instituto Brasileiro de Economia: <http://portalibre.fgv.br/main.jsp?lumPageId=402880811D8E34B9011D984D9EE23590>
- Ito, Y., & Kaihatsu, S. (June de 2016). Effects of Inflation and Wage Expectations on Consumer Spending: Evidence from Micro Data. *Bank of Japan Working Paper Series*, No. 16-E-7.
- Jordan, M. I. (1986). *Serial Order: A Parallel Distributed Processing Approach*. ICS Report 8604, University of California, San Diego.

- Keynes, J. M. (1936). *The General Theory of Employment, Interest and Money*. Londres: Macmillan.
- Khumalo, M. (2014). Households Savings and Inflation Expectations: Cointegrated Evidence from South Africa. *Corporate Ownership & Control*, V. 12, Ed. 1, pp. 572-580.
- Kukal, J., & Quang, T. (2011). Modeling the CNB's Monetary Policy Interest Rate by Artificial Neural Networks. *Politicka Ekonomie*, v. 59, n.6, pp. 810-829.
- Leitner, J., & Schmidt, R. (Jun de 2007). Expectation formation in an experimental foreign exchange market. *Central European Journal of Operations Research*, v. 15, n. 2, pp. 167-184.
- Lima, E. C., & Alves, P. P. (Jun de 2011). O Desempenho do Mercado (Focus) na Previsão da Inflação: Novos Resultados? *ipea, Texto para Discussão 1621*.
- Lima, E. C., & Céspedes, B. J. (Mar de 2003). O Desempenho do Mercado (Focus) e do BACEN na Previsão da Inflação: Comparações com Modelos Lineares Univariados. *Boletim de Conjuntura 60 (ipea)*, pp. 75-83.
- Lima, E. J., Araujo, F., & Costa e Silva, J. R. (2011). Previsão e Modelos Macroeconômicos no Banco Central do Brasil. *Dez Anos de Metas para a Inflação no Brasil - 1999-2009*, pp. 351-399. Acesso em 10 de julho de 2017, disponível em Banco Central do Brasil: https://www.bcb.gov.br/Pec/Metas/10_anos_metas_inflacao_completo.pdf
- Liu, C., Hou, W., & Liu, D. (04 de Mai de 2017). Foreign Exchange Rates Forecasting with Convolutional Neural Network. *Neural Processing Letters*, pp. 1-25.
- Lucas, R. J. (1972). Expectations and the Neutrality of Money. *Journal of Economic Theory*, 4 (2), pp. 103-124.
- Machin, S., & Van Reenen, J. (mar de 1993). Profit Margins and the Business Cycle: Evidence from UK Manufacturing Firms. *The Journal of Industrial Economics*, v. 41, pp. 29-50.
- Mandalinci, Z. (2017). Forecasting inflation in emerging markets: An evaluation of alternative models. *International Journal of Forecasting*, 33, pp. 1082-1104.
- Mario, P. d., & Carvalho, L. N. (2007). O Fenômeno da Falência numa Abordagem de Análise de Causas. *Anais do 7º Congresso de Controladoria e Contabilidade da USP*. São Paulo, SP, Brasil. Fonte: <http://www.congressousp.fipecafi.org/anais/artigos72007/316.pdf>
- Martinez, T. S., & Cerqueira, V. D. (ago. de 2013). Estrutura da inflação brasileira: determinantes e desagregação do IPCA. *Economia e Sociedade*, v. 22, pp. n. 2(48), p. 409-456.
- Mestre, R. (Feb de 2007). Are Survey-Based Inflation Expectations in the Euro Area Informative? *European Central Bank, Working Paper Series, No. 721*.

- Mikolajek-Gocejna, M. (2014). Expectations in the Theory of Economics. Em M. Mikolajek-Gocejna, *Investor Expectations in Value Based Management* (pp. 35-46). Springer International Publishing Switzerland.
- Mirmirani, S., & Li, H. C. (2004). A Comparison of VAR and Neural Networks with Genetic Algorithm in Forecasting Price of Oil. *Advances in Econometrics*, Vol. 19, pp. 203-223.
- Mitreă, C. A., Lee, C. K., & Wu, Z. (2009). A Comparison between Neural Networks and Traditional Forecasting Methods: A Case Study. *International Journal of Engineering Business Management*, v. 1, n. 2, pp. 19-24.
- Montes, G. C., & Tiberto, B. P. (2012). Macroeconomic environment, country risk and stock market performance: Evidence for Brazil. *Economic Modelling*, v. 29, pp. 1666-1678.
- Mullainathan, S., & Thaler, R. H. (2000). Behavioral Economics, Working Paper 7948. *National Bureau of Economic Research*.
- Muth, J. (Jul de 1961). Rational expectations and the theory of price movements. *Econometrica*, 29, pp. 315-335.
- Nakamura, E. (2005). Inflation forecasting using a neural network. *Economic Letters*, pp. 373-378.
- Pandini, J., Stüpp, D. R., & Fabre, V. V. (2017). Análise do Impacto das Variáveis Macroeconômicas no Desempenho Econômico-Financeiro das Empresas dos Setores de Consumo Cíclico e Não Cíclico da BM&FBovespa. *Anais do XIV Congresso de Iniciação Científica em Contabilidade da USP*. São Paulo, SP, Brasil. Fonte: <http://www.congressousp.fipecafi.org/anais/AnaisCongresso2017/ArtigosDownload/401.pdf>
- Parnell, J. A. (2013). *Strategic Management: Theory and Practice* (4ª ed.). SAGE Publications, Inc.
- Penrose, E. T. (1959). *The Theory of the Growth of the Firm*. New York: John Wiley & Sons.
- Potter, S. M. (30 de Março de 2011). Improving Survey Measures of Inflation Expectations. *Palestra no "Forecasters Club of New York"*. Acesso em 19 de fev de 2018, disponível em <https://www.newyorkfed.org/newsevents/speeches/2011/pot110330>
- Ribeiro, L. L., & Marinho, E. L. (2017). Gross National Happiness in Brazil: An analysis of its determinants. *Economia*, v. 18, pp. 156-167.
- Rosenblatt, F. (1958). The Perceptron: A Probabilistic Model For Information Storage And Organization In The Brain. *Psychological Review*, Vol. 65, pp. 386-408.
- Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, Vol. 323, pp. 533-536.

- Sachsida, A., Ribeiro, M., & Dos Santos, C. H. (out de 2009). A Curva de Phillips e a Experiência Brasileira. *IPEA - Texto para Discussão nº 1429*. Fonte: http://www.ipea.gov.br/portal/images/stories/PDFs/TDs/td_1429.pdf
- Salabun, W., & Pietrzykowski, M. (2016). Neural Networks in Economic Problems. *Selected Issues in Experimental Economics* (pp. 245-266). Springer International Publishing Switzerland.
- Semaan, D., Harb, A., & Kassem, A. (2014). Forecasting Exchange Rates: Artificial Neural Networks Vs Regression. *3rd International Conference on E-Technologies and Networks for Development (ICeND)* (pp. 156-161). Beirut, LEBANON: IEEE.
- Sharma, S., & Singh, S. (2016). Unemployment Rate Forecasting Using Supervised Neural Networks. *2016 6th International Conference - Cloud System and Big Data Engineering (Confluence)* (pp. 28-33). Noida, India: IEEE.
- Simon, H. (1957). A Behavioral Model of Rational Choice. Em *Models of Man: Social and Rational*. New York: John Wiley and Sons, Inc.
- Smith, K. A., & Gupta, J. N. (2000). Neural networks in business: techniques and applications for the operations researcher. *Computers & Operations Research*, pp. 1023-1044.
- Snieska, V., Laskiene, D., & Pekarskiene, I. (2008). Stock Returns and the Macroeconomic Environment: The Case of the Vilnius Stock Exchange. *Transformations in Business & Economics*, v. 7, ed. 2, pp. 115-129.
- Stephens Jr, M. (Feb de 2004). Job Loss Expectations, Realizations, and Household Consumption Behavior. *The Review of Economics and Statistics*, v. 86, ed. 1, pp. 253-269.
- Stockl, M., Moreira, R. R., & Giuberti, A. C. (2017). O impacto das commodities sobre a dinâmica da inflação no Brasil e o papel amortecedor do câmbio: evidências para o CRB Index e Índice de Commodities Brasil. *Nova Economia*, v. 27, n. 1, pp. 173-207.
- Stokes, A., & Abou-Zaid, A. S. (2012). Forecasting foreign exchange rates using artificial neural networks: a trader's approach. *International Journal of Monetary Economics and Finance*, v. 5, no. 4, pp. 370-394.
- Summa, R. (2011). Uma Avaliação Crítica das Estimativas da Curva de Phillips no Brasil. *Pesquisa & Debate*, v. 22, n. 02, pp. 157-183.
- Summa, R. F., & Macrini, L. (2014). Os determinantes da inflação brasileira recente: estimações utilizando redes neurais. *Nova Economia Belo Horizonte*, pp. 279-296.
- Sun, L. (2017). *Macroeconomic Factors and the Management Environment*. Acesso em 22 de Mar de 2018, disponível em BusinessDictionary: <http://www.businessdictionary.com/article/598/macroeconomic-factors-and-the-management-environment/>

- Sundermeyer, M., Schlüter, R., & Ney, H. (2012). LSTM Neural Networks for Language Modeling. *13th Annual Conference of the International-Speech-Communication-Association* (pp. 194-197). Portland, OR: ISCA-INT SPEECH COMMUNICATION ASSOC.
- Teixeira, F. O., De Oliveira, I. C., & Ferreira, P. C. (jul-set de 2017). Consumer's inflation expectations in Brazil. *Estudos Econômicos*, v. 47, n. 3, pp. 509-529.
- Terra, L. A., & Passador, J. L. (2012). Redes Neurais Artificiais na Previsão da Inflação: Aplicação como Ferramenta de Apoio à Análise de Decisões Financeiras em Organizações de Pequeno Porte. *Revista de Administração Mackenzie*, V. 13, pp. 68-86.
- Thakur, G. S., Bhattacharyya, R., & Mondal, S. S. (2016). Artificial Neural Network Based Model for Forecasting of Inflation in India. *Fuzzy Information and Engineering*, pp. 8: 87-100.
- Thaler, R. H. (2016). Behavioral Economics: Past, Present, and Future. *American Economic Review*, 106 (7), pp. 1577-1600.
- Thaler, R. H. (2016). *Misbehaving: The Making of Behavioral Economics*. New York, NY: W. W. Norton & Company.
- Tkacz, G. (2001). Neural network forecasting of Canadian GDP growth. *International Journal of Forecasting*, pp. 57-69.
- Tversky, A., & Kahneman, D. (27 de Sep de 1974). Judgment under Uncertainty: Heuristics and Biases. *Science*, v. 185, n. 4157, pp. 1124-1131.
- Vieira, C. A., Arruda, M. P., & Tavares, A. d. (Jan/Abr de 2016). O Impacto da Inflação no Endividamento das Instituições Financeiras Brasileiras. *Revista de Gestão, Finanças e Contabilidade*, v. 6, n. 1, pp. 28-44.
- Vinod, H. (2006). Maximum Entropy Ensembles for Time Series Inference in Economics. *Journal of Asian Economics*, 17(6), pp. 955-978.
- Vinod, H. D., & López-de-Lacalle, J. (2016). *Maximum Entropy Bootstrap for Time Series: The meboot R Package*. Fonte: The Comprehensive R Archive Network: <https://cran.r-project.org/web/packages/meboot/vignettes/meboot.pdf>
- Wang, G., & Zheng, X. (2009). The Unemployment Rate Forecast Model Based on Neural Network. *2009 International Workshop on Intelligent Systems and Applications* (pp. 1-4). Wuhan, China: IEEE.
- Welsch, H. (Nov de 2007). Macroeconomics and Life Satisfaction: Revisiting the "Misery Index". *Journal of Applied Economics*, v. X, n. 2, pp. 237-251.
- Wernerfelt, B. (1984). A Resource-based View of the Firm. *Strategic Management Journal*, v.5, pp. 171-180.
- Zhang, C., Bengio, S., Hardt, M., Recht, B., & Vinyals, O. (2017). Understanding Deep Learning Requires Rethinking Generalization. *ICLR 2017*. Fonte: <https://arxiv.org/pdf/1611.03530>

- Zhao, Z., Chen, W., Wu, X., Chen, P. C., & Liu, J. (Mar de 2017). LSTM network: a deep learning approach for short-term traffic forecast. *IET Intelligent Transport Systems*, pp. 68-75.
- Zhuge, Q., Xu, L., & Zhang, G. (24 de Mai de 2017). LSTM Neural Network with Emotional Analysis for Prediction of Stock Price. *Engineering Letters*, pp. 167-175.

ANEXO A – VARIÁVEIS INDEPENDENTES UTILIZADAS NA SELEÇÃO DE ATRIBUTOS PARA O MODELO MACROECONÔMICO

Num.	Variável	Descrição
1	ipca	Taxa do IPCA
2	ipca.1	Taxa do IPCA defasada 1 mês
3	ipca.2	Taxa do IPCA defasada 2 meses
4	ipca.6	Taxa do IPCA defasada 6 meses
5	ipca.12	Taxa do IPCA defasada 12 meses
6	var.ipca	Variação da taxa do IPCA
7	var.ipca.1	Variação da taxa do IPCA defasada 1 mês
8	var.ipca.2	Variação da taxa do IPCA defasada 2 meses
9	var.ipca.6	Variação da taxa do IPCA defasada 6 meses
10	var.ipca.12	Variação da taxa do IPCA defasada 12 meses
11	acum.2.ipca	Taxa do IPCA acumulada em 2 meses
12	acum.2.ipca.1	Taxa do IPCA acumulada em 2 meses, defasada 1 mês
13	acum.2.ipca.2	Taxa do IPCA acumulada em 2 meses, defasada 2 meses
14	acum.2.ipca.6	Taxa do IPCA acumulada em 2 meses, defasada 6 meses
15	acum.2.ipca.12	Taxa do IPCA acumulada em 2 meses, defasada 12 meses
16	acum.3.ipca	Taxa do IPCA acumulada em 3 meses
17	acum.3.ipca.1	Taxa do IPCA acumulada em 3 meses, defasada 1 mês
18	acum.3.ipca.2	Taxa do IPCA acumulada em 3 meses, defasada 2 meses
19	acum.3.ipca.6	Taxa do IPCA acumulada em 3 meses, defasada 6 meses
20	acum.3.ipca.12	Taxa do IPCA acumulada em 3 meses, defasada 12 meses
21	acum.6.ipca	Taxa do IPCA acumulada em 6 meses
22	acum.6.ipca.1	Taxa do IPCA acumulada em 6 meses, defasada 1 mês
23	acum.6.ipca.2	Taxa do IPCA acumulada em 6 meses, defasada 2 meses
24	acum.6.ipca.6	Taxa do IPCA acumulada em 6 meses, defasada 6 meses
25	acum.6.ipca.12	Taxa do IPCA acumulada em 6 meses, defasada 12 meses
26	acum.12.ipca	Taxa do IPCA acumulada em 12 meses
27	acum.12.ipca.1	Taxa do IPCA acumulada em 12 meses, defasada 1 mês
28	acum.12.ipca.2	Taxa do IPCA acumulada em 12 meses, defasada 2 meses
29	acum.12.ipca.6	Taxa do IPCA acumulada em 12 meses, defasada 6 meses
30	acum.12.ipca.12	Taxa do IPCA acumulada em 12 meses, defasada 12 meses
31	ipa	Taxa do IPA
32	ipa.1	Taxa do IPA defasada 1 mês
33	ipa.2	Taxa do IPA defasada 2 meses
34	ipa.6	Taxa do IPA defasada 6 meses
35	ipa.12	Taxa do IPA defasada 12 meses

36	var.ipa	Variação da taxa do IPA
37	var.ipa.1	Variação da taxa do IPA defasada 1 mês
38	var.ipa.2	Variação da taxa do IPA defasada 2 meses
39	var.ipa.6	Variação da taxa do IPA defasada 6 meses
40	var.ipa.12	Variação da taxa do IPA defasada 12 meses
41	acum.2.ipa	Taxa do IPA acumulada em 2 meses
42	acum.2.ipa.1	Taxa do IPA acumulada em 2 meses, defasada 1 mês
43	acum.2.ipa.2	Taxa do IPA acumulada em 2 meses, defasada 2 meses
44	acum.2.ipa.6	Taxa do IPA acumulada em 2 meses, defasada 6 meses
45	acum.2.ipa.12	Taxa do IPA acumulada em 2 meses, defasada 12 meses
46	acum.3.ipa	Taxa do IPA acumulada em 3 meses
47	acum.3.ipa.1	Taxa do IPA acumulada em 3 meses, defasada 1 mês
48	acum.3.ipa.2	Taxa do IPA acumulada em 3 meses, defasada 2 meses
49	acum.3.ipa.6	Taxa do IPA acumulada em 3 meses, defasada 6 meses
50	acum.3.ipa.12	Taxa do IPA acumulada em 3 meses, defasada 12 meses
51	acum.6.ipa	Taxa do IPA acumulada em 6 meses
52	acum.6.ipa.1	Taxa do IPA acumulada em 6 meses, defasada 1 mês
53	acum.6.ipa.2	Taxa do IPA acumulada em 6 meses, defasada 2 meses
54	acum.6.ipa.6	Taxa do IPA acumulada em 6 meses, defasada 6 meses
55	acum.6.ipa.12	Taxa do IPA acumulada em 6 meses, defasada 12 meses
56	acum.12.ipa	Taxa do IPA acumulada em 12 meses
57	acum.12.ipa.1	Taxa do IPA acumulada em 12 meses, defasada 1 mês
58	acum.12.ipa.2	Taxa do IPA acumulada em 12 meses, defasada 2 meses
59	acum.12.ipa.6	Taxa do IPA acumulada em 12 meses, defasada 6 meses
60	acum.12.ipa.12	Taxa do IPA acumulada em 12 meses, defasada 12 meses
61	selic	Taxa Selic
62	selic.1	Taxa Selic defasada 1 mês
63	selic.2	Taxa Selic defasada 2 meses
64	selic.6	Taxa Selic defasada 6 meses
65	selic.12	Taxa Selic defasada 12 meses
66	var.selic	Variação da taxa Selic
67	var.selic.1	Variação da taxa Selic defasada 1 mês
68	var.selic.2	Variação da taxa Selic defasada 2 meses
69	var.selic.6	Variação da taxa Selic defasada 6 meses
70	var.selic.12	Variação da taxa Selic defasada 12 meses
71	acum.2.selic	Taxa Selic acumulada em 2 meses
72	acum.2.selic.1	Taxa Selic acumulada em 2 meses, defasada 1 mês
73	acum.2.selic.2	Taxa Selic acumulada em 2 meses, defasada 2 meses
74	acum.2.selic.6	Taxa Selic acumulada em 2 meses, defasada 6 meses
75	acum.2.selic.12	Taxa Selic acumulada em 2 meses, defasada 12 meses
76	acum.3.selic	Taxa Selic acumulada em 3 meses
77	acum.3.selic.1	Taxa Selic acumulada em 3 meses, defasada 1 mês
78	acum.3.selic.2	Taxa Selic acumulada em 3 meses, defasada 2 meses
79	acum.3.selic.6	Taxa Selic acumulada em 3 meses, defasada 6 meses

80	acum.3.selic.12	Taxa Selic acumulada em 3 meses, defasada 12 meses
81	acum.6.selic	Taxa Selic acumulada em 6 meses
82	acum.6.selic.1	Taxa Selic acumulada em 6 meses, defasada 1 mês
83	acum.6.selic.2	Taxa Selic acumulada em 6 meses, defasada 2 meses
84	acum.6.selic.6	Taxa Selic acumulada em 6 meses, defasada 6 meses
85	acum.6.selic.12	Taxa Selic acumulada em 6 meses, defasada 12 meses
86	acum.12.selic	Taxa Selic acumulada em 12 meses
87	acum.12.selic.1	Taxa Selic acumulada em 12 meses, defasada 1 mês
88	acum.12.selic.2	Taxa Selic acumulada em 12 meses, defasada 2 meses
89	acum.12.selic.6	Taxa Selic acumulada em 12 meses, defasada 6 meses
90	acum.12.selic.12	Taxa Selic acumulada em 12 meses, defasada 12 meses
91	ldol	Log da cotação do Dólar
92	ldol.1	Log da cotação do Dólar defasado 1 mês
93	ldol.2	Log da cotação do Dólar defasado 2 meses
94	ldol.6	Log da cotação do Dólar defasado 6 meses
95	ldol.12	Log da cotação do Dólar defasado 12 meses
96	var.1.ldol	Variação mensal do log da cotação do Dólar
97	var.1.ldol.1	Variação mensal do log da cotação do Dólar, defasada 1 mês
98	var.1.ldol.2	Variação mensal do log da cotação do Dólar, defasada 2 meses
99	var.1.ldol.6	Variação mensal do log da cotação do Dólar, defasada 6 meses
100	var.1.ldol.12	Variação mensal do log da cotação do Dólar, defasada 12 meses
101	var.2.ldol	Variação em 2 meses do log da cotação do Dólar
102	var.2.ldol.1	Variação em 2 meses do log da cotação do Dólar, defasada 1 mês
103	var.2.ldol.2	Variação em 2 meses do log da cotação do Dólar, defasada 2 meses
104	var.2.ldol.6	Variação em 2 meses do log da cotação do Dólar, defasada 6 meses
105	var.2.ldol.12	Variação em 2 meses do log da cotação do Dólar, defasada 12 meses
106	var.3.ldol	Variação em 3 meses do log da cotação do Dólar
107	var.3.ldol.1	Variação em 3 meses do log da cotação do Dólar, defasada 1 mês
108	var.3.ldol.2	Variação em 3 meses do log da cotação do Dólar, defasada 2 meses
109	var.3.ldol.6	Variação em 3 meses do log da cotação do Dólar, defasada 6 meses
110	var.3.ldol.12	Variação em 3 meses do log da cotação do Dólar, defasada 12 meses
111	var.6.ldol	Variação em 6 meses do log da cotação do Dólar
112	var.6.ldol.1	Variação em 6 meses do log da cotação do Dólar, defasada 1 mês

113	var.6.ldol.2	Variação em 6 meses do log da cotação do Dólar, defasada 2 meses
114	var.6.ldol.6	Variação em 6 meses do log da cotação do Dólar, defasada 6 meses
115	var.6.ldol.12	Variação em 6 meses do log da cotação do Dólar, defasada 12 meses
116	var.12.ldol	Variação em 12 meses do log da cotação do Dólar
117	var.12.ldol.1	Variação em 12 meses do log da cotação do Dólar, defasada 1 mês
118	var.12.ldol.2	Variação em 12 meses do log da cotação do Dólar, defasada 2 meses
119	var.12.ldol.6	Variação em 12 meses do log da cotação do Dólar, defasada 6 meses
120	var.12.ldol.12	Variação em 12 meses do log da cotação do Dólar, defasada 12 meses
121	lpib	Log do PIB
122	lpib.1	Log do PIB, defasado 1 mês
123	lpib.2	Log do PIB, defasado 2 meses
124	lpib.6	Log do PIB, defasado 6 meses
125	lpib.12	Log do PIB, defasado 12 meses
126	var.1.lpib	Variação mensal do log do PIB
127	var.1.lpib.1	Variação mensal do log do PIB, defasada 1 mês
128	var.1.lpib.2	Variação mensal do log do PIB, defasada 2 meses
129	var.1.lpib.6	Variação mensal do log do PIB, defasada 6 meses
130	var.1.lpib.12	Variação mensal do log do PIB, defasada 12 meses
131	var.2.lpib	Variação em 2 meses do log do PIB
132	var.2.lpib.1	Variação em 2 meses do log do PIB, defasada 1 mês
133	var.2.lpib.2	Variação em 2 meses do log do PIB, defasada 2 meses
134	var.2.lpib.6	Variação em 2 meses do log do PIB, defasada 6 meses
135	var.2.lpib.12	Variação em 2 meses do log do PIB, defasada 12 meses
136	var.3.lpib	Variação em 3 meses do log do PIB
137	var.3.lpib.1	Variação em 3 meses do log do PIB, defasada 1 mês
138	var.3.lpib.2	Variação em 3 meses do log do PIB, defasada 2 meses
139	var.3.lpib.6	Variação em 3 meses do log do PIB, defasada 6 meses
140	var.3.lpib.12	Variação em 3 meses do log do PIB, defasada 12 meses
141	var.6.lpib	Variação em 6 meses do log do PIB
142	var.6.lpib.1	Variação em 6 meses do log do PIB, defasada 1 mês
143	var.6.lpib.2	Variação em 6 meses do log do PIB, defasada 2 meses
144	var.6.lpib.6	Variação em 6 meses do log do PIB, defasada 6 meses
145	var.6.lpib.12	Variação em 6 meses do log do PIB, defasada 12 meses
146	var.12.lpib	Variação em 12 meses do log do PIB
147	var.12.lpib.1	Variação em 12 meses do log do PIB, defasada 1 mês
148	var.12.lpib.2	Variação em 12 meses do log do PIB, defasada 2 meses
149	var.12.lpib.6	Variação em 12 meses do log do PIB, defasada 6 meses
150	var.12.lpib.12	Variação em 12 meses do log do PIB, defasada 12 meses
151	licbr	Log do IC-Br

152	licbr.1	Log do IC-Br, defasado 1 mês
153	licbr.2	Log do IC-Br, defasado 2 meses
154	licbr.6	Log do IC-Br, defasado 6 meses
155	licbr.12	Log do IC-Br, defasado 12 meses
156	var.1.licbr	Variação mensal do log do IC-Br
157	var.1.licbr.1	Variação mensal do log do IC-Br, defasada 1 mês
158	var.1.licbr.2	Variação mensal do log do IC-Br, defasada 2 meses
159	var.1.licbr.6	Variação mensal do log do IC-Br, defasada 6 meses
160	var.1.licbr.12	Variação mensal do log do IC-Br, defasada 12 meses
161	var.2.licbr	Variação em 2 meses do log do IC-Br
162	var.2.licbr.1	Variação em 2 meses do log do IC-Br, defasada 1 mês
163	var.2.licbr.2	Variação em 2 meses do log do IC-Br, defasada 2 meses
164	var.2.licbr.6	Variação em 2 meses do log do IC-Br, defasada 6 meses
165	var.2.licbr.12	Variação em 2 meses do log do IC-Br, defasada 12 meses
166	var.3.licbr	Variação em 3 meses do log do IC-Br
167	var.3.licbr.1	Variação em 3 meses do log do IC-Br, defasada 1 mês
168	var.3.licbr.2	Variação em 3 meses do log do IC-Br, defasada 2 meses
169	var.3.licbr.6	Variação em 3 meses do log do IC-Br, defasada 6 meses
170	var.3.licbr.12	Variação em 3 meses do log do IC-Br, defasada 12 meses
171	var.6.licbr	Variação em 6 meses do log do IC-Br
172	var.6.licbr.1	Variação em 6 meses do log do IC-Br, defasada 1 mês
173	var.6.licbr.2	Variação em 6 meses do log do IC-Br, defasada 2 meses
174	var.6.licbr.6	Variação em 6 meses do log do IC-Br, defasada 6 meses
175	var.6.licbr.12	Variação em 6 meses do log do IC-Br, defasada 12 meses
176	var.12.licbr	Variação em 12 meses do log do IC-Br
177	var.12.licbr.1	Variação em 12 meses do log do IC-Br, defasada 1 mês
178	var.12.licbr.2	Variação em 12 meses do log do IC-Br, defasada 2 meses
179	var.12.licbr.6	Variação em 12 meses do log do IC-Br, defasada 6 meses
180	var.12.licbr.12	Variação em 12 meses do log do IC-Br, defasada 12 meses
181	licbra	Log do IC-Br Agropecuária
182	licbra.1	Log do IC-Br Agropecuária, defasado 1 mês
183	licbra.2	Log do IC-Br Agropecuária, defasado 2 meses
184	licbra.6	Log do IC-Br Agropecuária, defasado 6 meses
185	licbra.12	Log do IC-Br Agropecuária, defasado 12 meses
186	var.1.licbra	Variação mensal do log do IC-Br Agropecuária
187	var.1.licbra.1	Variação mensal do log do IC-Br Agropecuária, defasada 1 mês
188	var.1.licbra.2	Variação mensal do log do IC-Br Agropecuária, defasada 2 meses
189	var.1.licbra.6	Variação mensal do log do IC-Br Agropecuária, defasada 6 meses
190	var.1.licbra.12	Variação mensal do log do IC-Br Agropecuária, defasada 12 meses
191	var.2.licbra	Variação em 2 meses do log do IC-Br Agropecuária

192	var.2.licbra.1	Variação em 2 meses do log do IC-Br Agropecuária, defasada 1 mês
193	var.2.licbra.2	Variação em 2 meses do log do IC-Br Agropecuária, defasada 2 meses
194	var.2.licbra.6	Variação em 2 meses do log do IC-Br Agropecuária, defasada 6 meses
195	var.2.licbra.12	Variação em 2 meses do log do IC-Br Agropecuária, defasada 12 meses
196	var.3.licbra	Variação em 3 meses do log do IC-Br Agropecuária
197	var.3.licbra.1	Variação em 3 meses do log do IC-Br Agropecuária, defasada 1 mês
198	var.3.licbra.2	Variação em 3 meses do log do IC-Br Agropecuária, defasada 2 meses
199	var.3.licbra.6	Variação em 3 meses do log do IC-Br Agropecuária, defasada 6 meses
200	var.3.licbra.12	Variação em 3 meses do log do IC-Br Agropecuária, defasada 12 meses
201	var.6.licbra	Variação em 6 meses do log do IC-Br Agropecuária
202	var.6.licbra.1	Variação em 6 meses do log do IC-Br Agropecuária, defasada 1 mês
203	var.6.licbra.2	Variação em 6 meses do log do IC-Br Agropecuária, defasada 2 meses
204	var.6.licbra.6	Variação em 6 meses do log do IC-Br Agropecuária, defasada 6 meses
205	var.6.licbra.12	Variação em 6 meses do log do IC-Br Agropecuária, defasada 12 meses
206	var.12.licbra	Variação em 12 meses do log do IC-Br Agropecuária
207	var.12.licbra.1	Variação em 12 meses do log do IC-Br Agropecuária, defasada 1 mês
208	var.12.licbra.2	Variação em 12 meses do log do IC-Br Agropecuária, defasada 2 meses
209	var.12.licbra.6	Variação em 12 meses do log do IC-Br Agropecuária, defasada 6 meses
210	var.12.licbra.12	Variação em 12 meses do log do IC-Br Agropecuária, defasada 12 meses
211	licbrm	Log do IC-Br Metal
212	licbrm.1	Log do IC-Br Metal, defasado 1 mês
213	licbrm.2	Log do IC-Br Metal, defasado 2 meses
214	licbrm.6	Log do IC-Br Metal, defasado 6 meses
215	licbrm.12	Log do IC-Br Metal, defasado 12 meses
216	var.1.licbrm	Variação mensal do log do IC-Br Metal
217	var.1.licbrm.1	Variação mensal do log do IC-Br Metal, defasada 1 mês
218	var.1.licbrm.2	Variação mensal do log do IC-Br Metal, defasada 2 meses
219	var.1.licbrm.6	Variação mensal do log do IC-Br Metal, defasada 6 meses
220	var.1.licbrm.12	Variação mensal do log do IC-Br Metal, defasada 12 meses
221	var.2.licbrm	Variação em 2 meses do log do IC-Br Metal

222	var.2.licbrm.1	Variação em 2 meses do log do IC-Br Metal, defasada 1 mês
223	var.2.licbrm.2	Variação em 2 meses do log do IC-Br Metal, defasada 2 meses
224	var.2.licbrm.6	Variação em 2 meses do log do IC-Br Metal, defasada 6 meses
225	var.2.licbrm.12	Variação em 2 meses do log do IC-Br Metal, defasada 12 meses
226	var.3.licbrm	Variação em 3 meses do log do IC-Br Metal
227	var.3.licbrm.1	Variação em 3 meses do log do IC-Br Metal, defasada 1 mês
228	var.3.licbrm.2	Variação em 3 meses do log do IC-Br Metal, defasada 2 meses
229	var.3.licbrm.6	Variação em 3 meses do log do IC-Br Metal, defasada 6 meses
230	var.3.licbrm.12	Variação em 3 meses do log do IC-Br Metal, defasada 12 meses
231	var.6.licbrm	Variação em 6 meses do log do IC-Br Metal
232	var.6.licbrm.1	Variação em 6 meses do log do IC-Br Metal, defasada 1 mês
233	var.6.licbrm.2	Variação em 6 meses do log do IC-Br Metal, defasada 2 meses
234	var.6.licbrm.6	Variação em 6 meses do log do IC-Br Metal, defasada 6 meses
235	var.6.licbrm.12	Variação em 6 meses do log do IC-Br Metal, defasada 12 meses
236	var.12.licbrm	Variação em 12 meses do log do IC-Br Metal
237	var.12.licbrm.1	Variação em 12 meses do log do IC-Br Metal, defasada 1 mês
238	var.12.licbrm.2	Variação em 12 meses do log do IC-Br Metal, defasada 2 meses
239	var.12.licbrm.6	Variação em 12 meses do log do IC-Br Metal, defasada 6 meses
240	var.12.licbrm.12	Variação em 12 meses do log do IC-Br Metal, defasada 12 meses
241	licbre	Log do IC-Br Energia
242	licbre.1	Log do IC-Br Energia, defasado 1 mês
243	licbre.2	Log do IC-Br Energia, defasado 2 meses
244	licbre.6	Log do IC-Br Energia, defasado 6 meses
245	licbre.12	Log do IC-Br Energia, defasado 12 meses
246	var.1.licbre	Variação mensal do log do IC-Br Energia
247	var.1.licbre.1	Variação mensal do log do IC-Br Energia, defasada 1 mês
248	var.1.licbre.2	Variação mensal do log do IC-Br Energia, defasada 2 meses
249	var.1.licbre.6	Variação mensal do log do IC-Br Energia, defasada 6 meses
250	var.1.licbre.12	Variação mensal do log do IC-Br Energia, defasada 12 meses

251	var.2.licbre	Variação em 2 meses do log do IC-Br Energia
252	var.2.licbre.1	Variação em 2 meses do log do IC-Br Energia, defasada 1 mês
253	var.2.licbre.2	Variação em 2 meses do log do IC-Br Energia, defasada 2 meses
254	var.2.licbre.6	Variação em 2 meses do log do IC-Br Energia, defasada 6 meses
255	var.2.licbre.12	Variação em 2 meses do log do IC-Br Energia, defasada 12 meses
256	var.3.licbre	Variação em 3 meses do log do IC-Br Energia
257	var.3.licbre.1	Variação em 3 meses do log do IC-Br Energia, defasada 1 mês
258	var.3.licbre.2	Variação em 3 meses do log do IC-Br Energia, defasada 2 meses
259	var.3.licbre.6	Variação em 3 meses do log do IC-Br Energia, defasada 6 meses
260	var.3.licbre.12	Variação em 3 meses do log do IC-Br Energia, defasada 12 meses
261	var.6.licbre	Variação em 6 meses do log do IC-Br Energia
262	var.6.licbre.1	Variação em 6 meses do log do IC-Br Energia, defasada 1 mês
263	var.6.licbre.2	Variação em 6 meses do log do IC-Br Energia, defasada 2 meses
264	var.6.licbre.6	Variação em 6 meses do log do IC-Br Energia, defasada 6 meses
265	var.6.licbre.12	Variação em 6 meses do log do IC-Br Energia, defasada 12 meses
266	var.12.licbre	Variação em 12 meses do log do IC-Br Energia
267	var.12.licbre.1	Variação em 12 meses do log do IC-Br Energia, defasada 1 mês
268	var.12.licbre.2	Variação em 12 meses do log do IC-Br Energia, defasada 2 meses
269	var.12.licbre.6	Variação em 12 meses do log do IC-Br Energia, defasada 6 meses
270	var.12.licbre.12	Variação em 12 meses do log do IC-Br Energia, defasada 12 meses
271	lpibd	Log do PIB em Dólar
272	lpibd.1	Log do PIB em Dólar, defasado 1 mês
273	lpibd.2	Log do PIB em Dólar, defasado 2 meses
274	lpibd.6	Log do PIB em Dólar, defasado 6 meses
275	lpibd.12	Log do PIB em Dólar, defasado 12 meses
276	var.1.lpibd	Variação mensal do log do PIB em Dólar
277	var.1.lpibd.1	Variação mensal do log do PIB em Dólar, defasada 1 mês
278	var.1.lpibd.2	Variação mensal do log do PIB em Dólar, defasada 2 meses
279	var.1.lpibd.6	Variação mensal do log do PIB em Dólar, defasada 6 meses

280	var.1.lpidb.12	Variação mensal do log do PIB em Dólar, defasada 12 meses
281	var.2.lpidb	Variação em 2 meses do log do PIB em Dólar
282	var.2.lpidb.1	Variação em 2 meses do log do PIB em Dólar, defasada 1 mês
283	var.2.lpidb.2	Variação em 2 meses do log do PIB em Dólar, defasada 2 meses
284	var.2.lpidb.6	Variação em 2 meses do log do PIB em Dólar, defasada 6 meses
285	var.2.lpidb.12	Variação em 2 meses do log do PIB em Dólar, defasada 12 meses
286	var.3.lpidb	Variação em 3 meses do log do PIB em Dólar
287	var.3.lpidb.1	Variação em 3 meses do log do PIB em Dólar, defasada 1 mês
288	var.3.lpidb.2	Variação em 3 meses do log do PIB em Dólar, defasada 2 meses
289	var.3.lpidb.6	Variação em 3 meses do log do PIB em Dólar, defasada 6 meses
290	var.3.lpidb.12	Variação em 3 meses do log do PIB em Dólar, defasada 12 meses
291	var.6.lpidb	Variação em 6 meses do log do PIB em Dólar
292	var.6.lpidb.1	Variação em 6 meses do log do PIB em Dólar, defasada 1 mês
293	var.6.lpidb.2	Variação em 6 meses do log do PIB em Dólar, defasada 2 meses
294	var.6.lpidb.6	Variação em 6 meses do log do PIB em Dólar, defasada 6 meses
295	var.6.lpidb.12	Variação em 6 meses do log do PIB em Dólar, defasada 12 meses
296	var.12.lpidb	Variação em 12 meses do log do PIB em Dólar
297	var.12.lpidb.1	Variação em 12 meses do log do PIB em Dólar, defasada 1 mês
298	var.12.lpidb.2	Variação em 12 meses do log do PIB em Dólar, defasada 2 meses
299	var.12.lpidb.6	Variação em 12 meses do log do PIB em Dólar, defasada 6 meses
300	var.12.lpidb.12	Variação em 12 meses do log do PIB em Dólar, defasada 12 meses
301	desemp	Taxa de desemprego
302	desemp.1	Taxa de desemprego, defasada 1 mês
303	desemp.2	Taxa de desemprego, defasada 2 meses
304	desemp.6	Taxa de desemprego, defasada 6 meses
305	desemp.12	Taxa de desemprego, defasada 12 meses
306	var.1.desemp	Variação mensal da taxa de desemprego
307	var.1.desemp.1	Variação mensal da taxa de desemprego, defasada 1 mês
308	var.1.desemp.2	Variação mensal da taxa de desemprego, defasada 2 meses

309	var.1.desemp.6	Variação mensal da taxa de desemprego, defasada 6 meses
310	var.1.desemp.12	Variação mensal da taxa de desemprego, defasada 12 meses
311	var.2.desemp	Variação em 2 meses da taxa de desemprego
312	var.2.desemp.1	Variação em 2 meses da taxa de desemprego, defasada 1 mês
313	var.2.desemp.2	Variação em 2 meses da taxa de desemprego, defasada 2 meses
314	var.2.desemp.6	Variação em 2 meses da taxa de desemprego, defasada 6 meses
315	var.2.desemp.12	Variação em 2 meses da taxa de desemprego, defasada 12 meses
316	var.3.desemp	Variação em 3 meses da taxa de desemprego
317	var.3.desemp.1	Variação em 3 meses da taxa de desemprego, defasada 1 mês
318	var.3.desemp.2	Variação em 3 meses da taxa de desemprego, defasada 2 meses
319	var.3.desemp.6	Variação em 3 meses da taxa de desemprego, defasada 6 meses
320	var.3.desemp.12	Variação em 3 meses da taxa de desemprego, defasada 12 meses
321	var.6.desemp	Variação em 6 meses da taxa de desemprego
322	var.6.desemp.1	Variação em 6 meses da taxa de desemprego, defasada 1 mês
323	var.6.desemp.2	Variação em 6 meses da taxa de desemprego, defasada 2 meses
324	var.6.desemp.6	Variação em 6 meses da taxa de desemprego, defasada 6 meses
325	var.6.desemp.12	Variação em 6 meses da taxa de desemprego, defasada 12 meses
326	var.12.desemp	Variação em 12 meses da taxa de desemprego
327	var.12.desemp.1	Variação em 12 meses da taxa de desemprego, defasada 1 mês
328	var.12.desemp.2	Variação em 12 meses da taxa de desemprego, defasada 2 meses
329	var.12.desemp.6	Variação em 12 meses da taxa de desemprego, defasada 6 meses
330	var.12.desemp.12	Variação em 12 meses da taxa de desemprego, defasada 12 meses
331	vpim	Variação mensal da produção industrial
332	vpim.1	Variação mensal da produção industrial, defasada 1 mês
333	vpim.2	Variação mensal da produção industrial, defasada 2 meses
334	vpim.6	Variação mensal da produção industrial, defasada 6 meses
335	vpim.12	Variação mensal da produção industrial, defasada 12 meses

336	acum.2.vpim	Variação em 2 meses da produção industrial
337	acum.2.vpim.1	Variação em 2 meses da produção industrial, defasada 1 mês
338	acum.2.vpim.2	Variação em 2 meses da produção industrial, defasada 2 meses
339	acum.2.vpim.6	Variação em 2 meses da produção industrial, defasada 6 meses
340	acum.2.vpim.12	Variação em 2 meses da produção industrial, defasada 12 meses
341	acum.3.vpim	Variação em 3 meses da produção industrial
342	acum.3.vpim.1	Variação em 3 meses da produção industrial, defasada 1 mês
343	acum.3.vpim.2	Variação em 3 meses da produção industrial, defasada 2 meses
344	acum.3.vpim.6	Variação em 3 meses da produção industrial, defasada 6 meses
345	acum.3.vpim.12	Variação em 3 meses da produção industrial, defasada 12 meses
346	acum.6.vpim	Variação em 6 meses da produção industrial
347	acum.6.vpim.1	Variação em 6 meses da produção industrial, defasada 1 mês
348	acum.6.vpim.2	Variação em 6 meses da produção industrial, defasada 2 meses
349	acum.6.vpim.6	Variação em 6 meses da produção industrial, defasada 6 meses
350	acum.6.vpim.12	Variação em 6 meses da produção industrial, defasada 12 meses
351	acum.12.vpim	Variação em 12 meses da produção industrial
352	acum.12.vpim.1	Variação em 12 meses da produção industrial, defasada 1 mês
353	acum.12.vpim.2	Variação em 12 meses da produção industrial, defasada 2 meses
354	acum.12.vpim.6	Variação em 12 meses da produção industrial, defasada 6 meses
355	acum.12.vpim.12	Variação em 12 meses da produção industrial, defasada 12 meses
356	ipca.meta.h12	Meta do IPCA para os próximos 12 meses definida pelo Copom ¹⁸
357	erro.meta	Diferença entre o IPCA de 12 meses realizado e a meta para estes 12 meses (variável anterior)
358	erro.meta.1	Diferença entre o IPCA de 12 meses realizado e a meta para estes 12 meses, defasada 1 mês
359	erro.meta.2	Diferença entre o IPCA de 12 meses realizado e a meta para estes 12 meses, defasada 2 meses
360	erro.meta.6	Diferença entre o IPCA de 12 meses realizado e a meta para estes 12 meses, defasada 6 meses

¹⁸ Calculada proporcionalmente quando envolve anos com metas diferentes.

361	erro.meta.12	Diferença entre o IPCA de 12 meses realizado e a meta para estes 12 meses, defasada 12 meses
-----	--------------	--

Quadro 4: Variáveis utilizadas na seleção de atributos