

Previsão de Inadimplência de Cartão de Crédito com *Machine Learning*

Camille M. Pleger, Raul C. Rodrigues

Escola Politécnica – Pontifícia Universidade Católica do Paraná (PUCPR)

{camille.pleger, raul.constanski}@pucpr.edu.br

Resumo. Este artigo apresenta a aplicação de técnicas de *Machine Learning* para a previsão de inadimplência em clientes de cartão de crédito, com o objetivo de apoiar a gestão de risco e reduzir perdas financeiras em instituições financeiras. Utilizou-se a base de dados *Default of Credit Card Clients*, composta por informações demográficas e histórico de faturas e pagamentos. Após a análise exploratória e o pré-processamento dos dados, foram treinados e comparados os modelos Regressão Logística, Support Vector Machine (SVM), Random Forest, XGBoost, Voting Classifier e Long Short-Term Memory (LSTM). A avaliação foi realizada por meio das métricas ROC-AUC, recall, precisão e F1-score, com foco na classe de inadimplentes. Os resultados indicaram que o SVM apresentou o melhor equilíbrio entre capacidade de detecção e controle de erros, alcançando o maior F1-score para a classe minoritária (0,5230).

Abstract. This article presents the application of *Machine Learning* techniques for predicting credit card default, with the objective of supporting risk management and reducing financial losses in financial institutions. The *Default of Credit Card Clients* dataset was used, containing demographic information as well as billing and payment history. After exploratory data analysis and data preprocessing, the following models were trained and compared: Logistic Regression, Support Vector Machine (SVM), Random Forest, XGBoost, Voting Classifier, and Long Short-Term Memory (LSTM). Model performance was evaluated using the ROC-AUC, recall, precision, and F1-score metrics, with a particular focus on the default class. The results indicated that the SVM achieved the best balance between detection capability and error control, obtaining the highest F1-score for the minority class (0.5230).

1. Introdução

O estudo tem como objetivo desenvolver e avaliar modelos de aprendizagem de máquina (*machine learning*) para predição de inadimplência no mês subsequente em clientes de cartão de crédito, utilizando dados demográficos e históricos de fatura e pagamentos, visando redução nas perdas financeiras e melhorando a eficiência de análise de risco de inadimplência.

A aplicação de inteligência preventiva do modelo pode atuar na redução da PDD (Provisão de devedores duvidosos), permitindo que a instituição tome medidas de contenção antes que o prejuízo se materialize, como a redução do limite de crédito ou parcelamento de dívida.

Para tanto, foi realizada a análise exploratória e pré-processamento dos dados, para melhor entender o problema de negócio e ajustes das features quando necessário, após isso, foram aplicados os seguintes algoritmos de classificação: Regressão Logística, Support Vector Machine (SVM), Random Forest, XGBoost, um modelo ensemble do tipo Voting Classifier e um modelo de rede neural Long Short-Term Memory (LSTM). Os modelos serão avaliados conforme as métricas ROC-AUC, recall, precisão e F1-score.

Os resultados demonstram a eficácia das técnicas de Machine Learning na previsão de inadimplência. Dentre os modelos avaliados, o SVM apresentou o melhor desempenho geral, destacando-se pelo maior F1-score (0,5230) e bom equilíbrio entre recall (0,5576) e precisão (0,4923). Modelos como Random Forest e LSTM obtiveram maior acurácia ($\approx 81\%$), porém com baixo recall, indicando dificuldade na identificação de inadimplentes. Já a Regressão Logística apresentou o maior recall (0,6353), sendo mais eficaz na detecção da classe minoritária, embora com baixa precisão. O Voting Classifier apresentou desempenho intermediário. A análise detalhada das métricas e das matrizes de confusão será apresentada no capítulo de resultados.

2. Contexto e Diagnóstico

A análise de risco de crédito é uma atividade essencial para as instituições financeiras, principalmente quando se trata de cartão de crédito, onde há grande volume de operações e não existem garantias atreladas, desta forma, incorrendo um maior risco de inadimplência. O cenário econômico atual, segundo dados recentes do Banco Central do Brasil (Estatísticas Monetárias e de Crédito - Nota para a Imprensa - 27.4.2026), a inadimplência crédito com recursos livres situou-se em 5,7% em fevereiro de 2026, acumulando um aumento de 1,2 pontos percentuais no período de um ano.

A relevância de antecipar a inadimplência consiste na identificação de potenciais devedores inadimplentes, possibilitando ações estratégicas proativas que podem reduzir perdas financeiras, decisões como redução de limite do cartão de crédito, oferta de renegociações e priorização em esteiras de cobranças. Falhas na previsão desse problema impactam no aumento de prejuízos financeiros e provisionamento para devedores duvidosos, prejudicando a saúde financeira das instituições financeiras.

Neste contexto que o presente estudo se insere, buscamos explorar e comparar a eficácia de diferentes técnicas de Machine Learning na modelagem e classificação do risco de crédito. Ao aplicar algoritmos de variados níveis de complexidade, como Regressão Logística, SVM, Random Forest, XGBoost, Voting Classifier e redes neurais LSTM, à base de dados “Default of Credit Card Clients”, o trabalho desenvolve um entendimento e comportamento de cada modelo a esse tipo de dado financeiro. Esse comparativo avalia as abordagens preditivas, lidando com os desafios inerentes à base, como a presença de classes desbalanceadas, e também fornece embasamento técnico para otimizar a tomada de decisão e a gestão de riscos nas instituições financeiras.

3. Estado da Arte

3.1 Algoritmos:

Para este estudo, foi selecionado um conjunto de algoritmos de aprendizagem supervisionada voltados a problemas de classificação binária, com o propósito de estimar a probabilidade de inadimplência de clientes no mês subsequente.

3.1.1 Regressão Logística

A Regressão Logística é um modelo linear amplamente utilizado para problemas de classificação binária. Diferente da regressão linear convencional, que busca prever valores contínuos, a regressão logística estima a probabilidade de uma observação pertencer a uma das duas classes, por exemplo, inadimplente ou adimplente (James et al., 2023).

O modelo é baseado na aplicação da função logística (ou sigmoide) sobre a combinação linear das variáveis de entrada. Essa função possui um formato “S” que mapeia qualquer valor entre 0 e 1, permitindo que o resultado seja interpretado como probabilidade de ocorrência do evento (Izbicki e Santos 2020).

A formulação matemática do modelo baseia-se no conceito de log-odds (ou logit), que estabelece uma relação linear entre os preditores e o logaritmo da razão de chances do evento ocorrer. Durante o treinamento, os coeficientes são estimados por meio da maximização da verossimilhança, cujo objetivo é encontrar os parâmetros que maximizam a probabilidade de observar os dados disponíveis, proporcionando a melhor separação possível entre as classes (James et al., 2023).

A escolha deste modelo para o estudo deve-se à sua ampla utilização em problemas de classificação binária e à facilidade de interpretação de seus coeficientes, o que permite compreender diretamente o impacto e a influência de cada variável preditora sobre a probabilidade de inadimplência.

3.1.2 Support Vector Machine (SVM)

O Support Vector Machine (SVM) é um algoritmo de classificação que busca determinar um hiperplano separador capaz de maximizar a margem entre classes distintas. Essa margem é definida a partir das observações mais próximas da fronteira de decisão, conhecidas como vetores de suporte. De forma geral, margens mais amplas estão associadas a maior capacidade de generalização (James et al., 2023)

Em problemas reais, como a previsão de inadimplência, a separação entre as classes raramente é perfeitamente linear. Para lidar com essa situação, o SVM utiliza o conceito de margens suaves (soft margin), permitindo pequenas violações da fronteira de decisão. Esse equilíbrio é controlado pelo parâmetro de regularização C , que define o grau de penalização dos erros de classificação: valores elevados tornam o modelo mais rígido, enquanto valores menores favorecem maior flexibilidade e generalização (James et al., 2023).

Além disso, o SVM pode empregar funções de kernel para modelar relações não lineares entre as variáveis. O kernel transforma implicitamente os dados em um espaço de maior dimensão, onde uma separação linear se torna possível (Izbicki e Santos, 2020). Neste estudo, utilizou-se o kernel de Base Radial (RBF), que mede a similaridade entre os pontos com base na distância euclidiana. Essa escolha justifica-se pela capacidade do RBF de capturar padrões altamente não lineares e complexos no comportamento histórico e demográfico dos clientes, otimizando a identificação do risco de default (Izbicki e Santos, 2020).

3.1.3 Random Forest

O Random Forest é um método de aprendizado baseado em ensemble que combina múltiplas árvores de decisão para produzir uma predição final mais robusta. Em vez de depender de um único modelo, a abordagem utiliza a agregação de diversos estimadores, sendo a decisão final obtida por votação majoritária no caso de classificação (James et al., 2023).

Diferente de uma árvore de decisão convencional, que é altamente suscetível a ruídos e ao overfitting, este modelo utiliza a técnica de *bagging* (*bootstrap aggregation*) (Izbicki e Santos, 2020). Nesse processo, cada árvore é treinada com uma amostra aleatória dos dados originais extraída com reposição, garantindo que cada modelo individual seja exposto a uma variação distinta do conjunto de dados.

Este modelo foi selecionado por sua robustez frente a ruídos e pela capacidade de modelar interações não lineares entre as variáveis sem exigir transformações adicionais nos dados. Além disso, sua estrutura baseada em múltiplas árvores reduz o risco de overfitting e fornece um modelo estável para problemas de classificação com características heterogêneas.

3.1.4 XG Boost

O XGBoost (Extreme Gradient Boosting) é uma técnica de ensemble baseada em árvores de decisão, na qual cada nova árvore é construída sequencialmente para corrigir os erros das anteriores. Essa abordagem permite ao modelo capturar relações complexas e não lineares entre as variáveis, resultando em elevado desempenho preditivo (Chen e Guestrin, 2016; Izbicki e Santos, 2020).

O processo de treinamento é controlado por hiperparâmetros como a taxa de aprendizado (*learning rate*), que regula a contribuição de cada árvore, a profundidade máxima das árvores (*max_depth*) e o número de estimadores (*n_estimators*). O ajuste adequado desses parâmetros é fundamental para equilibrar a capacidade de aprendizado do modelo e evitar o overfitting.

Este modelo foi incluído devido ao seu reconhecido alto desempenho em problemas de classificação supervisionada, especialmente em bases tabulares. Sua capacidade de corrigir erros de forma sequencial o torna altamente eficaz para discernir os sutis comportamentos financeiros associados à inadimplência.

3.1.5 Voting Classifier

O Voting Classifier é uma técnica de ensemble que combina diferentes modelos com o objetivo de melhorar o desempenho preditivo e reduzir a variabilidade das estimativas (James et al., 2023). Neste estudo, o modelo foi composto por Regressão Logística, Random Forest e XGBoost.

O Voting Classifier faz a apuração dos modelos de duas formas, votação rígida ou simples (Scikit-Learn, 2026):

Votação rígida (hard voting): opera sob o princípio da maioria. Por exemplo, se dos 3 modelos, 2 dizem "Inadimplente" e 1 diz "Adimplente", o resultado final será Inadimplente.

Votação suave (soft voting): O algoritmo soma as probabilidades de cada classe dadas por todos os modelos e tira uma média. A classe com a maior média vence.

Neste estudo, adotou-se a abordagem de votação suave (soft voting), uma vez que ela preserva a incerteza associada às previsões individuais e calibra de forma mais fina as probabilidades finais, fator de extrema relevância na análise de risco de crédito.

3.1.6 Long Short-Term Memory (LSTM)

O LSTM (Long Short-Term Memory) é uma arquitetura avançada de Redes Neurais Recorrentes (RNN), que lida de forma eficaz com ruídos, representações distribuídas e valores contínuos. Uma das principais vantagens deste modelo está na retropropagação de erro constante dentro de suas células de memória, o que permite à rede conectar eventos separados por grandes lacunas de tempo. (Hochreiter, Schmidhuber, 1997).

O LSTM tem uma estrutura em camadas (input, hidden e output), que atualizam em ciclos de entrada e saída (input,output) o Cell State (hidden). A atualização é feita por “portas” (gates), que irão remover ou adicionar informação para a Cell State, usando funções sigmoid e tangente hiperbólica (Qiu, Wang, 2025):

- 1- Forget Gate decide quais informações do passado devem ser descartadas ou retidas;
- 2- Input Gate define quais novas informações atualizam a memória para o Cell State;
- 3- Cell State Update combinação do estado anterior com adição da célula atual;
- 4- Output Gate determina quanto do Cell State tem impacto na previsão final.

A escolha de mais este modelo para o presente trabalho justifica-se pela natureza temporal dos dados de risco de crédito, aproveitando as vantagens descritas acima, esse tipo de rede neural pode identificar interações no histórico cronológico do cliente (como padrões de atraso espaçados nos meses).

3.2 Métricas de avaliação de desempenho:

3.2.1 ROC-AUC

A métrica ROC-AUC (Area Under the Receiver Operating Characteristic Curve) é utilizada para avaliar o desempenho de modelos de classificação binária, com foco na capacidade do classificador em distinguir entre classes distintas. A curva ROC é um gráfico que relaciona a taxa de verdadeiros positivos (VP) com a taxa de falsos positivos (FP), considerando todos os possíveis limiares de decisão (James et al., 2023).

A AUC resume o desempenho do modelo em um único valor, sem a necessidade de definir um ponto de corte específico. Valores próximos de 1 indicam excelente capacidade discriminativa, enquanto uma AUC de 0,5 representa um desempenho equivalente ao acaso (James et al., 2023). No contexto deste estudo, a AUC pode ser interpretada como a probabilidade de o modelo atribuir um escore de risco maior a um cliente inadimplente escolhido aleatoriamente do que a um cliente adimplente.

3.2.2 Acurácia

A acurácia representa a proporção total de previsões corretas em relação ao número total de observações analisadas. Em problemas de classificação binária, essa métrica considera tanto os verdadeiros positivos quanto os verdadeiros negativos, conforme a equação: (James et al., 2023):

$$Acurácia = \frac{VP + VN}{VP + VN + FP + FN}$$

Verdadeiros Positivos (VP): clientes inadimplentes corretamente identificados;

Verdadeiros Negativos (VN): clientes adimplentes corretamente identificados;

Falsos Positivos (FP): clientes adimplentes classificados incorretamente como inadimplentes;

Falsos Negativos (FN): clientes inadimplentes classificados incorretamente como adimplentes.

Quanto maior seu valor, maior é a proporção de classificações corretas realizadas pelo modelo. No entanto, essa métrica pode ser inadequada em bases de dados desbalanceadas, pois um modelo pode apresentar alta acurácia mesmo sem identificar corretamente a classe minoritária .

Dessa forma, embora a acurácia forneça uma visão geral do desempenho do modelo, sua interpretação deve ser complementada por métricas como recall, precisão, F1-score

e ROC-AUC, especialmente em problemas de risco de crédito, nos quais o principal objetivo é identificar corretamente a classe minoritária de interesse (James et al., 2023).

3.2.3 Recall

Recall, também conhecido como sensibilidade, é uma métrica utilizada para avaliar a capacidade de um modelo de identificar corretamente as instâncias da classe positiva. Ele é definido como a proporção de verdadeiros positivos (VP) em relação ao total de instâncias positivas reais (James et al., 2023), conforme a equação:

$$Recall = \frac{VP}{VP + FN}$$

Onde falso negativo (FN) representa os casos positivos que foram incorretamente classificados como negativos (James et al., 2023).

No contexto deste estudo, o Recall representa a capacidade do modelo de identificar corretamente os clientes inadimplentes. Um valor elevado nesta métrica indica que o algoritmo consegue capturar a maior parte dos casos de default, reduzindo a ocorrência de falsos negativos, que, neste cenário, representam clientes de alto risco que não foram identificados pelo banco.

Entretanto, o aumento do Recall frequentemente está associado a uma redução na precisão, uma vez que o modelo pode tornar-se excessivamente conservador, classificando clientes adimplentes como potenciais inadimplentes (James et al., 2023).

3.2.4 Precisão

A precisão é uma métrica utilizada para avaliar a qualidade das predições positivas realizadas por um modelo de classificação, indicando a proporção de instâncias corretamente classificadas como positivas em relação ao total de instâncias previstas como tal (James et al., 2023), conforme a equação:

$$Precisão = \frac{VP}{VP + FP}$$

No contexto deste estudo, a precisão representa a proporção de clientes classificados como inadimplentes que, de fato, apresentaram *default*. Um valor elevado nesta métrica indica que o modelo minimiza os falsos positivos, ou seja, evita classificar clientes adimplentes como inadimplentes.

Entretanto, a maximização da precisão tende a tornar o modelo excessivamente conservador, o que pode resultar em uma redução do *recall* (James et al., 2023). Em

cenários de análise de risco, uma precisão isoladamente alta pode ser problemática, pois o custo financeiro de não identificar um inadimplente (falso negativo) costuma ser significativamente superior ao custo de investigar um cliente adimplente erroneamente classificado (falso positivo).

3.2.5 F1-score

O F1-score é uma métrica que sintetiza a precisão e o recall em uma única medida, sendo amplamente adotada em problemas de classificação com dados desbalanceados. Diferentemente da média aritmética, o F1-score corresponde à média harmônica entre essas duas métricas, o que garante uma penalização maior para modelos que apresentem desempenho elevado em apenas uma delas, em relação à outra (James et al., 2023), conforme a equação:

$$F1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}}$$

No contexto deste estudo, o F1-score permite avaliar o desempenho geral do modelo na identificação de clientes inadimplentes. Ele atua equilibrando a necessidade de detectar o *default* e a importância de evitar a classificação incorreta de clientes adimplentes como inadimplentes (precisão).

Um valor elevado de F1-score indica que o algoritmo atingiu um compromisso satisfatório entre essas duas dimensões. Entretanto, por se tratar de uma média, essa métrica pode mascarar assimetrias entre precisão e recall (James et al., 2023).

3.2.6 Matriz de Confusão

A matriz de confusão é uma ferramenta utilizada para avaliar o desempenho de modelos de classificação, permitindo a análise detalhada da distribuição de acertos e erros. Ela organiza as previsões em uma estrutura tabular que compara as categorias reais com as previstas pelo algoritmo (James et al., 2023).

No escopo deste estudo, a análise da matriz permite transcender a métrica de acurácia global, focando na natureza dos erros. O falso negativo é tratado como a falha mais crítica, uma vez que clientes com perfil de default não identificados representam risco direto ao capital da instituição. Por outro lado, o falso positivo é monitorado pelo seu impacto comercial, evitando que clientes financeiramente saudáveis sofram recusas indevidas de crédito (James et al., 2023).

4. Estudo de Caso

4.1 Análise Exploratória e Diagnóstico do Dataset

A etapa inicial de um projeto de Machine Learning é fundamental para compreender a natureza dos dados e garantir a integridade do modelo preditivo. No contexto deste trabalho, a análise exploratória iniciou-se com a identificação dos tipos de dados, verificando a presença de variáveis categóricas (como sexo, escolaridade e estado civil) e variáveis numéricas contínuas (como valor do limite de crédito, histórico de faturas e pagamentos anteriores). A descrição das variáveis permitiu observar a escala dos valores e a consistência das informações temporais que compõem o histórico de pagamentos dos clientes.

Target

A variável alvo (target) do dataset, denominada “default payment next month”, indica o status de pagamento do cliente, ou seja, se ele se tornará inadimplente na fatura do mês subsequente. Neste contexto, a classe 0 (zero) representa os clientes adimplentes (que honram seus pagamentos), enquanto a classe 1 identifica os clientes inadimplentes.

Ao analisar a distribuição dessa variável, constata-se que 77,88% dos registros da base pertencem à classe 0, contra apenas 22,12% referentes à classe 1. Esse cenário confirma de forma crítica a presença de classes desbalanceadas no dataset, evidenciando uma predominância significativa de bons pagadores em relação a maus pagadores.

A principal dificuldade gerada por essa assimetria estatística é o viés introduzido no treinamento dos modelos preditivos. Ao lidar com dados desproporcionais, os algoritmos tradicionais de aprendizado de máquina tendem a priorizar os acertos da classe majoritária, alcançando uma acurácia global alta, porém enganosa. O impacto direto disso é que o modelo falharia em identificar a classe minoritária (inadimplentes), que é o foco de interesse de gestão de risco financeiro.

Para mitigar esse comportamento e evitar a dependência de dados sintéticos que poderiam distorcer a realidade estatística do problema, optou-se pela aplicação da técnica de Class Weight. Esse método ajusta os pesos do modelo durante o treinamento, atribuindo uma penalidade maior para erros cometidos na classe minoritária, garantindo que o algoritmo aprenda com eficácia os padrões de inadimplência mesmo diante da desproporção dos dados.

Exploração de features:

Sex, Education, Marriage

Dando continuidade à fase de análise exploratória e pré-processamento, foi realizada uma inspeção nas variáveis categóricas do dataset. Como é comum no processo de ciência de dados, as variáveis devem ser validadas e, se necessário, limpas para evitar ruídos nos algoritmos. Durante essa análise, identificou-se a necessidade de adequar

certos registros que fugiam do padrão estabelecido pela documentação oficial do dataset.

A seguir, detalha-se o tratamento e a distribuição dessas variáveis fundamentais:

Gênero (Sex): A variável que representa o gênero dos clientes, classificada como uma variável categórica nominal (onde ordem matemática não faz diferença), apresentou-se totalmente aderente à documentação original, não exigindo nenhum tipo de alteração ou limpeza. Em relação a sua distribuição, observou-se uma predominância da categoria 2, que engloba 60,37% da base de dados, enquanto a categoria 1 representa os 39,63% restantes.

Escolaridade (Education): A variável de escolaridade, de natureza categórica ordinal, revelou algumas inconsistências em relação ao dicionário de dados. Originalmente, a feature apresentava sete valores distintos, variando de 0 a 6. No entanto, os registros preenchidos com 0, 5 e 6 não possuíam correspondência na documentação oficial do problema. Para garantir a consistência estatística e a padronização dos dados, realizou-se uma adequação no dataset convertendo esses valores atípicos (0,5 e 6) para a categoria 4, que agrupa as observações de escolaridade sob o rótulo de “Outros”.

Estado Civil (Marriage): A variável referente ao estado civil, que também possui caráter categórico nominal, passou por uma padronização corretiva semelhante à da escolaridade. Detectou-se a presença do valor 0, um registro que não estava mapeado no documento oficial. Para solucionar essa divergência e alinhar os dados aos padrões esperados, os registros preenchidos com 0 foram transformados para a categoria 3, correspondente a “Outros”. Dessa forma, feature foi adequada para a etapa de modelagem preditiva, garantindo a coesão das classes.


Pagamentos (PAY): Avançando na análise exploratória, foi investigada as variáveis relativas ao histórico de pagamentos. Durante a investigação, identificou-se uma divergência em relação à documentação oficial do dataset: a presença de valores “-2” e “0”. Como a exclusão imediata de dados atípicos ou não documentados nem sempre é a melhor abordagem sem antes realizar uma tentativa de entender o contexto, fez-se necessário investigar o impacto estatístico desses registros na variável target.

Para compreender o real comportamento desses valores, realizou-se uma análise comparativa da distribuição da inadimplência. Avaliou-se o comportamento do target nos meses mais recentes (PAY_1, PAY_2 e PAY_3), cruzando os registros preenchidos com “-2” e “0” em contraposição aos registros que indicavam atrasos severos e já documentados como quantidade de meses em atraso (6, 7 e 8).

Os resultados dessa comparação foram reveladores, demonstrando a grande correlação entre essas variáveis e o target e permitiram o entendimento da natureza desses dados. Diagnosticou-se que os clientes classificados com os códigos “-2” e “0” apresentam uma tendência à inadimplência, concentrando aproximadamente 86% e 88% de bons pagadores em suas distribuições. Em forte contraste, o grupo de clientes que apresentou

atrasos históricos de 6,7 ou 8 meses demonstrou um comportamento oposto, com a maioria (cerca de 58%) evoluindo para a inadimplência no mês subsequente.

Figura 1. Comparação da relação dos valores das variáveis PAY_1, PAY_2 e PAY_3 com o target



Fonte: Autores, 2026

Diante desse diagnóstico, conclui-se que, apesar da ausência de definição na documentação original, os código “-2” e “0” representam perfis de comportamento financeiro saudável, possivelmente, dado contexto de cartão de crédito, indicando faturas sem uso prévio, pagamentos antecipados ou créditos em favor do cliente. A constatação garante que essas categorias não são meros ruídos, e com isso, foram devidamente mantidas na base observada.

Para finalizar a etapa de análise exploratória de dados (EDA), a análise de correlação foi conduzida para investigar e quantificar a associação linear entre as variáveis predictoras e a variável alvo. Os resultados obtidos revelam padrões comportamentais e financeiros importantes que guiarão o treinamento dos algoritmos. Destaca-se o diagnóstico do histórico de **Pagamentos** (PAY_x), variáveis que indicam o status de pagamento dos últimos seis meses, que apresenta comportamento temporal lógico: o atraso no mês imediatamente anterior (PAY_1) possui coeficiente de correlação de 0.32, é o indicador mais forte de que o cliente não pagará a próxima fatura. Essa força preditiva decai de forma gradual e consistente à medida que recuamos no tempo, chegando a 0.18 no sexto mês (PAY_6). Com isso finalizamos esta etapa de EDA.

4.2 Preparação

O Machine Learning possibilita a aplicação de algoritmos mais precisos e eficientes, capazes de identificar padrões complexos e relações não lineares nos dados, tornando-se uma ferramenta estratégica para instituições financeiras (James et al., 2023). No entanto, modelos estatísticos e de aprendizagem são altamente sensíveis à qualidade dos dados de entrada, uma vez que a presença de informações incorretas ou irrelevantes pode induzir o overfitting.

A preparação dos dados constitui uma etapa intermediária entre a análise exploratória e a aplicação dos modelos estatísticos, sendo fundamental para garantir a qualidade e a consistência das informações utilizadas.

Neste estudo, essa etapa é estruturada com base em três pilares principais: particionamento da base em conjuntos de treino, validação e teste; (i) padronização e tratamento de variáveis categóricas e numéricas; e (iii) tratamento do desbalanceamento de classes.

4.2.1 Particionamento dos dados: Inicialmente, realizou-se a partição da base de dados em três subconjuntos distintos: treino (60%), validação (20%) e teste (20%), isolando a variável target (default payment next month). Essa divisão permite avaliar a capacidade de generalização dos modelos em dados não vistos, reduzindo o risco de overfitting (James et al., 2023).

4.2.2 Padronização e escalonamento de dados: nesta etapa, utilizou-se a ferramenta *ColumnTransformer*, da biblioteca *scikit-learn*, com o objetivo de estruturar um fluxo de pré-processamento consistente e reproduzível. Essa abordagem permite aplicar, de forma simultânea e organizada, diferentes transformações para variáveis numéricas e categóricas, respeitando a natureza de cada tipo de dado.

- **Tratamento de Variáveis Numéricas:** Para os atributos contínuos, como idade, limite de crédito, históricos de faturas e pagamentos, foram padronizadas utilizando o *StandardScaler*, que aplica a transformação baseada no *Z-score*. Esse processo ajusta as variáveis para que apresentem média zero e desvio padrão unitário, garantindo que todas contribuam de forma equilibrada no treinamento dos modelos (Scikit-Learn, 2026). Sem o escalonamento, variáveis com escalas numéricas maiores (como a renda anual ou o limite de crédito) teriam um peso desproporcional na predição em comparação a variáveis binárias ou demográficas, enviesando o resultado final. Esse tratamento é essencial para assegurar a convergência estável de algoritmos baseados em otimização por gradiente, como a rede neural LSTM, e o desempenho de modelos que utilizam cálculos de distância euclidiana, como o SVM
- **Tratamento de Variáveis Categóricas:** Os atributos nominais, como sexo, escolaridade e estado civil, foram submetidos ao *OneHotEncoder*. Esta técnica converte categorias em variáveis binárias (0 ou 1), permitindo que o algoritmo processe os dados sem atribuir uma ordem hierárquica inexistente (Scikit-Learn, 2026). Como resultado, houve a expansão do número de atributos da base de dados, passando de 23 para 29 variáveis.

4.2.3 Tratamento de Classes Desbalanceadas (*Class Weight*): A estratégia de pesos de classe (class weight) consiste em uma técnica de balanceamento que atua de forma direta sobre a penalização do erro na função de custo, sem que seja necessário modificar a composição original da base de dados (Izbicki e Santos, 2020). Na prática, tal método confere uma carga de importância superior aos erros cometidos na classe minoritária (clientes inadimplentes), tornando-os mais onerosos para o algoritmo do que as falhas de classificação da classe majoritária.

No problema de predição de inadimplência, a base apresenta desbalanceamento significativo: aproximadamente 77,88% dos clientes são adimplentes, enquanto apenas 22,12% são inadimplentes. Em cenários como esse, os modelos de classificação possuem uma tendência natural de priorizar o acerto na classe predominante, uma vez que tal comportamento maximiza o índice de acurácia global (James et al., 2023). Como consequência, o modelo pode apresentar um desempenho aparentemente elevado, mas falhar em identificar a classe de maior interesse, os clientes inadimplentes.

Sem o uso de técnicas de balanceamento, o modelo poderia, por exemplo, classificar todos os clientes como adimplentes e ainda assim atingir cerca de 78% de acerto, sem cumprir o objetivo principal do estudo, que é identificar o risco de inadimplência.

A aplicação do class weight força o algoritmo a processar com maior rigor os padrões dos casos minoritários, garantindo a relevância estatística da classe de menor volume sem recorrer a expansões artificiais dos dados (Izbicki e Santos, 2020).

Como resultado, observa-se frequentemente uma ligeira retração na métrica de acurácia total, o que é compensado por uma elevação substancial no recall (sensibilidade) dos inadimplentes.

4.3 Aplicação do Algoritmos

Os modelos Regressão Logística, SVM e Random Forest foram implementados utilizando a biblioteca scikit-learn. Nesses modelos, utilizou-se o parâmetro `class_weight = "balanced"`, permitindo o ajuste automático dos pesos conforme a distribuição das classes.

Para o modelo XGBoost, foi utilizada a biblioteca XGBoost, sendo o desbalanceamento tratado por meio do parâmetro `scale_pos_weight`, calculado com base na proporção entre as classes. Adicionalmente, sempre que aplicável, definiu-se o parâmetro `random_state` para garantir a reprodutibilidade dos experimentos.

O processo de modelagem seguiu uma lógica estruturada em formato de pipeline, iniciando com o uso dos dados previamente processados (`X_train_proc` e `y_train`), os quais passaram por etapas de preparação, como limpeza, transformação e padronização das variáveis. O treinamento dos modelos foi realizado com esse conjunto de dados, visando capturar padrões relevantes para a tarefa de classificação.

Após o treinamento, os modelos foram aplicados ao conjunto de validação (`X_val_proc`), que não foi utilizado durante o ajuste, permitindo uma avaliação mais fiel da capacidade de generalização. Nessa etapa, foram geradas tanto as predições de classe, por meio do método `predict`, quanto às probabilidades associadas à classe positiva, por meio do método `predict_proba`, possibilitando análises mais detalhadas do desempenho.

O modelo **LSTM** exigiu uma reformulação estrutural da base de dados (`reshape`). O formato tabular padrão, onde o histórico de seis meses ficava distribuído em colunas, foi

“pivotado” para um array tridimensional (3D) onde os registros ficam empilhados cronologicamente:

Exemplo do formato anterior [n_clientes, n_features]

Registro 1: [Age, Limit_bal, PAY_1, PAY_2,...,PAY_AMT6]

Exemplo com o reshape aplicado:

Registro 1:

Mês 1 [Age, Limit_bal, PAY_6, BILL_AMT6,...,PAY_AMT6]

Mês 2 [Age, Limit_bal, PAY_5, BILL_AMT5, PAY_AMT5]

(...)

Mês 6 [Age, Limit_bal, PAY_1, BILL_AMT1, PAY_AMT1]

A implementação do algoritmo foi realizada com a biblioteca tensorflow.keras, com a seguinte estrutura e parametrização:

- Arquitetura: Iniciou-se com uma camada LSTM principal (64 neurônios) processando os 6 meses, seguida por uma camada Dropout (0.3) para prevenir o overfitting. A saída passa por uma camada oculta Densa (32 neurônios, ativação ReLU) e finaliza em uma camada Densa de 1 neurônio (ativação Sigmoid) para gerar a probabilidade binária final.
- Treinamento e Parada: O modelo foi compilado com o otimizador Adam e função de perda binary_crossentropy. Para lidar com o desbalanceamento das classes, usou-se o EarlyStopping focado na métrica val_auc, interrompendo o treinamento após 12 épocas sem melhoria (patience=12) e restaurando os melhores pesos obtidos.

4.4 Resultados

Analisando os modelos apresentados, foram obtidos os seguintes resultados:

Tabela 1. Comparação de resultados variável 0 (adimplentes) e 1 (inadimplentes).

Método	precision_0	recall_0	f1_0	precision_1	recall_1	f1_1
Logistic	0,8690	0,6871	0,7674	0,3657	0,6353	0,4642
SVM	0,8695	0,8367	0,8528	0,4923	0,5576	0,5230
RandomForest	0,8340	0,9480	0,8873	0,6468	0,3353	0,4417
XGBoost	0,8618	0,8164	0,8385	0,4545	0,5388	0,4931
Voting	0,8561	0,8924	0,8738	0,5545	0,4717	0,5098
LSTM	0,8436	0,9405	0,8894	0,6481	0,3858	0,4837

Fonte: Autores, 2026


Tabela 2. Comparação de resultados accuracy e roc_auc

Método	accuracy	roc_auc
Logistic	0,6757	0,7116
SVM	0,7750	0,7513
RandomForest	0,8125	0,7563
XGBoost	0,7550	0,7463
Voting	0,7993	0,7574
LSTM	0,8178	0,7697

Fonte: Autores, 2026

Dentre os modelos testados, o **Support Vector Machine (SVM)** apresentou o melhor desempenho geral em termos de equilíbrio entre as métricas, com destaque para o maior F1-score (0,5230), além de um recall de 0,5576 e precisão de 0,4923. Esses resultados indicam uma boa capacidade do modelo em identificar clientes inadimplentes, mantendo um controle adequado sobre falsos positivos. A análise da matriz de confusão reforça esse desempenho, evidenciando que o SVM foi capaz de identificar 740 inadimplentes, com 587 falsos negativos e 763 falsos positivos, configurando um equilíbrio consistente entre os tipos de erro. Na modelagem de risco de crédito, a minimização do falso negativo é um aspecto crítico, pois esse tipo de erro ocorre quando o modelo classifica um cliente inadimplente como adimplente.


Figura 2. Matriz de confusão: SVM



Fonte: Autores, 2026

A **Regressão Logística**, por sua vez, apresentou o maior valor de recall (0,6353), sendo o modelo mais eficaz na identificação de inadimplentes, com 843 casos corretamente classificados. No entanto, esse desempenho ocorre à custa de um elevado número de falsos positivos (1462), refletido também em sua baixa precisão (0,3657). Esse comportamento indica uma tendência do modelo em classificar mais clientes como inadimplentes, o que pode resultar em rejeições indevidas de crédito.


Figura 3. Matriz de confusão: Regressão logística



Fonte: Autores, 2026

O **Random Forest** apresentou alta precisão (0,6468) e baixo número de falsos positivos (243), demonstrando um comportamento mais conservador. Entretanto, seu recall de 0,3353 evidencia uma limitação significativa, sendo capaz de identificar apenas 445 inadimplentes, enquanto deixa de detectar 882 casos, o maior número de falsos negativos entre os modelos analisados. Esse resultado indica que, embora eficiente em dizer quem é bom pagador, o modelo não atende adequadamente ao objetivo principal de identificar o risco de inadimplência.

Figura 4. Matriz de confusão: Random Forest




Fonte: Autores, 2026

O **XGBoost** apresentou um desempenho intermediário, com recall de 0,5388, precisão de 0,4545 e F1-score de 0,4931, além de identificar 715 inadimplentes. Apesar de

demonstrar equilíbrio, não teve desempenho superior em nenhuma métrica quando comparado com o SVM, sendo uma boa alternativa robusta, mas não a melhor.


Figura 5. Matriz de confusão: XGBoost



Fonte: Autores, 2026

O modelo **Voting Classifier** apresentou um comportamento equilibrado, com F1-score de 0,5098, recall de 0,4717 e precisão de 0,5545, além de identificar 626 inadimplentes. Embora tenha apresentado menor número de falsos positivos (503) em comparação ao SVM, o aumento no número de falsos negativos (701) indica uma perda maior na identificação de inadimplentes, tornando-o menos adequado para o contexto de risco de crédito.


Figura 6. Matriz de confusão: Voting Classifier



Fonte: Autores, 2026

Por fim, o modelo **LSTM** apresentou a maior acurácia (0,8178) e o maior ROC-AUC (0,7697), o que poderia indicar um bom desempenho geral. No entanto, ao analisar o recall de 0,3858, o modelo identificou apenas 494 inadimplentes, deixando de detectar 833 casos, evidenciando baixa sensibilidade à classe minoritária. Esse comportamento demonstra que a acurácia, isoladamente, não é uma métrica adequada para avaliação em bases desbalanceadas.

Figura 7. Matriz de confusão: LSTM



OneHotEncoder é o que?

Fonte: Autores, 2026

Portanto, embora modelos como a LSTM e o Random Forest apresentem um desempenho superior em métricas de acurácia, o **SVM** se destaca por oferecer o equilíbrio entre a identificação de inadimplentes e o controle de erros, sendo o modelo mais adequado para o contexto do estudo. Essa análise reforça a importância de não avaliar métricas isoladas.

4.5 Conclusão

Os resultados deste estudo indicam que, em cenários de forte desbalanceamento de classes e considerando o impacto estratégico e financeiro de cada tipo de erro, a avaliação do modelo exige um olhar crítico voltado à classe de inadimplentes. No setor de cartões de crédito, falsos negativos representam perdas financeiras diretas e pressão sobre a Provisão de Devedores (PDD), enquanto que a classificação indevida de um bom pagador como risco (falso positivo) podem gerar perda de receita e desgaste no relacionamento com clientes adimplentes.

Nesse cenário, o F1-score da classe minoritária (Classe 1) mostrou-se um indicador adequado para a avaliação de desempenho. Ao calcular a média harmônica entre precisão e recall, essa métrica apresenta um equilíbrio ideal entre a cobertura e a qualidade das classificações. Entre os algoritmos testados, o modelo Support Vector Machine (SVM) demonstrou o desempenho mais equilibrado, alcançando o maior

F1-score para a classe de inadimplentes (0,5230), além de manter boa performance na classificação da classe majoritária.

Algoritmos de maior complexidade, como o LSTM, apresentaram resultados relevantes, especialmente por sua capacidade de modelar padrões temporais e relações não lineares entre as variáveis. No entanto, apesar de ter obtido a maior acurácia (0,8178) e o maior ROC-AUC (0,7697), o modelo apresentou baixo recall para a classe de inadimplentes (0,3858), indicando menor capacidade de identificar a classe minoritária, que constitui o principal objetivo deste estudo. O Voting Classifier apresentou desempenho competitivo, com F1-score de 0,5098, porém ligeiramente inferior ao obtido pelo SVM (0,5230). Esse resultado demonstra que a combinação dos modelos não foi suficiente para superar o desempenho do SVM no equilíbrio entre precisão e recall.

Dessa forma, observa-se que o SVM se configura como a abordagem mais promissora para o problema de negócio proposto. Entretanto, os resultados indicam que o SVM, LSTM e Voting Classifier podem ser alternativas relevantes para estudos futuros. Recomenda-se, como continuidade da pesquisa, a realização de testes mais aprofundados com esses modelos, explorando diferentes configurações e ajustes de hiperparâmetros, a fim de avaliar ganhos adicionais de desempenho, robustez preditiva e adaptação ao problema de inadimplência, especialmente em cenário desbalanceado.

5. Referências Bibliográficas

Izbicki, R. and Santos, T. M. dos. (2020) *Aprendizado de Máquina: Uma Abordagem Estatística*, 1st edition, Rio de Janeiro, Alta Books.

Qiu, Y. and Wang, J. (2025) “Credit Default Prediction Using Time Series-Based Machine Learning Models”, *Artificial Intelligence and Applications*, v. 3, n. 3, p. 284–294. DOI: 10.47852/bonviewAIA52023655.

James, G., Witten, D., Hastie, T. and Tibshirani, R. (2023) *An Introduction to Statistical Learning: With Applications in Python*, 2nd edition, Springer.

Hochreiter, S. and Schmidhuber, J. (1997) “Long Short-Term Memory”, *Neural Computation*, v. 9, n. 8, p. 1735–1780.

Chen, T. and Guestrin, C. (2016) “XGBoost: A Scalable Tree Boosting System”, In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, p. 785–794.

SCIKIT-LEARN. Voting Classifier. Scikit-learn, 2026. Disponível em: <https://scikit-learn.org/stable/modules/ensemble.html#voting-classifier>. Acesso em: 10 maio 2026.

SCIKIT-LEARN. OneHotEncoder. Scikit-learn, 2026. Disponível em: <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.OneHotEncoder.html>. Acesso em: 10 maio 2026.

SCIKIT-LEARN. StandardScaler. Scikit-learn, 2026. Disponível em: <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>. Acesso em: 10 maio 2026.

Banco Central do Brasil. Estatísticas Monetárias e de Crédito, 27 abr. 2026. Disponível em: <https://www.bcb.gov.br/estatisticas/estatisticasmonetariascredito>. Acesso em: 10 maio 2026